

The effort dial runs out before the money does

All three frontier models now expose the same five-step effort ladder, and Artificial Analysis has run every rung of it. Two things fall out. The top of the ladder is close to worthless: the last step buys between zero and one index points while costing up to a dollar sixty-five more per task. And at any score the three models can all reach, they do not cost remotely the same, with GPT-6 Astra arriving at Fable 5.1's top score for forty-three percent of the money. I work through both axes here, and the one finding I think is more solid than any of the rankings.

WHAT THIS PIECE REPLACES

An earlier version of this page covered Fable 5.1 against GPT-6 Astra only. Claude Opus 5 has since been swept across the same ladder by the same evaluator, so I have rewritten it as a three-model comparison rather than publish a second, overlapping piece. The Fable 5.1 numbers are unchanged; the conclusions are not, because Opus 5 turns out to have by far the steepest effort curve of the three and that changes what the effort dial looks like.

A NOTE ON THE INDEX VERSION

Artificial Analysis re-versions its Intelligence Index, and does so without labelling the scale on published articles. Its own Fable 5.1 launch piece reports a max-effort score of 66 against Opus 5's 63. The live leaderboard, under v4.3.2, reports 53 and 51. These are not a disagreement, they are two different scales, and I have used v4.3.2 throughout because it is the one that currently has all three models on it. Anyone still quoting 66 is quoting a retired scale.

SECTION ONE

What the dial actually controls

Effort is not a quality slider. It is a budget for deliberation, and the three vendors spend it very differently. Across the five settings Opus 5 moves from seven thousand reasoning tokens per task to forty-three thousand, Fable 5.1 from eight to forty-seven thousand, and Astra from under a thousand to seventeen thousand. That last figure is the one to hold on to: at its most expansive setting, Astra is still thinking with roughly a third of the tokens the Anthropic models spend at theirs.

What a reader wants to know is whether that extra thinking is bought back in results. For most of the ladder it is. At the top of it, it is not.

SECTION TWO

The curve, and where it goes flat

The three curves have genuinely different shapes, and the shape matters more than the finishing position.




Figure 1. Artificial Analysis Intelligence Index v4.3.2 across the five effort settings. Table 5.1 and Astra converge on 53 from opposite directions; Opus 5 runs a parallel track below both.

Opus 5 gains twelve index points from low to max, which is twice what either of the others gains. Read one way that is a strength, since the dial is doing real work. Read the other way it is a weakness, because what it mostly reflects is that Opus 5's low setting is comparatively poor: thirty-nine against forty-six and forty-seven. Astra gains seven points and four of them arrive in the first step. Table 5.1 gains six across the whole ladder, which is the intended behaviour of a model whose cheapest setting is already strong.

The practical consequence is that the gap between the models depends entirely on where you run them. At low effort Opus 5 is seven to eight points behind. At max it is two. If you were choosing a model by reading a single matched-max comparison, you would be choosing on the narrowest margin the data offers.

SECTION THREE

The frontier, once cost is on the axis

The index-against-effort chart is the one everybody publishes. The one that decides anything is index against cost, because effort levels are not comparable across vendors and dollars are.

Astra's entire curve sits above and to the left of both Anthropic models. There is no score it reaches that either of them reaches more cheaply. Astra at low effort, at eighty-two cents and a score of forty-six, beats Opus 5 at medium effort, at two dollars nineteen and a score of forty-five. Table 5.1 and Astra both finish on fifty-three, at seven dollars sixty-three and three dollars twenty-six respectively. That is two point three times the money for an identical score. Opus 5 does not reach fifty-three at any setting or any price.

I want to be careful about what this does and does not establish. It is one evaluator's index, run once, at list prices. It is not a claim that Astra is the better model for a given job, and section six is about a benchmark split that cuts the other way. But as a statement about what a point of measured capability costs, it is the least ambiguous thing in this entire dataset.




Figure 2. The same five settings per model, plotted against what a task actually costs. Up and to the left is better.

SECTION FOUR

The last step buys nothing

Diminishing returns on deliberation are expected. The rate of the diminishing is what surprised me.




Figure 3. Marginal efficiency of each step up the ladder, in index points per extra dollar per task.

The first step returns between three point three and five point six index points per extra dollar. The last returns between zero and one point one. For Fable 5.1 the last step returns exactly zero: xhigh and max both score fifty-three, and max costs one dollar sixty-five more per task, emits seventeen thousand more output tokens and takes sixty seconds longer. On the eight index components, max beats xhigh on three of them and loses on two.

My reading is that for Fable 5.1, max effort is not a setting to be used by default. It is a setting for the specific tasks where SciCode-like or long-context work is the bottleneck, and the two points it buys there are worth paying for. Used as a global default it is a straightforward waste.

SECTION FIVE

Eight benchmarks, and a clean split

The aggregate index hides a specialisation that is consistent across every effort level, which makes it much harder to dismiss as noise.




Figure 4. The eight percentage and index-scaled components of the Intelligence Index. Vertical scales differ per panel, so read the shapes and the ordering rather than the heights.

Astra leads both Anthropic models at every effort level on the three tool-use and document-grounded evaluations: AutomationBench-AA by seven to thirteen points, Terminal-Bench 4.0 by two to seven over Fable 5.1 and eight to sixteen over Opus 5, and GDP.pdf by two to six and nine to thirteen respectively. Fable 5.1 leads on the scientific-code and knowledge evaluations, by seven points on SciCode at max and four on Humanity's Last Exam, and it is the only model above eighty-four percent on AA-LCR long-context retrieval.

Opus 5 leads nothing at matched max effort. Its best result is a tie with Astra on SciCode and on Humanity's Last Exam. Its weakness is concentrated almost entirely in the agentic column, which is worth knowing if agentic work is not what you are buying it for.

SECTION SIX

More effort is not reliably better

Ten of the twenty-four model and benchmark pairs in the component set are non-monotone in effort. Some of that is noise at small sample counts. Two of them are not.

Fable 5.1's GDP.pdf score falls monotonically across the whole ladder, twenty-eight percent at low down to twenty-six at max. Opus 5's AA-LCR long-context score peaks at medium, eighty-two percent, and is three points lower at max. A single dip is noise; a monotone decline over four steps is a pattern, and the pattern is that on long-document retrieval, extended deliberation appears to hurt. I would not want to over-read two series, but it is enough that I would not set max effort globally without checking it against the specific task type.

SECTION SEVEN

What effort costs in tokens and time

Cost per task is a derived figure. The underlying quantities are more revealing.




Figure 5. Per-task output tokens and wall-clock time, from the same index runs.

At max effort Fable 5.1 emits seventy-eight thousand output tokens per task and Opus 5 seventy-three thousand, against Astra's twenty-seven thousand. For the same index score, that is roughly a third of the tokens. Latency follows: a max-effort task takes Opus 5 seven hundred and ninety-one seconds and Fable 5.1 seven hundred and thirty-seven, against Astra's four hundred and ninety. At low effort the relative gap is wider still, seventy-nine seconds against one hundred and seventy-three and two hundred and seventy-six.

For anything a person waits on, that is the difference between a pause and a coffee break, and it is the argument for running below max that I find most persuasive. The index points you give up going from max to xhigh are worth one or zero. The seconds you get back are worth sixty.

SECTION EIGHT

The two labs disagree about Opus 5, and only about Opus 5

This is the finding I did not expect and the one I am most confident is real, because it does not depend on trusting either vendor's number.

On all four Fable 5.1 figures the two labs agree to the decimal: 55.8, 52.6, 31.4, 65.0. On all three Opus 5 figures OpenAI's number is between 7.6 and 9.5 points lower than Anthropic's. OpenAI's own page puts Opus 5 at 44.5 percent on Terminal-Bench 4.0 where Anthropic reports 52.3.

Exact agreement on one model and systematic disagreement on the other rules out most of the innocent explanations. A harness difference, a scaffold difference or sampling variance would perturb both models, not one. The explanation I find most likely is that OpenAI carried Fable 5.1's figures across from Anthropic's published table while re-running Opus 5 itself, possibly at a lower effort setting, though I cannot demonstrate that from the pages themselves. Either way the practical rule is the one I would apply to any of these tables: do not build a comparison on a competitor's reported figure for a third-party model.

SECTION NINE




Figure 6. The seven model and benchmark pairs for which both labs publish a figure.

What independent evaluators say

Two organisations run these models themselves rather than republishing vendor figures, and they do not fully agree with each other.

Vals AI puts Fable 5.1 first on its aggregate index at 68.83 percent, Opus 5 second at 67.21 and Astra third at 66.61. The whole spread is 2.2 points against stated confidence intervals of plus or minus 1.08 and 1.09, so Fable's lead over Astra is at the edge of significance and Opus 5's position is not distinguishable from either. On Terminal-Bench 4.0 Vals independently reproduces Artificial Analysis's ordering, Astra ahead of Fable 5.1 ahead of Opus 5, at consistently lower absolute values. Two evaluators agreeing on rank while disagreeing on level is the normal and healthy pattern.

ARC Prize is the only other source publishing effort-resolved numbers. On ARC-AGI-2 Astra leads Fable 5.1 at every matched level, by 7.1 points at low narrowing to 3.3 at high and xhigh. Opus 5 was run at high and max only. I would treat ARC-AGI-1 as saturated, since at 96 to 99 percent it is measuring sampling noise, and I would treat ARC-AGI-3 with caution: its two harnesses disagree by thirty-seven points on the same model, and its no-effort setting scores higher than its low setting, which should not happen.

LMarena separates its four listed variants by eighteen Elo points on vote counts ranging from 2,693 to 42,617. That ordering is not statistically meaningful and I would not cite it. Its WebDev board, where the spread is 113 points, is worth more: Astra 1800, Fable 5.1 1758, Opus 5 1687.

SECTION TEN

What this evidence cannot settle

Most of the comparison a reader actually wants does not exist. Neither Anthropic nor OpenAI publishes a single effort-labelled number. Both ship effort-swept charts with unlabelled axes, which is a decision I find hard to read charitably given how easily the figures could be tabulated. Artificial Analysis is the only source with all three models on all five settings, and for Astra's per-effort data it is the only source at all, with no independent replication anywhere.

There are no effort breakdowns anywhere for OSWorld, CursorBench, FrontierMath, GPQA, Terminal-Bench-Science or SWE-bench. SWE-bench Verified has no published entry for any

of the three models; the figures in circulation are vendor-reported and unverifiable. Nobody publishes results indexed by thinking-token budget, so the named ladder is all there is and the reasoning-tokens column is the closest available proxy.

Two of Artificial Analysis's own metrics, AA-Briefcase and GDPval-AA, returned different values on repeated reads of the same comparison pages, so I have left them out of every figure here rather than pick one. And the margins at matched max effort, 53 against 53 against 51, sit inside the range where a second independent evaluator produces a different ordering entirely. The cost and token findings are far more robust than the capability ranking, and if you take one thing from this piece I would rather it were those.

Sources

Primary data. Artificial Analysis three-way comparison, model leaderboard and the per-effort comparison pages for each model; Vals Index v2 and Vals Terminal-Bench 4.0; ARC Prize results for GPT-6 Astra, Fable 5.1 and Opus 5; LMArena. Vendor figures from Anthropic and OpenAI.

What I verified. Every figure in this piece was read off the cited page on 21 September 2026, and the matched-max row of the Artificial Analysis component table was re-read directly rather than taken second hand. Nothing is estimated or interpolated. Where two sources disagree I have shown both rather than averaging them.

What I could not verify. Astra's per-effort figures have no independent replication. The official SWE-bench, Terminal-Bench, OSWorld and LiveBench leaderboards render their tables client-side and returned nothing, so every figure I have for those benchmarks is second hand. AA-Briefcase and GDPval-AA were unstable across repeated reads and are excluded from the figures. Aggregator sites were used only where they name a primary source, and every conflict I found traces to an aggregator disagreeing with a primary site.

エフォートのつまみは、費用より先に効き目が尽きる

三つのフロンティアモデルはいずれも同じ 5 段階のエフォート階梯を公開しており、Artificial Analysis がその全段を実測した。そこから二つのことが出てくる。階梯の最上段はほとんど無価値である。最後の一段が買うのは指数で 0 から 1 ポイントにすぎず、その代わりに 1 タスクあたり最大 1.65 ドルを余計に払う。そして三つのモデルがともに到達できるスコアにおいて、費用はまったく同じではない。GPT-6 Astra は Fable 5.1 の最高スコアに、その 43 パーセントの金額で到達する。ここでは両方の軸を検討し、どの順位付けよりも確かだと考えている一つの発見を述べる。

この記事が置き換えたもの

このページの以前の版は Fable 5.1 と GPT-6 Astra の比較のみを扱っていた。その後 Claude Opus 5 が同じ 評価者によって同じ階梯で実測されたため、重複する二本目を公開するのではなく、三モデル比較として書き直した。Fable 5.1 の数値は変わっていないが、結論は変わっている。Opus 5 のエフォート曲線が三つの中で群を抜いて急であり、それがエフォートのつまみの見え方を変えるからである。

指数のバージョンについて

Artificial Analysis は知能指数を改版するが、公開記事では尺度のバージョンを明示しない。同社自身の Fable 5.1 発表記事は最大エフォートで 66、Opus 5 で 63 と報じている。現行のリーダーボードは v4.3.2 の下で 53 と 51 である。これは不一致ではなく、別の尺度である。本稿では三モデルすべてが載っている v4.3.2 を通して用いた。いま 66 を引用している文章は、すでに引退した尺度を引用している。

第一節

つまみが実際に制御しているもの

エフォートは品質のつまみではない。熟慮に充ててよい予算であり、三社はその使い方がかなり異なる。5 段階を通じて、Opus 5 は 1 タスクあたりの推論トークンを 7000 から 4 万 3000 へ、Fable 5.1 は 8000 から 4 万 7000 へ動かす。Astra は 1000 未満から 1 万 7000 である。最後の数字を覚えておきたい。最も潤沢な設定においてなお、Astra は Anthropic 勢が最大設定で費やすトークンの三分の一ほどで考えている。

読者が知りたいのは、その追加の思考が結果として回収されるかどうかである。階梯の大部分では回収される。頂上では、されない。

第二節

曲線と、それが平坦になる地点

三本の曲線は形が本当に異なり、その形は到達点よりも重要である。




図1。Artificial Analysis 知能指数 v4.3.2 の5段階。Fable 5.1 と Astra は反対方向から 53 に収束し、Opus 5 はその下を並行して走る。

Opus 5 は低から最大まで 12 ポイント伸びる。他の二つのいずれの 2 倍である。一方の読み方ではこれは強みであり、つまみが実際に働いていることを意味する。もう一方の読み方では弱みである。主に反映しているのは、Opus 5 の低設定が相対的に劣ることだからだ。39 に対して 46 と 47 である。Astra は 7 ポイント伸び、そのうち 4 は最初の一段で到達する。Fable 5.1 は階梯全体で 6 ポイントであり、これは最も安い設定がすでに強いモデルの意図された振る舞いである。

実際上の帰結は、モデル間の差がどの設定で走らせるかに完全に依存するということである。低エフォートでは Opus 5 は 7 から 8 ポイント後ろにいる。最大では 2 ポイントである。同一最大エフォートの比較表を一つだけ読んでモデルを選ぶなら、このデータが提示する最も狭い差で選んでいることになる。

第三節

費用を軸に置いたときの前線

指数対エフォートの図は誰もが公開する。何かを決められるのは指数対費用の図のほうである。エフォートの段階はベンダー間で比較できないが、ドルは比較できるからだ。

Astra の曲線全体が、Anthropic 勢いずれの曲線よりも上かつ左にある。Astra が到達するスコアで、どちらかがより安く到達できるものは一つもない。低エフォートの Astra は 82 セントでスコア 46、中エフォートの Opus 5 は 2.19 ドルでスコア 45 である。Fable 5.1 と Astra はともに 53 で終わるが、それぞれ 7.63 ドルと 3.26 ドルである。同一スコアに 2.3 倍の金額ということになる。Opus 5 はどの設定でも、いくら払っても 53 に届かない。

これが何を立証し何を立証しないかについては慎重でありたい。単一の評価者の指数を一度走らせたものであり、定価での話である。ある仕事にとって Astra が優れたモデルだという主張ではない。第六節では逆向きに切れるベンチマークの分裂を扱う。しかし、測定された能力 1 ポイントの値段についての言明としては、このデータ全体の中で最も曖昧さが少ない。

第四節




図2。モデルごとの同じ 5 設定を、1 タスクが実際にいくらかかるかに対して描いた。左上ほど良い。

最後の一段は何も買わない

熟慮の収益が逓減することは予想される。驚いたのはその速さである。




図3。階段を一段上がるごとの限界効率を、1 タスクあたり追加1ドルあたりの指数ポイントで示す。

最初の一段は追加 1 ドルあたり 3.3 から 5.6 ポイントを返す。最後の一段は 0 から 1.1 である。Fable 5.1 の最後の一段はちょうどゼロを返す。超高と最大はともに 53 であり、最大は 1 タスクあたり 1.65 ドル高く、出力 トークンを 1 万 7000 多く出し、60 秒長くかかる。指数の 8 構成要素のうち、最大が超高に勝つのは 3 つ、負けるのは 2 つである。

私の読みでは、Fable 5.1 の最大エフォートは既定で使う設定ではない。SciCode 的な仕事や長文脈の仕事がボトルネックになる特定のタスクのための設定であり、そこで買える 2 ポイントは払う価値がある。全体の既定値として使えば、それは端的な浪費である。

第五節

8 つのベンチマーク、そして明確な分裂

総合指数は、どのエフォート段階でも一貫している専門分化を隠している。一貫しているからこそ、ノイズとして片付けるのは難しい。




図4。知能指数のうち百分率および指数尺度の8構成要素。縦軸の尺度は図ごとに異なるので、高さではなく形と順序を読んでほしい。

Astra は道具使用と文書接地の3評価において、すべてのエフォート段階で Anthropic 勢の両方を上回る。AutomationBench-AA で7から13ポイント、Terminal-Bench 4.0でFable 5.1に対し2から7、Opus 5に対し8から16、GDP.pdfでそれぞれ2から6および9から13である。Fable 5.1は科学コードと知識の評価で先行し、最大設定のSciCodeで7ポイント、人類最後の試験で4ポイント上回る。AA-LCRの長文脈検索で84パーセントを超える唯一のモデルでもある。

Opus 5は同一最大エフォートで首位に立つ項目がない。最良の結果はSciCodeと人類最後の試験でのAstraとの同点である。弱さはほぼエージェント系の列に集中しており、エージェント的な仕事のために買うのではないなら、知っておく価値がある。

第六節

エフォートを上げれば必ず良くなるわけではない

構成要素のモデルとベンチマークの組24のうち、10がエフォートに対して単調でない。一部は少数標本でのノイズである。二つはそうではない。

Fable 5.1のGDP.pdfは階梯全体で単調に下がる。低で28パーセント、最大で26である。Opus 5のAA-LCR長文脈スコアは中で82パーセントの頂点を打ち、最大では3ポイント低い。一度の落ち込みはノイズだが、4段にわたる単調な低下はパターンである。そのパターンとは、長文書の検索においては熟慮の延長がむしろ害になるらしい、ということだ。2系列を過大に読むつもりはないが、タスクの種類に照らして確かめずに最大エフォートを全体の既定値にはしない、と言える程度には十分である。

第七節

エフォートがトークンと時間で払う代償

1 タスクあたり費用は導出された数字である。その下にある量のほうが多くを語る。




図5。同じ指数実行から得た、1タスクあたりの出力トークンと実時間。

最大エフォートで Fable 5.1 は 1 タスクあたり 7 万 8000 の出力トークンを、Opus 5 は 7 万 3000 を出す。Astra は 2 万 7000 である。同じ指数スコアに対して、およそ三分の一のトークンということになる。レイテンシも同様である。最大エフォートの 1 タスクに Opus 5 は 791 秒、Fable 5.1 は 737 秒かかり、Astra は 490 秒である。低エフォートでは相対差はさらに大きく、79 秒に対して 173 秒と 276 秒である。

人が待つものについては、これは一息と休憩の差である。最大より下で走らせる論拠として、私が最も説得的だと感じるのはこれだ。最大から超高に下げて手放す指数ポイントは 1 か 0 の値打ちしかない。取り戻す秒数は 60 の値打ちがある。

第八節

二社は Opus 5 についてだけ食い違う

これは予想していなかった発見であり、同時に最も確度が高いと考えているものでもある。どちらのベンダーの数字を信用するかに依存しないからだ。




図6。両社がともに数値を公表しているモデルとベンチマークの 7 組。

Fable 5.1 の 4 つの数値について、二社は小数点まで一致する。55.8、52.6、31.4、65.0 である。Opus 5 の 3 つの数値については、OpenAI の値が Anthropic の値より 7.6 から 9.5 ポイント低い。OpenAI 自身のページは Terminal-Bench 4.0 で Opus 5 を 44.5 パーセント

としているが、Anthropic は 52.3 と報じている。

一方のモデルで完全一致し、他方で系統的に食い違うという形は、無害な説明の大半を排除する。ハーネスの違い、足場の違い、標本変動であれば、両方のモデルを揺らすはずで、片方だけということはない。最も確からしいと私が考える説明は、OpenAI が Fable 5.1 の数値を Anthropic の公表表から引き写す一方、Opus 5 は自前で、おそらくはより低いエフォート設定で走らせ直した、というものである。ただしページ自体からそれを実証することはできない。いずれにせよ実務的な規則は、この種の表すべてに私が適用するものと同じである。競合他社が公表した第三者モデルの数値の上に比較を組み立ててはならない。

第九節

独立した評価者は何と言っているか

ベンダーの数値を転載するのではなく自ら実行している組織が二つあり、両者は完全には一致しない。

Vals AI は総合指数で Fable 5.1 を 68.83 パーセントで 1 位、Opus 5 を 67.21 で 2 位、Astra を 66.61 で 3 位とする。全体の幅は 2.2 ポイントで、表示されている信頼区間はプラスマイナス 1.08 と 1.09 である。したがって Fable の Astra に対する優位は有意性の境目にあり、Opus 5 の位置はどちらとも区別できない。Terminal-Bench 4.0 では Vals は Artificial Analysis の順序、すなわち Astra、Fable 5.1、Opus 5 の順を独立に再現しており、絶対値は一貫して低い。二つの評価者が順位で一致し水準で食い違うのは、正常で健全な形である。

エフォート別の数値を公開しているもう一つの情報源は ARC Prize だけである。ARC-AGI-2 では Astra がすべての同一段階で Fable 5.1 を上回り、低で 7.1 ポイント、高と超高では 3.3 ポイントまで縮まる。Opus 5 は高と最大でのみ実行された。ARC-AGI-1 は飽和していると見るべきで、96 から 99 パーセントの領域では標本ノイズを測っている。ARC-AGI-3 は慎重に扱いたい。同一モデルで二つのハーネスが 37 ポイント食い違い、エフォートなしの設定が低設定より高いスコアを出しているが、これは起きてはならないことである。

LMArena は掲載されている 4 つの変種を 18 Elo 点の幅で並べているが、投票数は 2,693 から 42,617 まで幅がある。この順序は統計的に意味がなく、引用しない。幅が 113 点ある WebDev のボードのほうが価値がある。Astra 1800、Fable 5.1 1758、Opus 5 1687 である。

第十節

このエビデンスが決着させられないこと

読者が実際に求める比較の大半は存在しない。Anthropic も OpenAI も、エフォートを明示した数値を一つも公開していない。両社ともエフォートを振った図を軸ラベルなしで出している。数値を表にするのがどれほど容易かを思えば、好意的に読むのは難しい判断である。三モデルすべてを 5 設定すべてで持つ情報源は Artificial Analysis だけであり、Astra のエフォート別データについてはそこが唯一の情報源で、独立した再現はどこにもない。

OSWorld、CursorBench、FrontierMath、GPQA、Terminal-Bench-Science、SWE-bench については、エフォート別の内訳がどこにも存在しない。SWE-bench Verified には三モデルいずれの公開エントリもなく、流通している数値はベンダー公表であって検証できない。思考トークン予算で刻んだ結果を公開している者もないので、名前のついた階梯がすべてであり、推論トークン数の列が入手できる最も近い代理指標である。

Artificial Analysis 自身の指標のうち AA-Briefcase と GDPval-AA の 2 つは、同じ比較ページを繰り返し読む たびに異なる値を返した。どちらかを選ぶのではなく、本稿のすべての図から外してある。そして同一最大エフォート での差、53 対 53 対 51 は、二つ目の独立した評価者がまったく異なる順序を出す範囲の内側にある。費用とトークン についての発見は能力の順位付けよりはるかに頑健であり、この記事から一つ持ち帰るとすれば、そちらであってほしい。

出典

一次データ。Artificial Analysis の 三者比較、モデルリーダーボード、および各モデルの エフォート別比較ページ。Vals Index v2 と Vals Terminal-Bench 4.0。ARC Prize の GPT-6 Astra、Fable 5.1、Opus 5 の結果。LMArena。ベンダー公表値は Anthropic と OpenAI による。

検証したこと。本稿のすべての数値は 2026年9月21日に 出典ページから直接読み取った。Artificial Analysis の構成要素表のうち同一最大エフォートの行は、孫引きではなく直接読み直している。推定や 補間が行っていない。二つの情報源が食い違う場合は、平均せず双方を示した。

検証できなかったこと。Astra のエフォート別数値には独立した再現がない。SWE-bench、Terminal-Bench、OSWorld、LiveBench の公式リーダーボードは表をクライアント側で描画しており何も返さなかった ため、これらのベンチマークについて私が持つ数値はすべて孫引きである。AA-Briefcase と GDPval-AA は再読のたびに不安定であり、図から除外した。集約サイトは一次情報源を明示している場合にのみ用いた。見つかった食い違いはすべて、集約サイトが一次サイトと食い違っているものに遡る。