

Effort buys less than the model you point it at.

Claude Fable 5.1 across five effort settings, against GPT-6 Astra

Benjamin Michael Haire · 8 September 2026 · all figures: Intelligence Index v4.3

Reasoning effort is not a quality dial; it is a budget for deliberation over whatever is already in the context window. Raising effort lets the model spend more tokens reasoning before it commits, which helps when the answer is hard to derive from material the model can already see. It does nothing when the material is the wrong material. The five settings are five points on a deliberation-budget curve, and the question is where that curve stops repaying its cost. On the current index the answer is earlier than anyone would guess, and the more consequential choice turns out to be a different one entirely.

On the index version. Artificial Analysis has retired Intelligence Index v4.2 and rescored every model on v4.3, whose agentic-coding component is now Terminal-Bench v4.0 rather than v2.1. The versions are not comparable. The models did not change; only the measurement did. Every figure here is v4.3.

1 The curve, and where it goes flat

The horizontal axis is logarithmic, so a constant return per doubling of spend would appear as a straight line. Any downward bend is real diminishing return rather than an artefact of the scale.




Figure 1. The effort frontier on index v4.3. Six index points separate low from xhigh, and 87 million output tokens separate them. Between xhigh and max the line is horizontal: both score 53, and the additional 68 million tokens purchase nothing measurable.

That terminal flat segment is new to v4.3. On the previous index there was still a single point of separation between xhigh and max. There is now none, which means the most expensive setting Fable offers is, on this evaluation, indistinguishable from the setting below it.

2 The last setting buys nothing




Figure 2. The value of the marginal token, by step. 0.182 index points per additional million tokens from low to medium, 0.034 from high to xhigh, and exactly zero from xhigh to max.

High remains the last setting where the marginal token does recognisable work. As absolute efficiency the same collapse appears: 1.42 index points per million tokens at low, 0.82 at high, 0.28 at max.

3 Latency is the cost that scales worst

Effort budgets are consumed before the first output token is emitted, so the entire deliberation cost is front-loaded into the wait. A four and a half minute pause does not merely cost four and a half minutes: it breaks the loop in which a developer holds a hypothesis in working memory while the agent tests it.




Figure 3. The latency tax. 6.6 seconds at low against 275.5 at max, a factor of forty-two, while cost per task rises by roughly three.

4 The other axis: which model

Everything above varies one parameter. The more interesting comparison varies the other. GPT-6 Astra is evaluated on the same v4.3 suite at the same list prices, \$10 per million input tokens and \$50 per million output, which makes the cost comparison unusually clean: any difference in spend is a difference in token efficiency rather than in pricing.




Figure 4. Intelligence against what it costs to buy. Astra sits left of Fable throughout. Both reach 51, Astra for \$2,917 and Fable for \$5,242. On this measure Astra is the cheaper route to a given score.

If the index score were the whole story the conclusion would be simple, and it would not favour Fable. That is worth stating plainly before the rest of the analysis complicates it.

5 Ten benchmarks, and a split decision

The index is a composite of ten evaluations. A tie on the composite is compatible with large differences underneath it, and here the differences are large and point in both directions.




Figure 5. Every component of index v4.3, both models at max effort. Fable takes five, Astra takes four, AA-Omniscience ties. Two of Astra's wins are the largest margins on the chart.

Two results cut against the obvious narratives. **CritPt goes to Astra**, 32 against 30. CritPt is research-level physics reasoning: 71 unpublished frontier problems contributed by more than fifty physics researchers across eleven subfields, in guess-resistant formats. If Fable's advantage were fundamentally about depth of physical-science knowledge, that is the benchmark it should win. **AA-Omniscience ties at 43**, but underneath the tie Fable posts 67 per cent raw factual accuracy, the highest on the entire leaderboard. The index penalises confident wrong answers and rewards abstention, so Astra reaches parity by declining more often rather than by knowing more.

6 The only matched-effort comparison

Every figure so far compares the models at max effort, which is nobody's working configuration. AA-Briefcase is the one evaluation publishing both models at all five settings. It scores

long-horizon agentic knowledge work: four multi-week projects, 91 tasks, graded on rubric pass rate, analytical quality and presentation quality combined into an Elo.




Figure 6. AA-Briefcase Elo at matched effort. Fable leads at every setting. Fable at high (1578) scores above Astra at max (1562), and Fable at medium above Astra at high.

The magnitudes are worth comparing directly against the effort dial, because they are in the same units. Moving Fable across its entire effort range gains 178 Elo. Swapping Astra for Fable at fixed effort gains between 84 and 231, typically near 100. On this benchmark the choice of model is worth between half and the whole of the choice of effort setting.

7 The full table

Configuration	Index v4.3	Out. tokens	Suite cost	TTFT	Briefcase
Fable low	47	33M	\$3,158	6.6s	1484
Fable medium	49	44M	\$3,983	9.7s	1531
Fable high	51	62M	\$5,242	23.7s	1578
Fable xhigh	53	120M	\$9,063	107.3s	1650
Fable max	53	188M	\$13,129	275.5s	1662
Astra medium	50	19M	\$2,434	5.2s	1451
Astra high	51	26M	\$2,917	45.6s	1494
Astra max	53	60M	\$5,324	322.5s	1562

Suite cost is the total Artificial Analysis paid to run the full Intelligence Index v4.3 on that configuration, the cleanest like-for-like cost figure because the workload is identical. Both models list at \$10 per million input tokens and \$50 per million output. Astra low and xhigh are omitted: not all metrics are published for them.

8 What the split is actually tracking

The wins are not scattered at random. Fable takes AA-Briefcase, GDPval-AA v2, AA-LCR, Humanity’s Last Exam and SciCode: long-horizon work over dense inputs, long-context reasoning, and knowledge recall and synthesis. Astra takes Terminal-Bench v4.0, AutomationBench-AA, GDP.pdf and CritPt: shorter-horizon tool execution, automation, extraction and constrained problem solving.

The mechanism this suggests is not that one model is smarter. It is that the two have different profiles across context length and horizon. Sustained reasoning over a large amount of already-loaded material is where Fable separates; short, well-scoped, tool-driven tasks are where Astra does. A codebase of serious size imposes the first on almost every task, because the context is always large and the reasoning always has to hold many pieces at once.

9 What this evidence cannot settle

- Nine of the ten sweep comparisons are at max effort, which is neither of the settings most people run. AA-Briefcase is the only matched-effort series, so the central claim rests on a single benchmark.
- Terminal-Bench v4.0 publishes only xhigh and max for either model, so the coding-specific comparison has no entry at high or medium.
- Several gaps are small enough to be within benchmark noise. A two-point CritPt difference and a four-point AA-LCR difference should not carry weight individually; they matter only as part of a consistent pattern across ten evaluations.
- These are eval-suite aggregates over tasks whose context is supplied correctly by the harness. On a codebase of any real size the dominant failure mode is confident reasoning over the wrong files, and raising effort makes that worse rather than better. Neither axis measured here touches that problem.

The dial is nearly exhausted by the time it reaches high, and entirely exhausted above xhigh. The model choice is not exhausted at all. Most of the attention spent on effort settings would be better spent on which model is reading the code, and almost all of it would be better spent on which code the model is reading.

Sources. Artificial Analysis: Claude Fable 5.1 model pages (low to max); GPT-6 Astra model pages (medium, high, max); the Astra versus Fable 5.1 comparison page; and the AA-Briefcase, AA-Omniscience, CritPt, SciCode and Terminal-Bench v4.0 leaderboards. All figures Intelligence Index v4.3, retrieved 8 September 2026. Anthropic, ``Introducing Claude Fable 5.1 and Claude Mythos 5.1''. OpenAI, ``GPT-6 Astra''. Tian M, Gao L, Peng H, et al., ``SciCode'', NeurIPS Datasets and Benchmarks, 2024. Derived quantities are computed from the table above. AI assistance was used for retrieval, computation, figures, drafting and translation; no benchmark was run independently.

エフォートが買えるものは、 どのモデルに向けるかが買えるものより小さい。

Claude Fable 5.1 の 5 段階のエフォート設定と GPT-6 Astra の比較

Benjamin Michael Haire · 2026年9月8日 · 数値はすべて Intelligence Index v4.3

推論エフォートは品質のつまみではない。すでにコンテキストウィンドウに入っている材料に対して、どれだけ熟慮に費やしてよいかという予算である。エフォートを上げるとは、モデルが答えを確定する前により多くのトークンを推論に費やせるようにすることであり、モデルがすでに見ている材料から答えを導くこと自体が難しい場合には有効である。しかし材料そのものが誤っている場合には効かない。5 段階は熟慮予算曲線上の 5 点であり、問うべきはその曲線がどこでコストを回収しなくなるかである。現行の指数における答えは誰の予想よりも早く、より重大な選択はまったく別のところにある。

指数バージョンについて。 Artificial Analysis は Intelligence Index v4.2 を廃止し、全モデルを v4.3 で再採点した。v4.3 のエージェント型コーディング要素は Terminal-Bench v2.1 ではなく v4.0 である。両バージョンは比較可能ではない。モデルが変わったのではなく、測定の側が変わった。本稿の数値はすべて v4.3 である。

1 曲線と、それが平坦になる地点

横軸は対数である。支出が倍増するごとに一定の収益が得られる関係は直線として現れるため、下向きの屈曲は尺度の産物ではなく実際の収穫逨減を意味する。




図 1. 指数 v4.3 におけるエフォートのフロンティア。low と xhigh の差は指数で 6 ポイント、出力トークンでは 8700 万である。xhigh と max のあいだは水平であり、両設定とも 53、追加の 6800 万トークンは測定可能な何もかも購入していない。

この末端の平坦部分は v4.3 で新たに現れたものである。旧指数では xhigh と max のあいだになお 1 ポイントの差があった。現在それはない。すなわち Fable が提供する最も高価な設定は、この評価上、一段下の設定と区別がつかない。

2 最後の設定は何も買わない




図 2. 段階ごとの限界トークンの価値。low から medium では追加 100 万トークンあたり 0.182 ポイント、high から xhigh では 0.034、xhigh から max ではちょうどゼロである。

high は、限界トークンがなお認識可能な仕事をしている最後の設定である。絶対効率として表しても同じ崩壊が現れる。low では 100 万トークンあたり 1.42 指数ポイント、high では 0.82、max では 0.28 である。

3 最も悪くスケールするのはレイテンシである

エフォート予算は最初の出力トークンが放出される前に消費されるため、熟慮のコスト全体が待ち時間に前倒しされる。4 分半の停止は 4 分半の損失にとどまらない。開発者が仮説をワーキングメモリに保持したままエージェントに検証させるループを断ち切る。




図 3. レイテンシ税。low の 6.6 秒に対して max は 275.5 秒、42 倍である。一方で課題あたりのコストは約 3 倍にとどまる。

4 もう一つの軸、どのモデルを選ぶか

ここまではすべて一方の引数を変動させたものである。より興味深い比較はもう一方を変動させる。GPT-6 Astra は同一の v4.3 スイートで、同一の表示価格、すなわち入力 100 万トークンあたり 10 ドル、出力 100 万トークンあたり 50 ドルで評価されている。そのためコスト比較は異例に明快であり、支出の差はすべて価格ではなくトークン効率の差である。




図 4. 知能と、それを買うのに要する費用。Astra は全域で Fable の左にある。両者とも 51 に達するが、Astra は 2,917 ドル、Fable は 5,242 ドルである。この尺度では Astra が安価な経路である。

指数の得点が話のすべてであれば結論は単純であり、しかも Fable に有利ではない。以降がこれを複雑にする前に、この点を明確に述べておく。

5 10 のベンチマーク、そして判定は分かれる

指数は 10 の評価の合成である。合成値での引き分けは、その下にある大きな差と両立する。ここでは差は大きく、しかも両方向を向いている。




図 5. 指数 v4.3 の全構成要素、両モデルとも max エフォート。Fable が 5 つ、Astra が 4 つを取り、AA-Omniscience は引き分けである。Astra の勝利のうち 2 つは図中最大の差である。

分かりやすい筋書きに反する 2 つの結果がある。**CritPt は Astra が取る**。32 対 30 である。CritPt は研究水準の物理推論であり、11 の下位分野にわたる 50 名超の物理研究者が寄稿した未発表のフロンティア問題 71 題を、当て推量に耐える形式で出題する。Fable の優位が本質的に自然科学の知識の深さによるのであれば、勝つべきはこのベンチマークである。**AA-Omniscience は 43 で引き分けるが**、その下で Fable は素の事実正答率 67 パーセントを記録しており、リーダーボード全体の最高値である。この指数は確信を伴う誤答を減点し棄権を評価するため、Astra はより多く知ることによってではなく、より多く答えを控えることによって同水準に達している。

6 唯一の同一エフォート比較

ここまでの数値はすべて max エフォートでの比較であり、それは誰の実運用構成でもない。AA-Briefcase は両モデルを 5 段階すべてで公表している唯一の評価である。長期にわたるエージェント型知識労働を採点するもので、4 つの複数週プロジェクト、91 課題を、ループリック通過率、分析品質、提示品質の合成 Elo で評価する。




図 6. 同一エフォートにおける AA-Briefcase Elo。Fable は全設定で先行する。Fable の high (1578) は Astra の max (1562) を上回り、Fable の medium は Astra の high を上回る。

ここでの大きさはエフォートのつまみと直接比較する価値がある。単位が同じだからである。Fable をエフォート範囲の全域で動かすと 178 Elo を得る。エフォートを固定して Astra を Fable に入れ替えると 84 から 231、典型的にはおよそ 100 を得る。このベンチマーク上では、モデルの選択はエフォート設定の選択の半分から全体に相当する価値をもつ。

7 全データ表

構成	指数 v4.3	出力トークン	実行コスト	初トークン	Briefcase
Fable low	47	33M	\$3,158	6.6秒	1484
Fable medium	49	44M	\$3,983	9.7秒	1531
Fable high	51	62M	\$5,242	23.7秒	1578
Fable xhigh	53	120M	\$9,063	107.3秒	1650
Fable max	53	188M	\$13,129	275.5秒	1662
Astra medium	50	19M	\$2,434	5.2秒	1451
Astra high	51	26M	\$2,917	45.6秒	1494
Astra max	53	60M	\$5,324	322.5秒	1562

実行コストは Artificial Analysis が当該構成で Intelligence Index v4.3 全体を実行するのに要した総額であり、ワークロードが同一であるため最も明快な同条件のコスト指標である。両モデルとも入力 100 万トークンあたり 10 ドル、出力 100 万トークンあたり 50 ドルである。Astra の low と xhigh は一部の指標が未公表のため省いた。

8 この分裂が実際に捉えているもの

勝敗は無作為に散らばってはいない。Fable が取るのは AA-Briefcase、GDPval-AA v2、AA-LCR、Humanity's Last Exam、SciCode である。すなわち情報密度の高い入力に対する長期的作業、長文脈推論、知識の想起と統合である。Astra が取るのは Terminal-Bench v4.0、AutomationBench-AA、GDP.pdf、CritPt であり、比較的短期のツール実行、自動化、抽出、制約下の問題解決である。

ここから示唆される機序は、一方が賢いということではない。両者は文脈長と作業の時間的射程にわたって異なるプロファイルをもつということである。すでに読み込まれた大量の材料に対する持続的推論は Fable が引き離す領域であり、短く適切に区切られたツール駆動の課題は Astra が引き離す領域である。相応の規模をもつコードベースはほぼすべての課題において

前者を課す。文脈は常に大きく、推論は常に多数の断片を同時に保持しなければならないからである。

9 このエビデンスが決着させられないこと

- ・ 掃討比較 10 件のうち 9 件は max エフォートでのものであり、多くの人が実際に使う設定ではない。AA-Briefcase が唯一の同一エフォート系列であるため、中心的主張は単一のベンチマークに依拠している。
- ・ Terminal-Bench v4.0 はいずれのモデルについても xhigh と max しか公表しておらず、コーディング固有の比較は high や medium には存在しない。
- ・ 差のいくつかはベンチマークのノイズに収まる程度に小さい。CritPt の 2 ポイント差や AA-LCR の 4 ポイント差は単独では重みをもつべきではなく、10 の評価にわたる一貫した型の一部としてのみ意味をもつ。
- ・ これらは、ハーネスによってコンテキストが正しく供給された課題群にわたる集計値である。相応の規模をもつコードベースにおいて支配的な失敗様式は誤ったファイルに対する確信に満ちた推論であり、エフォートを上げることはそれを悪化させる。ここで測定されたどちらの軸も、その問題に触れていない。

つまりは high に達する時点でほぼ使い果たされ、xhigh より上では完全に使い果たされている。モデルの選択はまったく使い果たされていない。エフォート設定に費やされる注意の大半は、どのモデルがコードを読んでいるかに向けたほうがよく、そのほぼすべては、モデルがどのコードを読んでいるかに向けたほうがよい。

出典。Artificial Analysis: Claude Fable 5.1 各モデルページ (low から max)、GPT-6 Astra 各モデルページ (medium、high、max)、Astra 対 Fable 5.1 比較ページ、および AA-Briefcase、AA-Omniscience、CritPt、SciCode、Terminal-Bench v4.0 の各リーダーボード。数値はすべて Intelligence Index v4.3、2026 年 9 月 8 日取得。Anthropic 「Introducing Claude Fable 5.1 and Claude Mythos 5.1」。OpenAI 「GPT-6 Astra」。Tian M, Gao L, Peng H, et al. 「SciCode」NeurIPS Datasets and Benchmarks, 2024。導出量は上表から計算した。取得、計算、図版、草稿、翻訳に AI 支援を用いた。ベンチマークを独自に実行してはいない。