

The reasoning-effort dial stops paying long before it reaches the top.

Claude Fable 5.1 across its five effort settings, scored for coding

Benjamin Michael Haire · 8 September 2026

Reasoning effort is not a quality dial; it is a budget for deliberation over whatever is already in the context window. That distinction decides the whole analysis. Raising effort lets the model spend more tokens reasoning before it commits to an answer, which helps when the answer is genuinely hard to derive from material the model can already see. It does nothing at all when the material in front of the model is the wrong material. Fable 5.1's five settings are therefore best read as five points on a deliberation-budget curve, and the interesting question is where that curve stops repaying its cost.

1 What the dial actually controls

Fable 5.1 ships with five effort settings: low, medium, high, xhigh and max. Anthropic sets high as the default in Claude Code and medium in the consumer surfaces, and states that low and medium effort on 5.1 already match full-effort Fable 5. Artificial Analysis evaluated all five before release, running each through the same Intelligence Index v4.2 suite, which is the only public dataset that holds the workload constant while varying only the effort parameter.

Holding the workload constant matters more than it appears. Every published comparison of effort settings measures how much deliberation the model spends on a fixed set of tasks, not how well it performs on tasks of different shapes. The curve below therefore measures one thing precisely: the return on additional deliberation, given a fixed and correctly specified problem. It is silent on the failure mode that dominates large real codebases, which is the problem being specified from the wrong files.

2 Intelligence bought against tokens spent

The horizontal axis below is logarithmic. That choice is not cosmetic: on a log axis a constant return per doubling of spend appears as a straight line, so any downward bend is a real diminishing return rather than an artefact of the scale. Fable 5.1 bends almost immediately.




Figure 1. The effort frontier. Each point is one effort setting running the identical Intelligence Index v4.2 suite. Six index points separate the cheapest setting from the most expensive; ten times the output tokens separate them as well.

The shape is the familiar one for any search process with a finite answer space. Early deliberation eliminates the cheap errors, which are numerous; later deliberation works on the residue,

which is both smaller and harder. What varies between models is where the elbow sits. On Fable 5.1 it sits at high, and everything above high is buying the residue.

3 Coding is where the curve dies earliest

Terminal-Bench v2.1 is the agentic-coding component of the index: long-horizon terminal work, and the closest public proxy for the sort of task a coding agent is actually given. Artificial Analysis publishes it for the top three effort settings only.




Figure 2. Agentic coding across the top three settings. The entire published spread is 3.8 percentage points wide and the three points occupy 1.5 of them. Position rather than length is used, because bars on this range would exaggerate a small difference.

Read as scores, 89.9, 91.0 and 91.4 look like a modest but real progression. Read as an error budget the picture is blunter. At high the model fails 10.1 tasks in every hundred; at max it fails 8.6. Spending 4.3 times the tokens removes 1.5 failures per hundred and leaves the other 8.6 exactly where they were. Those remaining failures are not failures of insufficient deliberation, or more deliberation would have cleared them.

This is also the regime where benchmark saturation starts to matter. A 1.5-point spread at the top of a benchmark is close to the resolution of the benchmark itself. The published numbers can tell us that max is not much better than high; they are too coarse to tell us confidently that it is better at all.

4 Marginal return collapses eighteenfold

Differencing the frontier gives the quantity that should drive the decision: index points gained per additional million output tokens spent on each step up.




Figure 3. The value of the marginal token, by step. The last rung of the ladder is roughly eighteen times worse value per token than the first. Nothing about the model degrades; the evaluation runs out of headroom.

High is the last setting before this figure falls below 0.04. In absolute terms the same collapse is visible as efficiency: 2.68 index points per million tokens at low, 1.23 at high, 0.30 at max. High

delivers 98 per cent of max-effort Terminal-Bench performance for 23 per cent of the output tokens, and that single ratio carries most of the practical argument.

5 Latency is the cost that scales worst

Tokens are the cost that appears on an invoice. Time to first token is the cost that is felt, and it scales far worse than price does. Output speed actually rises with effort, from 52.8 to 69.5 tokens per second, which is why cost per task grows by only 3.6 times across the range while the wait before anything appears grows by 47 times.




Figure 4. The latency tax. At max effort the median first token arrives after four and a half minutes. For an interactive editing loop this is usually the binding constraint well before spend is.

The mechanism is straightforward: effort budgets are spent before the first output token is emitted, so the entire deliberation cost is front-loaded into the wait. A four-minute pause does not merely cost four minutes. It breaks the loop in which a developer holds a hypothesis in working memory while the agent tests it, and that loop is most of the value of an interactive coding agent.

6 The full table

Effort	Index	T-Bench	Tokens	\$/task	TTFT	pts/M
low	51	–	19M	\$1.70	5.8s	2.68
medium	53	–	29M	\$2.14	12.7s	1.83
high	54	89.9%	44M	\$2.86	27.6s	1.23
xhigh	56	91.0%	98M	\$4.64	107.3s	0.57
max	57	91.4%	190M	\$6.12	272.3s	0.30

Output tokens and cost are for running the full Intelligence Index suite, as measured by Artificial Analysis on the Adaptive Reasoning, Default Fallback variants. Pricing is \$10 per million input tokens and \$50 per million output tokens, with cache reads at \$0.25 per million.

7 What follows in practice

- **High is the defensible default**, and is already the default in Claude Code. It sits at the elbow of the curve, and the 98-per-cent-for-23-per-cent trade is the whole argument for it.
- **Medium deserves more consideration than it gets.** If the parity claim holds, medium on 5.1 is full-effort Fable 5 at 12.7 seconds to first token rather than 27.6. For scaffolding, test writing and mechanical refactors, the halved latency is worth more than two index points.
- **Xhigh is a per-task escalation, not a session default.** 1.1 percentage points of Terminal-Bench for 2.2 times the tokens is a poor standing arrangement and a reasonable one-off.
- **Max is hard to justify for coding.** 0.4 points over xhigh for 1.9 times the tokens and 2.5 times

the wait. Its case is single-shot research-grade reasoning, not an editing loop.

8 What this evidence cannot settle

- **Two sets of numbers from the same source disagree.** The Artificial Analysis launch article quotes an index range of 58 to 66 across 13.1M to 143.7M output tokens; the per-model pages and release comparison table give 51 to 57 across 19M to 190M. This analysis uses the model pages throughout, because they are internally consistent across all five settings and are the only ones carrying per-setting cost and latency. The shape of the curve is the same on either set; the absolute levels are not settled.
- **Low and medium have no published Terminal-Bench score,** so the coding curve rests on three points rather than five, and the two cheapest settings are inferred from the composite index alone.
- **The larger limitation is one of construct.** These are eval-suite aggregates over tasks whose context is supplied correctly by the harness. On a codebase of any real size the dominant failure mode is not shallow reasoning over the right files; it is confident reasoning over the wrong ones. Raising effort makes that failure worse rather than better, because it produces more elaborate and more plausible inference from the same faulty premises.

Sources. Artificial Analysis: Claude Fable 5.1 model pages for low, medium, high, xhigh and max effort; the release comparison table; the Terminal-Bench v2.1 leaderboard; and the article ``Claude Fable 5.1 tops the Artificial Analysis Intelligence Index''. Anthropic: ``Introducing Claude Fable 5.1 and Claude Mythos 5.1'', September 2026. All retrieved 7 September 2026. Every derived quantity here is computed from the table in section six rather than taken from a source. AI assistance was used for data retrieval, computation, figure generation, drafting and translation; no benchmark was run independently.

推論エフォートの曲線は、 最上段に達するはるか手前で採算が合わなくなる。

Claude Fable 5.1 の 5 段階のエフォート設定を、コーディング用途で評価する

Benjamin Michael Haire · 2026年9月8日

推論エフォートは品質のつまみではない。すでにコンテキストウィンドウに入っている材料に対して、どれだけ熟慮に費やしてよいかという予算である。この区別が分析全体を決定する。エフォートを上げるとは、モデルが答えを確定する前により多くのトークンを推論に費やせるようにすることであり、モデルがすでに見ている材料から答えを導くこと自体が難しい場合には有効である。しかし目の前にある材料が誤っている場合には、まったく効かない。したがって Fable 5.1 の 5 段階は、熟慮予算曲線上の 5 点として読むのが適切であり、問うべきはその曲線がどこでコストを回収しなくなるかである。

1 エフォートが実際に制御しているもの

Fable 5.1 には low、medium、high、xhigh、max の 5 段階が用意されている。Anthropic は Claude Code では high を、コンシューマ向けの各面では medium を既定値とし、5.1 の low および medium がすでに全エフォートの Fable 5 に匹敵すると述べている。Artificial Analysis はリリース前に 5 段階すべてを評価し、同一の Intelligence Index v4.2 スイートを各設定で実行した。これはワークロードを固定したままエフォート引数のみを変動させた、唯一の公開データセットである。

ワークロードを固定している点は見た目以上に重要である。公開されているエフォート設定の比較はいずれも、固定された課題集合に対してモデルがどれだけ熟慮に費やしたかの比較であって、形の異なる課題における性能の比較ではない。したがって以下の曲線が精確に測定しているのは、問題が固定され正しく指定されている条件下での追加的熟慮の収益という一点である。大規模な実コードベースで支配的となる失敗様式、つまり誤ったファイルから問題が指定されるという事態については何も語らない。

2 投じたトークンに対して得られる知能

下図の横軸は対数である。この選択は装飾ではない。対数軸上では、支出が倍増するごとに一定の収益が得られる関係は直線として現れる。したがって下向きの屈曲は尺度の産物ではなく、実際の収穫逨減を意味する。Fable 5.1 はほぼ即座に屈曲する。




図 1. エフォートのフロンティア。各点は、同一の Intelligence Index v4.2 スイートを実行した 1 つのエフォート設定である。最も安い設定と最も高い設定の差は指数で 6 ポイントであり、同時に出力トークン数では 10 倍の差がある。

この形状は、有限の解空間をもつ探索過程に共通するものである。初期の熟慮は数の多い安価な誤りを除去し、後期の熟慮は残余に取り組む。残余はより小さく、かつより困難である。

モデルごとに異なるのはその肘がどこに位置するかであり、Fable 5.1 では肘は high にある。high より上はすべて残余を買っていることになる。

3 コーディングでは曲線が最も早く死ぬ

Terminal-Bench v2.1 は同指数のエージェント型コーディング要素であり、長時間にわたるターミナル作業を対象とする。コーディングエージェントが実際に与えられる種類の課題に対する、公開されたもののなかで最も近い代理指標である。Artificial Analysis はこれを上位3段階についてのみ公表している。




図 2. 上位3段階におけるエージェント型コーディング。公開されている全範囲は3.8パーセントポイント幅であり、3点はそのうち1.5ポイントを占めるにすぎない。この範囲で棒グラフを用いると小さい差を誇張するため、長さではなく位置で符号化している。

89.9、91.0、91.4 という数値をスコアとして読めば、控えめではあるが実質的な進歩に見える。しかし誤り予算として読むと像はより率直になる。high では100課題あたり10.1件が失敗し、maxでは8.6件が失敗する。4.3倍のトークンを投じて除去できるのは100件あたり1.5件であり、残る8.6件はそのまま残る。この残余は熟慮不足による失敗ではない。もしそうであれば、より多くの熟慮が解消していたはずである。

この領域ではベンチマークの飽和も問題になり始める。ベンチマーク上端における1.5ポイントの幅は、ベンチマーク自体の分解能に近い。公開された数値から言えるのはmaxがhighより大きく優れてはいないということであり、そもそも優れているかどうかを確信をもって述べるには粗すぎる。

4 限界収益は18分の1に崩れる

フロンティアを階差にとると、意思決定を駆動すべき量が得られる。すなわち、各段階の引き上げにおいて追加的に投じた100万出力トークンあたりに得られる指数ポイントである。




図 3. 段階ごとの限界トークンの価値。梯子の最後の一段は、最初の一段に比べてトークンあたりおよそ18倍不利である。モデルが劣化しているのではなく、評価の側に伸びしろがなくなる。

highはこの値が0.04を下回る直前の設定である。絶対量で見ても同じ崩壊が効率として現れる。lowでは100万トークンあたり2.68指数ポイント、highでは1.23、maxでは0.30で

ある。high は出力トークンの 23 パーセントで max の Terminal-Bench 性能の 98 パーセントを実現しており、この 1 つの比が実務上の議論の大半を担っている。

5 最も悪くスケールするのはレイテンシである

トークンは請求書に現れるコストである。最初のトークンまでの時間は体感されるコストであり、価格よりもはるかに悪くスケールする。出力速度自体はエフォートとともに毎秒 52.8 トークンから 69.5 トークンへ上昇する。そのため課題あたりのコストが全域で 3.6 倍にとどまる一方、何かが現れるまでの待ち時間は 47 倍に伸びる。




図 4. レイテンシ税。max では最初のトークンの中央値が 4 分半後に到着する。対話的な編集ループにおいては、支出が制約になるよりはるかに手前でこれが律速となる。

機序は単純である。エフォート予算は最初の出力トークンが放出される前に消費されるため、熟慮のコスト全体が待ち時間に前倒しされる。4 分の停止は 4 分の損失にとどまらない。開発者が仮説をワーキングメモリに保持したままエージェントにそれを検証させるループを断ち切る。そしてそのループこそが、対話的コーディングエージェントの価値の大半である。

6 全データ表

エフォート	指数	T-Bench	トークン	\$/課題	初トークン	百万あたり
low	51	–	19M	\$1.70	5.8秒	2.68
medium	53	–	29M	\$2.14	12.7秒	1.83
high	54	89.9%	44M	\$2.86	27.6秒	1.23
xhigh	56	91.0%	98M	\$4.64	107.3秒	0.57
max	57	91.4%	190M	\$6.12	272.3秒	0.30

出力トークン数とコストは Intelligence Index サイト全体の実行に対するものであり、Artificial Analysis が Adaptive Reasoning, Default Fallback の各構成について測定した値である。価格は入力 100 万トークンあたり 10 ドル、出力 100 万トークンあたり 50 ドル、キャッシュ読み出しは 100 万トークンあたり 0.25 ドルである。

7 実務上の帰結

- **high が擁護可能な既定値であり、Claude Code ではすでに既定値になっている。** 曲線の肘に位置しており、「23 パーセントで 98 パーセント」という取引がその根拠のすべてである。
- **medium は通常受けている以上の検討に値する。** 同等性の主張が成り立つならば、5.1 の medium は全エフォートの Fable 5 に相当し、最初のトークンまで 27.6 秒ではなく 12.7 秒である。足場づくり、テスト記述、機械的なリファクタリングでは、レイテンシ半減の価値は指数 2 ポイントを上回る。

- **xhigh** は課題単位のエスカレーションであってセッション既定値ではない。2.2 倍のトークンで Terminal-Bench 1.1 パーセントポイントを買うのは常設の取り決めとしては拙劣であり、単発の判断としては妥当である。
- **max** はコーディング用途では正当化が難しい。1.9 倍のトークンと 2.5 倍の待ち時間に対して xhigh より 0.4 ポイントである。その用途は編集ループではなく単発の研究水準の推論にある。

8 このエビデンスが決着させられないこと

- 同一の出典から 2 組の数値が食い違っている。Artificial Analysis のローンチ記事は指数を 58 から 66、出力トークンを 1310 万から 1 億 4370 万と記載する一方、モデル別ページおよびリリース比較表は 51 から 57、1900 万から 1 億 9000 万としている。本稿は一貫してモデル別ページを採用した。5 段階すべてで内的に整合しており、設定ごとのコストとレイテンシを載せているのがこちらだけだからである。曲線の形状はいずれの組でも変わらないが、絶対水準は確定していない。
- **low** と **medium** には公開された Terminal-Bench スコアがない。したがってコーディングの曲線は 5 点ではなく 3 点に依拠しており、最も安価な 2 設定は複合指数のみから推定されている。
- より大きな限界は構成概念にある。これらは、ハーネスによってコンテキストが正しく供給された課題群にわたる集計値である。ある程度の規模をもつコードベースにおいて支配的な失敗様式は、正しいファイルに対する浅い推論ではなく、誤ったファイルに対する確信に満ちた推論である。エフォートを上げることはこの失敗を改善するのではなく悪化させる。同じ誤った前提から、より精緻でより尤もらしい推論を生み出すからである。

出典。Artificial Analysis: Claude Fable 5.1 の low / medium / high / xhigh / max 各モデルページ、リリース比較表、Terminal-Bench v2.1 リーダーボード、記事「Claude Fable 5.1 tops the Artificial Analysis Intelligence Index」。Anthropic: 「Introducing Claude Fable 5.1 and Claude Mythos 5.1」2026 年 9 月。いずれも 2026 年 9 月 7 日取得。本稿の導出量はすべて第六節の表から計算したものである。データ取得、計算、図版生成、草稿作成および翻訳に AI 支援を用いた。ベンチマークを独自に実行してはいない。