

推論エフォートの曲線は、 最上段に達するはるか手前で採算が合わなくなる。

Claude Fable 5.1 の 5 段階のエフォート設定を、コーディング用途で評価する

Benjamin Michael Haire · 2026年9月8日

推論エフォートは品質のつまみではない。すでにコンテキストウィンドウに入っている材料に対して、どれだけ熟慮に費やしてよいかという予算である。この区別が分析全体を決定する。エフォートを上げるとは、モデルが答えを確定する前により多くのトークンを推論に費やせるようにすることであり、モデルがすでに見ている材料から答えを導くこと自体が難しい場合には有効である。しかし目の前にある材料が誤っている場合には、まったく効かない。したがって Fable 5.1 の 5 段階は、熟慮予算曲線上の 5 点として読むのが適切であり、問うべきはその曲線がどこでコストを回収しなくなるかである。

1 エフォートが実際に制御しているもの

Fable 5.1 には low、medium、high、xhigh、max の 5 段階が用意されている。Anthropic は Claude Code では high を、コンシューマ向けの各面では medium を既定値とし、5.1 の low および medium がすでに全エフォートの Fable 5 に匹敵すると述べている。Artificial Analysis はリリース前に 5 段階すべてを評価し、同一の Intelligence Index v4.2 スイートを各設定で実行した。これはワークロードを固定したままエフォート引数のみを変動させた、唯一の公開データセットである。

ワークロードを固定している点は見た目以上に重要である。公開されているエフォート設定の比較はいずれも、固定された課題集合に対してモデルがどれだけ熟慮に費やしたかの比較であって、形の異なる課題における性能の比較ではない。したがって以下の曲線が精確に測定しているのは、問題が固定され正しく指定されている条件下での追加的熟慮の収益という一点である。大規模な実コードベースで支配的となる失敗様式、つまり誤ったファイルから問題が指定されるという事態については何も語らない。

2 投じたトークンに対して得られる知能

下図の横軸は対数である。この選択は装飾ではない。対数軸上では、支出が倍増するごとに一定の収益が得られる関係は直線として現れる。したがって下向きの屈曲は尺度の産物ではなく、実際の収穫逨減を意味する。Fable 5.1 はほぼ即座に屈曲する。




図 1. エフォートのフロンティア。各点は、同一の Intelligence Index v4.2 スイートを実行した 1 つのエフォート設定である。最も安い設定と最も高い設定の差は指数で 6 ポイントであり、同時に出力トークン数では 10 倍の差がある。

この形状は、有限の解空間をもつ探索過程に共通するものである。初期の熟慮は数の多い安価な誤りを除去し、後期の熟慮は残余に取り組む。残余はより小さく、かつより困難である。

モデルごとに異なるのはその肘がどこに位置するかであり、Fable 5.1 では肘は high にある。high より上はすべて残余を買っていることになる。

3 コーディングでは曲線が最も早く死ぬ

Terminal-Bench v2.1 は同指数のエージェント型コーディング要素であり、長時間にわたるターミナル作業を対象とする。コーディングエージェントが実際に与えられる種類の課題に対する、公開されたもののなかで最も近い代理指標である。Artificial Analysis はこれを上位3段階についてのみ公表している。




図 2. 上位3段階におけるエージェント型コーディング。公開されている全範囲は3.8パーセントポイント幅であり、3点はそのうち1.5ポイントを占めるにすぎない。この範囲で棒グラフを用いると小さい差を誇張するため、長さではなく位置で符号化している。

89.9、91.0、91.4 という数値をスコアとして読めば、控えめではあるが実質的な進歩に見える。しかし誤り予算として読むと像はより率直になる。high では 100 課題あたり 10.1 件が失敗し、max では 8.6 件が失敗する。4.3 倍のトークンを投じて除去できるのは 100 件あたり 1.5 件であり、残る 8.6 件はそのまま残る。この残余は熟慮不足による失敗ではない。もしそうであれば、より多くの熟慮が解消していたはずである。

この領域ではベンチマークの飽和も問題になり始める。ベンチマーク上端における 1.5 ポイントの幅は、ベンチマーク自体の分解能に近い。公開された数値から言えるのは max が high より大きく優れてはいないということであり、そもそも優れているかどうかを確信をもって述べるには粗すぎる。

4 限界収益は 18 分の 1 に崩れる

フロンティアを階差にとると、意思決定を駆動すべき量が得られる。すなわち、各段階の引き上げにおいて追加的に投じた 100 万出力トークンあたりに得られる指数ポイントである。




図 3. 段階ごとの限界トークンの価値。梯子の最後の一段は、最初の一段に比べてトークンあたりおよそ 18 倍不利である。モデルが劣化しているのではなく、評価の側に伸びしろがなくなる。

high はこの値が 0.04 を下回る直前の設定である。絶対量で見ても同じ崩壊が効率として現れる。low では 100 万トークンあたり 2.68 指数ポイント、high では 1.23、max では 0.30 で

ある。high は出力トークンの 23 パーセントで max の Terminal-Bench 性能の 98 パーセントを実現しており、この 1 つの比が実務上の議論の大半を担っている。

5 最も悪くスケールするのはレイテンシである

トークンは請求書に現れるコストである。最初のトークンまでの時間は体感されるコストであり、価格よりもはるかに悪くスケールする。出力速度自体はエフォートとともに毎秒 52.8 トークンから 69.5 トークンへ上昇する。そのため課題あたりのコストが全域で 3.6 倍にとどまる一方、何かが現れるまでの待ち時間は 47 倍に伸びる。




図 4. レイテンシ税。max では最初のトークンの中央値が 4 分半後に到着する。対話的な編集ループにおいては、支出が制約になるよりはるかに手前でこれが律速となる。

機序は単純である。エフォート予算は最初の出力トークンが放出される前に消費されるため、熟慮のコスト全体が待ち時間に前倒しされる。4 分の停止は 4 分の損失にとどまらない。開発者が仮説をワーキングメモリに保持したままエージェントにそれを検証させるループを断ち切る。そしてそのループこそが、対話的コーディングエージェントの価値の大半である。

6 全データ表

エフォート	指数	T-Bench	トークン	\$/課題	初トークン	百万あたり
low	51	–	19M	\$1.70	5.8秒	2.68
medium	53	–	29M	\$2.14	12.7秒	1.83
high	54	89.9%	44M	\$2.86	27.6秒	1.23
xhigh	56	91.0%	98M	\$4.64	107.3秒	0.57
max	57	91.4%	190M	\$6.12	272.3秒	0.30

出力トークン数とコストは Intelligence Index サイト全体の実行に対するものであり、Artificial Analysis が Adaptive Reasoning, Default Fallback の各構成について測定した値である。価格は入力 100 万トークンあたり 10 ドル、出力 100 万トークンあたり 50 ドル、キャッシュ読み出しは 100 万トークンあたり 0.25 ドルである。

7 実務上の帰結

- **high** が擁護可能な既定値であり、Claude Code ではすでに既定値になっている。曲線の肘に位置しており、「23 パーセントで 98 パーセント」という取引がその根拠のすべてである。
- **medium** は通常受けている以上の検討に値する。同等性の主張が成り立つならば、5.1 の medium は全エフォートの Fable 5 に相当し、最初のトークンまで 27.6 秒ではなく 12.7 秒である。足場づくり、テスト記述、機械的なリファクタリングでは、レイテンシ半減の価値は指数 2 ポイントを上回る。

- **xhigh** は課題単位のエスカレーションであってセッション既定値ではない。2.2 倍のトークンで Terminal-Bench 1.1 パーセントポイントを買うのは常設の取り決めとしては拙劣であり、単発の判断としては妥当である。
- **max** はコーディング用途では正当化が難しい。1.9 倍のトークンと 2.5 倍の待ち時間に対して xhigh より 0.4 ポイントである。その用途は編集ループではなく単発の研究水準の推論にある。

8 このエビデンスが決着させられないこと

- 同一の出典から 2 組の数値が食い違っている。Artificial Analysis のローンチ記事は指数を 58 から 66、出力トークンを 1310 万から 1 億 4370 万と記載する一方、モデル別ページおよびリリース比較表は 51 から 57、1900 万から 1 億 9000 万としている。本稿は一貫してモデル別ページを採用した。5 段階すべてで内的に整合しており、設定ごとのコストとレイテンシを載せているのがこちらだけだからである。曲線の形状はいずれの組でも変わらないが、絶対水準は確定していない。
- **low** と **medium** には公開された Terminal-Bench スコアがない。したがってコーディングの曲線は 5 点ではなく 3 点に依拠しており、最も安価な 2 設定は複合指数のみから推定されている。
- より大きな限界は構成概念にある。これらは、ハーネスによってコンテキストが正しく供給された課題群にわたる集計値である。ある程度の規模をもつコードベースにおいて支配的な失敗様式は、正しいファイルに対する浅い推論ではなく、誤ったファイルに対する確信に満ちた推論である。エフォートを上げることはこの失敗を改善するのではなく悪化させる。同じ誤った前提から、より精緻でより尤もらしい推論を生み出すからである。

出典。Artificial Analysis: Claude Fable 5.1 の low / medium / high / xhigh / max 各モデルページ、リリース比較表、Terminal-Bench v2.1 リーダーボード、記事「Claude Fable 5.1 tops the Artificial Analysis Intelligence Index」。Anthropic: 「Introducing Claude Fable 5.1 and Claude Mythos 5.1」2026 年 9 月。いずれも 2026 年 9 月 7 日取得。本稿の導出量はすべて第六節の表から計算したものである。データ取得、計算、図版生成、草稿作成および翻訳に AI 支援を用いた。ベンチマークを独自に実行してはいない。