

エフォートが買えるものは、 どのモデルに向けるかが買えるものより小さい。

Claude Fable 5.1 の 5 段階のエフォート設定と GPT-6 Astra の比較

Benjamin Michael Haire · 2026年9月8日 · 数値はすべて Intelligence Index v4.3

推論エフォートは品質のつまみではない。すでにコンテキストウィンドウに入っている材料に対して、どれだけ熟慮に費やしてよいかという予算である。エフォートを上げるとは、モデルが答えを確定する前により多くのトークンを推論に費やせるようにすることであり、モデルがすでに見ている材料から答えを導くこと自体が難しい場合には有効である。しかし材料そのものが誤っている場合には効かない。5 段階は熟慮予算曲線上の 5 点であり、問うべきはその曲線がどこでコストを回収しなくなるかである。現行の指数における答えは誰の予想よりも早く、より重大な選択はまったく別のところにある。

指数バージョンについて。 Artificial Analysis は Intelligence Index v4.2 を廃止し、全モデルを v4.3 で再採点した。v4.3 のエージェント型コーディング要素は Terminal-Bench v2.1 ではなく v4.0 である。両バージョンは比較可能ではない。モデルが変わったのではなく、測定の側が変わった。本稿の数値はすべて v4.3 である。

1 曲線と、それが平坦になる地点

横軸は対数である。支出が倍増するごとに一定の収益が得られる関係は直線として現れるため、下向きの屈曲は尺度の産物ではなく実際の収穫逨減を意味する。




図 1. 指数 v4.3 におけるエフォートのフロンティア。low と xhigh の差は指数で 6 ポイント、出力トークンでは 8700 万である。xhigh と max のあいだは水平であり、両設定とも 53、追加の 6800 万トークンは測定可能な何もかも購入していない。

この末端の平坦部分は v4.3 で新たに現れたものである。旧指数では xhigh と max のあいだになお 1 ポイントの差があった。現在それはない。すなわち Fable が提供する最も高価な設定は、この評価上、一段下の設定と区別がつかない。

2 最後の設定は何も買わない




図 2. 段階ごとの限界トークンの価値。low から medium では追加 100 万トークンあたり 0.182 ポイント、high から xhigh では 0.034、xhigh から max ではちょうどゼロである。

high は、限界トークンがなお認識可能な仕事をしている最後の設定である。絶対効率として表しても同じ崩壊が現れる。low では 100 万トークンあたり 1.42 指数ポイント、high では 0.82、max では 0.28 である。

3 最も悪くスケールするのはレイテンシである

エフォート予算は最初の出力トークンが放出される前に消費されるため、熟慮のコスト全体が待ち時間に前倒しされる。4 分半の停止は 4 分半の損失にとどまらない。開発者が仮説をワーキングメモリに保持したままエージェントに検証させるループを断ち切る。




図 3. レイテンシ税。low の 6.6 秒に対して max は 275.5 秒、42 倍である。一方で課題あたりのコストは約 3 倍にとどまる。

4 もう一つの軸、どのモデルを選ぶか

ここまではすべて一方の引数を変動させたものである。より興味深い比較はもう一方を変動させる。GPT-6 Astra は同一の v4.3 スイートで、同一の表示価格、すなわち入力 100 万トークンあたり 10 ドル、出力 100 万トークンあたり 50 ドルで評価されている。そのためコスト比較は異例に明快であり、支出の差はすべて価格ではなくトークン効率の差である。




図 4. 知能と、それを買うのに要する費用。Astra は全域で Fable の左にある。両者とも 51 に達するが、Astra は 2,917 ドル、Fable は 5,242 ドルである。この尺度では Astra が安価な経路である。

指数の得点が話のすべてであれば結論は単純であり、しかも Fable に有利ではない。以降がこれを複雑にする前に、この点を明確に述べておく。

5 10 のベンチマーク、そして判定は分かれる

指数は 10 の評価の合成である。合成値での引き分けは、その下にある大きな差と両立する。ここでは差は大きく、しかも両方向を向いている。




図 5. 指数 v4.3 の全構成要素、両モデルとも max エフォート。Fable が 5 つ、Astra が 4 つを取り、AA-Omniscience は引き分けである。Astra の勝利のうち 2 つは図中最大の差である。

分かりやすい筋書きに反する 2 つの結果がある。**CritPt は Astra が取る**。32 対 30 である。CritPt は研究水準の物理推論であり、11 の下位分野にわたる 50 名超の物理研究者が寄稿した未発表のフロンティア問題 71 題を、当て推量に耐える形式で出題する。Fable の優位が本質的に自然科学の知識の深さによるのであれば、勝つべきはこのベンチマークである。**AA-Omniscience は 43 で引き分けるが**、その下で Fable は素の事実正答率 67 パーセントを記録しており、リーダーボード全体の最高値である。この指数は確信を伴う誤答を減点し棄権を評価するため、Astra はより多く知ることによってではなく、より多く答えを控えることによって同水準に達している。

6 唯一の同一エフォート比較

ここまでの数値はすべて max エフォートでの比較であり、それは誰の実運用構成でもない。AA-Briefcase は両モデルを 5 段階すべてで公表している唯一の評価である。長期にわたるエージェント型知識労働を採点するもので、4つの複数週プロジェクト、91 課題を、ループリック通過率、分析品質、提示品質の合成 Elo で評価する。




図 6. 同一エフォートにおける AA-Briefcase Elo。Fable は全設定で先行する。Fable の high (1578) は Astra の max (1562) を上回り、Fable の medium は Astra の high を上回る。

ここでの大きさはエフォートのつまみと直接比較する価値がある。単位が同じだからである。Fable をエフォート範囲の全域で動かすと 178 Elo を得る。エフォートを固定して Astra を Fable に入れ替えると 84 から 231、典型的にはおよそ 100 を得る。このベンチマーク上では、モデルの選択はエフォート設定の選択の半分から全体に相当する価値をもつ。

7 全データ表

構成	指数 v4.3	出力トークン	実行コスト	初トークン	Briefcase
Fable low	47	33M	\$3,158	6.6秒	1484
Fable medium	49	44M	\$3,983	9.7秒	1531
Fable high	51	62M	\$5,242	23.7秒	1578
Fable xhigh	53	120M	\$9,063	107.3秒	1650
Fable max	53	188M	\$13,129	275.5秒	1662
Astra medium	50	19M	\$2,434	5.2秒	1451
Astra high	51	26M	\$2,917	45.6秒	1494
Astra max	53	60M	\$5,324	322.5秒	1562

実行コストは Artificial Analysis が当該構成で Intelligence Index v4.3 全体を実行するのに要した総額であり、ワークロードが同一であるため最も明快な同条件のコスト指標である。両モデルとも入力 100 万トークンあたり 10 ドル、出力 100 万トークンあたり 50 ドルである。Astra の low と xhigh は一部の指標が未公表のため省いた。

8 この分裂が実際に捉えているもの

勝敗は無作為に散らばってはいない。Fable が取るのは AA-Briefcase、GDPval-AA v2、AA-LCR、Humanity's Last Exam、SciCode である。すなわち情報密度の高い入力に対する長期的作業、長文脈推論、知識の想起と統合である。Astra が取るのは Terminal-Bench v4.0、AutomationBench-AA、GDP.pdf、CritPt であり、比較的短期のツール実行、自動化、抽出、制約下の問題解決である。

ここから示唆される機序は、一方が賢いということではない。両者は文脈長と作業の時間的射程にわたって異なるプロファイルをもつということである。すでに読み込まれた大量の材料に対する持続的推論は Fable が引き離す領域であり、短く適切に区切られたツール駆動の課題は Astra が引き離す領域である。相応の規模をもつコードベースはほぼすべての課題において

前者を課す。文脈は常に大きく、推論は常に多数の断片を同時に保持しなければならないからである。

9 このエビデンスが決着させられないこと

- ・ 掃討比較 10 件のうち 9 件は max エフォートでのものであり、多くの人が実際に使う設定ではない。AA-Briefcase が唯一の同一エフォート系列であるため、中心的主張は単一のベンチマークに依拠している。
- ・ Terminal-Bench v4.0 はいずれのモデルについても xhigh と max しか公表しておらず、コーディング固有の比較は high や medium には存在しない。
- ・ 差のいくつかはベンチマークのノイズに収まる程度に小さい。CritPt の 2 ポイント差や AA-LCR の 4 ポイント差は単独では重みをもつべきではなく、10 の評価にわたる一貫した型の一部としてのみ意味をもつ。
- ・ これらは、ハーネスによってコンテキストが正しく供給された課題群にわたる集計値である。相応の規模をもつコードベースにおいて支配的な失敗様式は誤ったファイルに対する確信に満ちた推論であり、エフォートを上げることはそれを悪化させる。ここで測定されたどちらの軸も、その問題に触れていない。

つまりは high に達する時点でほぼ使い果たされ、xhigh より上では完全に使い果たされている。モデルの選択はまったく使い果たされていない。エフォート設定に費やされる注意の大半は、どのモデルがコードを読んでいるかに向けたほうがよく、そのほぼすべては、モデルがどのコードを読んでいるかに向けたほうがよい。

出典。Artificial Analysis: Claude Fable 5.1 各モデルページ (low から max)、GPT-6 Astra 各モデルページ (medium、high、max)、Astra 対 Fable 5.1 比較ページ、および AA-Briefcase、AA-Omniscience、CritPt、SciCode、Terminal-Bench v4.0 の各リーダーボード。数値はすべて Intelligence Index v4.3、2026 年 9 月 8 日取得。Anthropic 「Introducing Claude Fable 5.1 and Claude Mythos 5.1」。OpenAI 「GPT-6 Astra」。Tian M, Gao L, Peng H, et al. 「SciCode」NeurIPS Datasets and Benchmarks, 2024。導出量は上表から計算した。取得、計算、図版、草稿、翻訳に AI 支援を用いた。ベンチマークを独自に実行してはいない。