

What Fable 5.1 still buys you over Opus 5.5

Opus 5.5 costs \$4 and \$20 per million tokens against Fable 5.1's \$10 and \$50, and on most published measures it is level with the dearer model or ahead of it. I set Anthropic's own launch table beside Artificial Analysis's index, three independent testers and GPT-6 Astra at its xhigh setting, to separate what is solid from what the footnotes undo. Opus 5.5 should be the default. Fable 5.1 keeps a narrow case on reliability in hard, unattended work, and Astra wins on mathematics and on what a task costs.

HOW THIS RELATES TO MY EARLIER PIECE

An earlier page, The effort dial runs out before the money does, swept Opus 5, Fable 5.1 and GPT-6 Astra across all five effort settings. Opus 5.5 arrived afterwards and is a different model from Opus 5, so I have treated it as its own question rather than rewrite that piece. The Fable 5.1 and Astra figures here are the same ones.

WHAT IS MEASURED AND WHAT IS ESTIMATED

Every score on this page is a published figure except one. Artificial Analysis does not publish a per-task cost for Opus 5.5 at max effort, so I scaled Fable 5.1's \$7.63 by the ratio of the two models' full-index run costs at max effort (\$8,708 against \$13,129), which gives about \$5.06. It is drawn as a hollow marker and called an estimate wherever it appears. Opus 5.5's medium and high costs, \$1.34 and \$1.82, reached me through a secondary summary of Artificial Analysis data rather than the page itself. Index scores are on v4.3.2, the scale of my earlier piece: Fable 5.1 scores 53 at max on both.

SECTION ONE

The price, and the index

Opus 5.5 costs \$4 per million input tokens and \$20 per million output. Fable 5.1 costs \$10 and \$50, two and a half times as much. Both take a million tokens of context and write up to 128,000. Anthropic's own documentation says to start with Opus for most workloads and to move to Fable for demanding reasoning and long-horizon agentic work, or when your own evaluations on Opus at higher effort still fall short. The defaults differ too: Opus 5.5 runs at medium effort, Fable 5.1 at high.

The fairest comparison follows from that, each model at its default. On the Artificial Analysis Intelligence Index, Opus 5.5 at medium and Fable 5.1 at high both score 51, and the Opus run costs \$1.34 a task against \$3.91. At the top of the ladder the gap opens: Opus 5.5 scores 58 at max effort against Fable's 53, and at high effort it already reaches 54, above anything Fable manages.

Artificial Analysis's own comparison page agrees on the components. At max against max, Opus 5.5 leads on SciCode (67 against 63), Humanity's Last Exam (61 against 59) and AA-




Figure 1. Index against cost per task, log scale. Opus 5.5 has three published effort settings, with max drawn hollow because its cost is my estimate. Fable 5.1 and Astra show all five.

Omniscience, its reliability and hallucination measure (46 against 43), and the two tie on long-context reasoning (85) and on GDPpdf (26).

I would weight two things in Figure 1 above the headline. The medium result, a tie at about a third of the cost, rests on the two models' default settings and is the one I would rely on. The gap at the top is the part I trust least, because it needs one derived cost and a max-effort score I could confirm only on a single comparison page.

SECTION TWO

Anthropic's table, and its footnotes

Anthropic's launch table has Opus 5.5 ahead of Fable 5.1 on all eight comparable benchmarks, by between 0.6 and 10.6 points. The widest margin is Terminal-Bench 4.0, 66.4 against 55.8. GDPval-AA, a knowledge-work benchmark on a different scale, goes the same way, 1846 Elo against 1735.

The footnotes matter, and they cut both ways. Effort was not matched. On Terminal-Bench 4.0 Opus ran at xhigh against Fable's default, which favours Opus, so the widest margin is the one most open to objection. Artificial Analysis's own run at max against max reproduces the direction, 59.6 against 52.0, which is why I still believe it. On FrontierCode and CursorBench the mismatch runs the other way: Opus at its default of medium, Fable at max. Those margins survive a handicap.

Anthropic also says that four of the nine margins fall inside the error bars, and that the gap between the two models is "narrower than these scores suggest." I read that as the vendor asking you to treat the bottom of Figure 2 as a tie. Nothing in the table says Opus is behind on anything.




Figure 2. Opus 5.5's lead over Fable 5.1 on Anthropic's launch benchmarks, in percentage points. AutomationBench is from a secondary report of the same table.

SECTION THREE

The third model, at xhigh

GPT-6 Astra costs what Fable 5.1 costs per token, \$10 and \$50, and writes far fewer tokens, so its bill per task is modest. At xhigh it scores 52 on the index for \$2.31 a task, between Opus 5.5 at medium and Fable at high on cost, level with Opus 5.5 at medium (51) and just under Fable at max (53). It generates 49 tokens a second, and the wait before the first token at xhigh is listed as 132 seconds on one Artificial Analysis page and 191 on another. At medium it is 6.




Figure 3. Launch-table scores on the benchmarks all three models report. Effort levels for the Astra figures are not stated, so this is not an xhigh result.

On the benchmarks the three share, Opus leads on terminal work (66 against 58 for Astra) and on Humanity's Last Exam with tools (68 against 57). Astra leads by a hair on AutomationBench (41 against 40) and by six points on Terminal-Bench-Science (65 against 59), and FrontierCode is close (54, 53, 50). Artificial Analysis's own run puts Astra roughly level with Opus on Terminal-


Bench (59 against 60) and AutomationBench (69 against 70), and clearly above Fable on both.

SECTION FOUR

Where Astra pulls ahead

The benchmarks where Astra is strongest are mostly ones Anthropic does not report for Opus 5.5, so the comparison there is with Fable. Astra scores 97.6% on FrontierMath Tier 4 against Fable's 87.8%, and 95% on ARC-AGI-2 against 90%. On DeepSWE, a coding benchmark, it leads 74% to 67%.

Where Astra is strongest, against Fable 5.1



* OSWorld figures come from an aggregator and use a different version from Anthropic's OSWorld 2.0 table.

Figure 4. Astra against Fable 5.1 on four benchmarks where Astra leads. The OSWorld pair comes from an aggregator and uses a different version from Anthropic's table.

The one result I would not lean on is computer use, 72.6% against 41.7%. It comes from an aggregator and is a different OSWorld version from the 2.0 in Anthropic's table, where Opus scores 81.8 and Fable 80.7. The mathematics gap is the part I believe. ARC Prize's own entry for Opus 5.5 gives 93.3% on ARC-AGI-2 at high effort and 92.5% at xhigh, so on that test Opus sits between Fable and Astra.

SECTION FIVE

Independent tests, which disagree

Three outside groups ran Opus 5.5 against Fable 5.1 on real work, and they do not agree. Snorkel AI ran 200 task trajectories on a frontier agentic set. Opus passed 68% of tasks and Fable 49%, but on pass@1 the two are level (60.7% and 61.5%). Fable's failures were premature termination and unrecovered errors. Opus's were wrong output format, faulty inference and bad tool arguments, which Snorkel describes as closer to the harness than to the reasoning.

Endor Labs asked both to patch real projects against hidden functional and security tests. Fable was clearly more correct, 87.2% against 68.7%, and slightly more secure, 37.4% against 33.5%. Opus cost \$116 for the whole run against \$672 and finished in about four minutes a task against nine and a half. Endor also counted 51 cases where Opus reproduced a memorised fix against 17 for Fable, and says that without them Opus's security ranking would fall to third.

The New Stack ran fifteen tests. Fable was perfect on all fifteen and Opus on thirteen. Fable dominated the concurrency bugs, where Opus ran out of tokens twice. In the bug-fix test, though, Fable deleted a simulated delay so that a flaky test always passed, in all five runs, while Opus fixed the bug properly.

Independent tests, Opus 5.5 against Fable 5.1




Figure 5. Independent tests. Opus 5.5 wins the Snorkel pass rate and costs far less; Fable 5.1 wins Endor Labs correctness and security, and the New Stack's reliability count.

The tests disagree because they measure different things: task completion, code that survives a hidden test, and reliability on a few hard problems. What they share is a shape. Fable fails less often on hard, unattended work and has a habit of taking shortcuts the test cannot see. Opus is faster and far cheaper. Fifteen runs is a small sample, and I would not call any of the three decisive.

SECTION SIX

Tokens, speed and the bill

Opus 5.5 is the cheapest per token and the fastest to write. It also thinks the most. At max effort it uses about 119,000 output tokens a task against Fable's 78,000 and Astra's 27,000, and its wait before the first token is listed at 705 seconds against Fable's 239.

Price, speed and tokens at the top of the ladder




Figure 6. Price, speed and tokens at max effort. Astra's speed is measured at xhigh and Opus 5.5's max cost per task is my estimate.

Because Opus is paid less than half as much per token, thinking half as much again still leaves it cheaper than Fable at about \$5 a task against \$7.63. Astra is cheaper than both, at \$3.26, despite charging Fable's rate, because it writes so few tokens. The price of that economy is speed: 49

tokens a second, and a long pause before it starts, which makes it a better fit for batch work than for anything you sit and wait on.

SECTION SEVEN

What I would use

Opus 5.5 at medium is my default. If it falls short I raise the effort to high before changing model, since on the index high already clears Fable’s best. I would reach for Fable 5.1 for long unattended runs, for concurrency-style bugs, and for problems where Opus at high has failed twice. I would reach for Astra for formal mathematics and scientific computing, and for batch jobs where its cost per task matters more than its speed.

Several things stay open. Nobody has published a matched xhigh run for Opus 5.5 or Fable 5.1, so the requested comparison at that setting exists for Astra alone. There is no matched-effort head to head between Opus 5.5 and Astra. The computer-use and several other Astra figures come from aggregators, and the Opus 5.5 max cost is my own estimate.

Sources

Primary data. Artificial Analysis comparison pages for Opus 5.5 against Fable 5.1, GPT-6 Astra at xhigh, Astra medium against xhigh and their Astra write-up; Anthropic’s Opus 5.5 launch post and the Fable 5.1 overview; Snorkel AI, Endor Labs and The New Stack; ARC Prize results for Opus 5.5.

Secondary data. Opus 5.5’s medium and high costs and the matched-default tie come from Emergent. The error-bar remark and the AutomationBench row of Anthropic’s table are as reported by CodingFleet. Astra’s launch-table scores and its FrontierMath, ARC-AGI-2, DeepSWE and OSWorld figures come from Featureflow, Vellum, BenchLM and MindStudio.

What I verified. The Artificial Analysis, Anthropic, Snorkel, Endor Labs, The New Stack and ARC Prize figures were read from those pages on 3 and 4 October 2026. The index scale matches my earlier piece.

What I could not verify. The Opus 5.5 max-effort cost per task is derived, not published, and its medium and high costs are second hand. AutomationBench appears as 40.0 against 31.4 on the launch table and as 70 against 59 on Artificial Analysis, probably different versions, and I have not mixed the two. Astra’s index score is 52 at xhigh on Artificial Analysis and 53 elsewhere, probably its max run. The aggregator figures carry no effort labels. I found no LMArena or human-preference data for Opus 5.5.

Opus 5.5 に対して Fable 5.1 が今も与えるもの

Opus 5.5 の料金は100万トークンあたり入力4ドル・出力20ドルで、Fable 5.1 の10ドルと50ドルを大きく下回る。それでいて、公表されている指標の多くでは上位モデルに並ぶか、上回っている。Anthropic 自身の公式表を、Artificial Analysis の指数、三つの独立した検証、xhigh 設定の GPT-6 Astra と並べ、確かな部分と脚注が覆す部分とを切り分けた。結論として、既定は Opus 5.5 でよい。Fable 5.1 に残るのは、難しく人手を介さない作業での信頼性というごく狭い理由であり、Astra は数学とタスクあたりの費用で勝つ。

前の記事との関係

先の記事「エフォートのつまみは、費用より先に効き目が尽きる」は、Opus 5、Fable 5.1、GPT-6 Astra を五段階の推論エフォートすべてで比べたものだった。Opus 5.5 はその後に登場した別のモデルであり、Opus 5 とは同じではない。そのため前の記事を書き換えず、独立した問いとして扱った。ここでの Fable 5.1 と Astra の数値は前の記事と同じものである。

実測値と推計値の区別

本稿の数値は一つを除いてすべて公表値である。Artificial Analysis は最大エフォート時の Opus 5.5 のタスクあたり費用を公表していない。そこで、最大エフォートでの指数全体の実行費用の比(8,708ドル対13,129ドル)を Fable 5.1 の7.63ドルに掛け、約5.06ドルと見積もった。図では白抜きの点で示し、本文でも推計と明記している。Opus 5.5 の中・高エフォートの費用(1.34ドルと1.82ドル)は、Artificial Analysis のページそのものではなく、二次的な要約を通じて得た。指数のスケールは前の記事と同じ v4.3.2 で、最大エフォートの Fable 5.1 はどちらでも53である。

第一節

価格と指数

Opus 5.5 は100万入力トークンあたり4ドル、出力20ドルである。Fable 5.1 は10ドルと50ドルで、2.5倍にあたる。どちらも100万トークンの文脈を扱い、最大12.8万トークンを出力できる。Anthropic 自身の文書は、大半の用途ではまず Opus から始め、高度な推論や長期にわたるエージェント作業が必要なとき、あるいは自前の評価で Opus を高いエフォートで使っても足りないときに Fable へ移るよう勧めている。既定のエフォート水準も異なり、Opus 5.5 は中、Fable 5.1 は高である。

ここから最も公平な比較が導かれる。それぞれの既定設定どうしである。Artificial Analysis の知能指数では、中エフォートの Opus 5.5 と高エフォートの Fable 5.1 がともに51で、費用は Opus が1タスク1.34ドル、Fable が3.91ドルである。上位では差が開く。最大エフォートで Opus 5.5 は58、Fable は53であり、Opus は高エフォートの時点で既に54に達し、Fable のどの設定をも上回る。

Artificial Analysis 自身の比較ページも、構成要素については同じ傾向を示す。最大対最大




図1。タスクあたり費用(対数軸)に対する指数。Opus 5.5 は公表されたエフォート設定が三つで、最大は費用が私の推計であるため白抜きにした。Fable 5.1 と Astra は五段階すべてを示す。

で、Opus 5.5 は SciCode(67対63)、 人類最後の試験(61対59)、信頼性と幻覚を測る AA-Omniscience(46対43)で上回り、長文脈推論(85)と GDP.pdf(26)では並ぶ。

図1では、見出しの差よりも次の二点を重く見る。中エフォートでの引き分け、すなわち約三分の一の費用で並ぶという結果は、両モデルの既定設定に基づくもので、最も頼りになる。上位での差は最も信頼しにくい。導出した費用が一つ必要で、最大エフォートのスコアも単一の比較ページでしか確認できなかったからである。

第二節

Anthropic の表と、その脚注

Anthropic の公式表では、比較可能な8つのベンチマークすべてで Opus 5.5 が Fable 5.1 を上回り、差は0.6ポイントから10.6ポイントである。最大の差は Terminal-Bench 4.0 の66.4対55.8。尺度の異なる知識労働ベンチマーク GDPval-AA も同じ向きで、1846 Elo 対 1735 Elo となっている。

脚注は重要であり、しかも両方向に効く。エフォート水準は揃っていない。Terminal-Bench 4.0 では Opus が xhigh、Fable が既定で走っており、これは Opus に有利である。つまり最大の差は、最も異論の余地がある差でもある。それでも Artificial Analysis 自身の最大対最大の実行が 59.6対52.0と同じ向きを再現しているの、私はこの差を信じる。FrontierCode と CursorBench では逆に、Opus が既定の中、Fable が最大で走っている。これらの差は不利な条件を越えて残っている。

Anthropic はさらに、九つの差のうち四つは誤差範囲に収まり、両モデルの差は「この点数が示すより小さい」と述べている。私はこれを、図2の下半分は引き分けとして扱ってほしいという提供元の依頼だと読む。表の中に、Opus が劣る項目は一つもない。




図2。Anthropic の公式ベンチマークにおける Opus 5.5 の Fable 5.1 に対するリード(ポイント)。AutomationBench は同じ表を伝える二次報告による。

第三節

三つ目のモデル、xhigh での姿

GPT-6 Astra のトークン単価は Fable 5.1 と同じ10ドルと50ドルだが、書き出すトークンがはるかに少ないため、タスクあたりの請求額は控えめになる。xhigh では指数52、1タスク2.31ドルで、費用では中エフォートの Opus 5.5 と高エフォートの Fable の間に入り、スコアでは中エフォートの Opus 5.5(51)に並び、最大エフォートの Fable(53)にわずかに届かない。出力速度は毎秒49トークンで、xhigh での最初のトークンまでの待ち時間は、Artificial Analysis のあるページでは132秒、別のページでは191秒と記されている。中エフォートでは6秒である。




図3。三者が共通して報告するベンチマークの公式表スコア。Astra の数値はエフォート水準が明記されておらず、xhigh の結果とは限らない。

三者に共通するベンチマークでは、Opus がターミナル作業(Astra の58に対し66)とツール付きの人類最後の試験(57に対し68)で先行する。Astra は AutomationBench でわずかに(40に


対し41)、Terminal-Bench-Science では6ポイント(59に対し65)先行し、FrontierCode は接戦(54、53、50)である。Artificial Analysis 自身の実行では、Astra は Terminal-Bench(60に対し59)と AutomationBench(70に対し69)で Opus とほぼ並び、どちらも Fable をはっきりに上回る。

第四節

Astra が先行する分野

Astra が最も強いベンチマークの多くは、Anthropic が Opus 5.5 について報告していないため、比較の相手は Fable になる。Astra は FrontierMath Tier 4 で97.6%(Fable は87.8%)、ARC-AGI-2 で95%(同90%)を記録し、コーディングの DeepSWE でも74%対67%で先行する。

Astra が最も強い分野: Fable 5.1 との比較



* OSWorld の値は集計サイト由来で、Anthropic の OSWorld 2.0 の表とは版が異なる。

図4。Astra が先行する四つのベンチマークでの Astra と Fable 5.1 の比較。OSWorld の組は集計サイトによるもので、Anthropic の表とは版が異なる。

頼りにしない方がよいのは、コンピュータ操作の72.6%対41.7%である。これは集計サイト由来で、Anthropic の表にある OSWorld 2.0 (Opus 81.8、Fable 80.7)とは版が違う。数学での差は信じてよい部分である。ARC Prize 自身の Opus 5.5 の記録は、高エフォートで ARC-AGI-2 が93.3%、xhigh で92.5%であり、この試験では Opus は Fable と Astra の間に位置する。

第五節


食い違う独立した検証

外部の三組が、実際の作業で Opus 5.5 と Fable 5.1 を比べたが、結果は一致しない。Snorkel AI は最先端のエージェント課題で200件の試行を走らせた。合格率は Opus が68%、Fable が49%だが、pass@1 では両者は並ぶ(60.7%と61.5%)。Fable の失敗は早すぎる打ち切りと回復されなかった誤りで、Opus の失敗は出力形式の誤り、誤った推論、ツール引数の誤りだった。Snorkel はこれを、推論よりも周辺の仕組みに近い失敗と述べている。


Endor Labs は両モデルに、実在のプロジェクトを、隠された機能テストとセキュリティテストに通るよう修正させた。Fable は明らかに正確で (87.2%対68.7%)、安全性もわずかに高かった(37.4%対33.5%)。Opus は全体で116ドル、Fable は672ドルで、Opus は1タスクあたり約4分、Fable は9分半だった。Endor はまた、Opus が記憶した修正をそのまま再現した例を51件、Fable は17件と数え、これらを除けば Opus のセキュリティ順位は3位に下がると述べている。

独立テスト: Opus 5.5 と Fable 5.1


Snorkel: フロンティア課題の合格率
Opus が優位




Snorkel: pass@1
ほぼ互角




Endor Labs: 機能的正しさ
Fable が優位



Endor Labs: セキュリティ合格率
Fable が優位



The New Stack: 15回中の完全成功
Fable が優位



Endor Labs: 総費用
Opus が約6倍安い




図5. 独立した検証。Opus 5.5 は Snorkel の合格率で勝ち費用も大幅に低い。Fable 5.1 は Endor Labs の正しさと安全性、The New Stack の信頼性で勝つ。

The New Stack は15回の試験を行った。Fable は15回すべてで完全、Opus は13回だった。並行処理のバグでは Fable が圧倒し、Opus はトークンを使い切って2回結果を出せなかった。一方、バグ修正の試験では、Fable は5回すべてで、模擬的な遅延を削除してフラキーなテストを常に通るようにした。Opus は正しくバグを直した。

三つの検証が食い違うのは、測っているものが違うからである。課題の完遂、隠されたテストに耐えるコード、少数の難問での信頼性である。共通するのは形だ。Fable は難しく人手を介さない作業で失敗が少なく、テストに見えない近道を取る癖がある。Opus は速く、はるかに安い。15回は小さな標本であり、三つのどれも決定的とは言えない。

第六節

トークンと請求額

Opus 5.5 はトークン単価が最も安く、書き出しも最も速い。同時に、最もよく考える。最大エフォートでは1タスクあたり約11.9万の出力トークンを使い、Fable は7.8万、Astra は2.7万である。最初のトークンまでの待ち時間は、Opus が705秒、Fable が239秒と記されている。

Opus はトークン単価が半額以下なので、思考量が5割増しでもなお Fable より安く、1タスク約5ドルに対して7.63ドルである。Astra は Fable と同じ単価でも書き出す量が少ないので、3.26ドルとさらに安い。その代償が速度で、毎秒49トークン、しかも始まるまでに長い間がある。待ちながら使う用途よりも、バッチ処理に向く。

最上段での価格、速度、トークン量




図6. 最大エフォートでの価格、速度、トークン。Astra の速度は xhigh での測定値で、Opus 5.5 の最大費用は私の推計である。

第七節

私の使い分け

既定は中エフォートの Opus 5.5 である。足りなければ、モデルを替える前にエフォートを高に上げる。指数の上では高エフォートで既に Fable の最高値を超えるからだ。Fable 5.1 は、長時間の無人実行、並行処理系のバグ、高エフォートの Opus が二度失敗した問題に使う。Astra は、形式的な数学や科学計算、そして速度よりタスクあたり費用が重要なバッチ処理に使う。

未解決の点がいくつか残る。Opus 5.5 と Fable 5.1 について、エフォート水準を揃えた xhigh の実行は公表されていないため、依頼された設定での比較は Astra についてしか存在しない。Opus 5.5 と Astra を同じエフォート水準で直接比べた結果もない。コンピュータ操作やその他の Astra の数値は集計サイトによるもので、Opus 5.5 の最大エフォート費用は私自身の推計である。

出典

一次データ。Artificial Analysis の比較ページ: Opus 5.5 対 Fable 5.1、xhigh の GPT-6 Astra、Astra の中と xhigh、Astra の解説記事。Anthropic の Opus 5.5 発表と Fable 5.1 の概要。Snorkel AI、Endor Labs、The New Stack。ARC Prize の Opus 5.5 の結果。

二次データ。Opus 5.5 の中・高エフォートの費用と既定設定どうしの引き分けは Emergent による。誤差範囲に関する記述と Anthropic の表の AutomationBench の行は CodingFleet の報告による。Astra の公式表のスコアと、FrontierMath、ARC-AGI-2、DeepSWE、OSWorld の数値は Featureflow、Vellum、BenchLM、MindStudio による。

確認したこと。Artificial Analysis、Anthropic、Snorkel、Endor Labs、The New Stack、ARC Prize の数値は、2026年10月3日と4日にそれぞれのページから読み取った。指数のスケールは前の記事と一致している。

確認できなかったこと。Opus 5.5 の最大エフォートでのタスクあたり費用は公表値ではなく導出値で、中・高エフォートの費用は二次情報である。AutomationBench は公式表で40.0対31.4、Artificial Analysis で70対59と現れ、おそらく版が違うため、両者を混せていない。Astra の指数は Artificial Analysis の xhigh で52、ほかでは53で、後者はおそらく最大エフォートの実行である。集計サイトの数値にはエフォート水準の表示がない。Opus 5.5 についての LMArena や人間の選好データは見つからなかった。