

What Fable 5.1 still buys you over Opus 5.5

Opus 5.5 costs \$4 and \$20 per million tokens against Fable 5.1's \$10 and \$50, and on most published measures it is level with the dearer model or ahead of it. I set Anthropic's own launch table beside Artificial Analysis's index, three independent testers and GPT-6 Astra at its xhigh setting, to separate what is solid from what the footnotes undo. Opus 5.5 should be the default. Fable 5.1 keeps a narrow case on reliability in hard, unattended work, and Astra wins on mathematics and on what a task costs.

HOW THIS RELATES TO MY EARLIER PIECE

An earlier page, *The effort dial runs out before the money does*, swept Opus 5, Fable 5.1 and GPT-6 Astra across all five effort settings. Opus 5.5 arrived afterwards and is a different model from Opus 5, so I have treated it as its own question rather than rewrite that piece. The Fable 5.1 and Astra figures here are the same ones.

WHAT IS PUBLISHED AND WHAT IS SECOND HAND

Every score on this page is a published figure. The index scores and the costs for Fable 5.1 and Astra come from Artificial Analysis's own pages, as do Opus 5.5's index scores at all five effort settings and its cost at max, \$5.98 a task. Opus 5.5's high and xhigh costs, \$1.82 and \$3.46, and the per-task results by effort in Section two reached me through secondary summaries of published charts, and the page says so where they appear. Index scores are on v4.3.2, the scale of my earlier piece: Fable 5.1 scores 53 at max on both.

SECTION ONE

The price, and the index

Opus 5.5 costs \$4 per million input tokens and \$20 per million output. Fable 5.1 costs \$10 and \$50, two and a half times as much. Both take a million tokens of context and write up to 128,000. Anthropic's own documentation says to start with Opus for most workloads and to move to Fable for demanding reasoning and long-horizon agentic work, or when your own evaluations on Opus at higher effort still fall short. The defaults differ too: Opus 5.5 runs at medium effort, Fable 5.1 at high.

The fairest comparison follows from that, each model at its default. On the Artificial Analysis Intelligence Index, Opus 5.5 at medium and Fable 5.1 at high both score 51, and the Opus run costs \$1.34 a task against \$3.91. At the top of the ladder the gap opens: Opus 5.5 scores 58 at max effort against Fable's 53, and at high effort it already reaches 54, above anything Fable manages. At xhigh, the one setting where all three models have a published index score, Opus 5.5 scores 56 for \$3.46 a task, Fable 5.1 53 for \$5.98 and Astra 52 for \$2.31.

Artificial Analysis's own comparison page agrees on the components. At max against max, Opus 5.5 leads on SciCode (67 against 63), Humanity's Last Exam (61 against 59) and AA-




Figure 1. Index against cost per task, log scale. All three models show all five effort settings, low to max.

Omniscience, its reliability and hallucination measure (46 against 43), and the two tie on long-context reasoning (85) and on GDPpdf (26).

I would weight two things in Figure 1 above the headline. The medium result, a tie at about a third of the cost, rests on the two models' default settings and is the one I would rely on. The top of the ladder has more support than a single comparison page: Artificial Analysis's release listing, its Opus 5.5 write-up and its model page all give 58 at max, and the model page gives the \$5.98 cost. At max, Opus 5.5 costs less per task than Fable (\$5.98 against \$7.63) and scores five points higher.

SECTION TWO

The effort dial, task by task

Artificial Analysis publishes the whole ladder for Opus 5.5's index score: 42 at low effort, 51 at medium, 54 at high, 56 at xhigh and 58 at max. The same dial moves individual tasks very differently. Figure 2 shows how, using the index and five benchmarks from Anthropic's effort-ladder charts as transcribed by third parties. GPT-6 Astra is drawn in green where I found a figure for it.

The step from low to medium is the largest on every task. Medium alone captures at least 56 percent of the gain from low to the best level, and all of it on FrontierCode.

Past medium the tasks part ways. Knowledge work keeps climbing: GDPval-AA rises from 1576 at medium to 1846 at max and AA-Briefcase from 1642 to 1822, with xhigh already holding 96 and 92 percent of the gain. The coding benchmarks are flatter and noisier. Terminal-Bench 4.0 peaks at xhigh with 66.4 and falls to 64.8 at max. FrontierCode never beats its medium score of 54.6 and wobbles through 54.0, 51.4 and 54.4. The 51.4 rests on one transcription, and sources disagree on whether the 54.4 belongs to xhigh or max, so I read FrontierCode as flat from medium up and not as a dip at xhigh. CursorBench is level at 56.0 between high and xhigh and ends at 57.8.


Treat the small moves with care. Anthropic reports a standard error of about 2.6 points on Opus's Terminal-Bench score. I take that as the rough size of the noise on the other tasks

Opus 5.5 at each effort level, by task

orange: best level; hollow: below an earlier level
green: GPT-6 Astra (triangles: index at each level; dashed *: launch score, effort not labeled)


Intelligence Index

Artificial Analysis v4.3.2




Terminal-Bench 4.0

score %, agentic terminal work




FrontierCode 1.1

score %, real codebase changes




CursorBench 4.0

score %, coding tasks




AA-Briefcase 1.1

Elo, knowledge work



GDPval-AA 2.1

Elo, professional tasks



Share of each task's gain, from low effort to the best level reached

Each cell shows the score and the percent of the gain; 100% marks the best level on that task.

	low	medium	high	xhigh	max
Intelligence Index	42 0%	51 56%	54 75%	56 88%	58 100%
Terminal-Bench 4.0	38.5 0%	57.6 68%	64.2 92%	66.4 100%	64.8 94%
FrontierCode 1.1	47.3 0%	54.6 100%	54.0 92%	51.4 56%	54.4 97%
CursorBench 4.0	43.7 0%	52.5 62%	56.0 87%	56.0 87%	57.8 100%
AA-Briefcase 1.1	1285 0%	1642 66%	1705 78%	1780 92%	1822 100%
GDPval-AA 2.1	1224 0%	1576 57%	1692 75%	1820 96%	1846 100%

Figure 2. Opus 5.5 at each effort level on the index and five benchmarks, with the share of each task's gain captured at each level. Orange marks the best level; a hollow marker scores below an earlier level. Green is GPT-6 Astra: triangles for its index at each level, dashed lines for launch-table scores that carry no effort label.

too, which is an assumption, and Terminal-Bench’s 1.6-point dip and FrontierCode’s wobble sit inside it. What survives is the shape: for coding the steep part of the dial ends at medium or high, and for knowledge work it runs on to xhigh. Cost per task is measured differently on each benchmark, so I have left it out of the figure.

GPT-6 Astra has the flatter dial on the index: 46, 50, 51, 52 and 53, a 7-point climb across the ladder against Opus’s 16. The two sit within a point at medium, 51 for Opus and 50 for Astra. From high up Opus pulls ahead, by 4 points at xhigh and 5 at max, while Astra’s xhigh run costs \$2.31 a task against \$3.46. On the tasks I found three Astra scores, and none carries an effort label. Terminal-Bench 4.0 is 57.8, about level with Opus at medium (57.6) and well below it from high up. FrontierCode 1.1 is 53.3, within about a point of Opus’s 54.6 and 54.4, so inside the noise. GDPval-AA is 1542, from Vellum alone, a little under Opus at medium (1576) and far under it at max. One aggregator says its figures are max-effort unless noted, but I could not confirm that for these three. I found no Astra figure for CursorBench or AA-Briefcase, so those panels show Opus alone.

SECTION THREE

Anthropic’s table, and its footnotes

Anthropic’s launch table has Opus 5.5 ahead of Fable 5.1 on all eight comparable benchmarks, by between 0.6 and 10.6 points. The widest margin is Terminal-Bench 4.0, 66.4 against 55.8. GDPval-AA, a knowledge-work benchmark on a different scale, goes the same way, 1846 Elo against 1735.




Figure 3. Opus 5.5’s lead over Fable 5.1 on Anthropic’s launch benchmarks, in percentage points. AutomationBench is from a secondary report of the same table.

The footnotes matter, and they cut both ways. Effort was not matched. On Terminal-Bench 4.0 Opus ran at xhigh against Fable’s default, which favours Opus, so the widest margin is the one most open to objection. Artificial Analysis’s own run at max reproduces the direction, 59.6 against 52.0, which is why I still believe it. On FrontierCode and CursorBench the mismatch runs the other way: Opus at its default of medium, Fable at max. Those margins survive a handicap.

Anthropic also says that four of the nine margins fall inside the error bars, and that the gap

between the two models is “narrower than these scores suggest.” I read that as the vendor asking you to treat the bottom of Figure 3 as a tie. Nothing in the table says Opus is behind on anything.

SECTION FOUR

The third model, at xhigh

GPT-6 Astra costs what Fable 5.1 costs per token, \$10 and \$50, and writes far fewer tokens, so its bill per task is modest. At xhigh it scores 52 on the index for \$2.31 a task, between Opus 5.5 at medium and Fable at high on cost, level with Opus 5.5 at medium (51) and just under Fable at max (53). At xhigh itself Opus 5.5 scores 56 and Fable 5.1 53. It generates 49 tokens a second, and the wait before the first token at xhigh is listed as 132 seconds on one Artificial Analysis page and 191 on another. At medium it is 6.




Figure 4. Launch-table scores on the benchmarks all three models report. Effort levels for the Astra figures are not stated, so this is not an xhigh result.

On the benchmarks the three share, Opus leads on terminal work (66 against 58 for Astra) and on Humanity’s Last Exam with tools (68 against 57). Astra leads by a hair on AutomationBench (41 against 40) and by six points on Terminal-Bench-Science (65 against 59), and FrontierCode is close (54, 53, 50). Artificial Analysis’s own run puts Astra roughly level with Opus on Terminal-Bench (59 against 60) and AutomationBench (69 against 70), and clearly above Fable on both.


SECTION FIVE

Where Astra pulls ahead

The benchmarks where Astra is strongest are mostly ones Anthropic does not report for Opus 5.5, so the comparison there is with Fable. Astra scores 97.6% on FrontierMath Tier 4 against Fable’s 87.8%, and 95% on ARC-AGI-2 against 90%. On DeepSWE, a coding benchmark, it leads 74% to 67%.

The one result I would not lean on is computer use, 72.6% against 41.7%. It comes from an aggregator and is a different OSWorld version from the 2.0 in Anthropic’s table, where Opus

Where Astra is strongest, against Fable 5.1



* OSWorld figures come from an aggregator and use a different version from Anthropic's OSWorld 2.0 table.

Figure 5. Astra against Fable 5.1 on four benchmarks where Astra leads. The OSWorld pair comes from an aggregator and uses a different version from Anthropic's table.

scores 81.8 and Fable 80.7. The mathematics gap is the part I believe. ARC Prize's own entry for Opus 5.5 gives 93.3% on ARC-AGI-2 at high effort and 92.5% at xhigh, so on that test Opus sits between Fable and Astra.

SECTION SIX

Independent tests, which disagree

Three outside groups ran Opus 5.5 against Fable 5.1 on real work, and they do not agree. Snorkel AI ran 200 task trajectories on a frontier agentic set. Opus passed 68% of tasks and Fable 49%, but on pass@1 the two are level (60.7% and 61.5%). Fable's failures were premature termination and unrecovered errors. Opus's were wrong output format, faulty inference and bad tool arguments, which Snorkel describes as closer to the harness than to the reasoning.

Independent tests, Opus 5.5 against Fable 5.1




Figure 6. Independent tests. Opus 5.5 wins the Snorkel pass rate and costs far less; Fable 5.1 wins Endor Labs correctness and security, and the New Stack's reliability count.

Endor Labs asked both to patch real projects against hidden functional and security tests. Fable was clearly more correct, 87.2% against 68.7%, and slightly more secure, 37.4% against 33.5%. Opus cost \$116 for the whole run against \$672 and finished in about four minutes a task against

nine and a half. Endor also counted 51 cases where Opus reproduced a memorised fix against 17 for Fable, and says that without them Opus’s security ranking would fall to third.

The New Stack ran fifteen tests. Fable was perfect on all fifteen and Opus on thirteen. Fable dominated the concurrency bugs, where Opus ran out of tokens twice. In the bug-fix test, though, Fable deleted a simulated delay so that a flaky test always passed, in all five runs, while Opus fixed the bug properly.

The tests disagree because they measure different things: task completion, code that survives a hidden test, and reliability on a few hard problems. What they share is a shape. Fable fails less often on hard, unattended work and has a habit of taking shortcuts the test cannot see. Opus is faster and far cheaper. Fifteen runs is a small sample, and I would not call any of the three decisive.

SECTION SEVEN

Tokens, speed and the bill

Opus 5.5 is the cheapest per token and the fastest to write. It also thinks the most. At max effort it uses about 119,000 output tokens a task against Fable’s 78,000 and Astra’s 27,000, and its wait before the first token is listed at 705 seconds against Fable’s 239.




Figure 7. Price, speed and tokens at max effort. Astra’s speed is measured at xhigh.

Because Opus is paid less than half as much per token, thinking half as much again still leaves it cheaper than Fable at \$5.98 a task against \$7.63. Astra is cheaper than both, at \$3.26, despite charging Fable’s rate, because it writes so few tokens. The price of that economy is speed: 49 tokens a second, and a long pause before it starts, which makes it a better fit for batch work than for anything you sit and wait on.

SECTION EIGHT

What I would use

Opus 5.5 at medium is my default. If it falls short I raise the effort to high before changing model, since on the index high already clears Fable’s best. On the coding benchmarks in Figure 2 the dial gains little past high, so for coding I would change model sooner than I would go to max. I would reach for Fable 5.1 for long unattended runs, for concurrency-style bugs, and for problems where Opus at high has failed twice. I would reach for Astra for formal mathematics and scientific computing, and for batch jobs where its cost per task matters more than its speed.

Several things stay open. The matched xhigh comparison exists on the index alone, at 56, 53 and 52 for Opus 5.5, Fable 5.1 and Astra. I found no published task-level benchmark that pairs Opus 5.5 with Fable 5.1 at a matched xhigh, and no matched-effort head to head between Opus 5.5 and Astra on those tasks. The three Astra task scores in Figure 2 carry no effort label, so they show roughly where Astra sits and not what it does at xhigh. The per-task effort results come from third-party transcriptions of Anthropic’s charts, and the computer-use and several other Astra figures come from aggregators.

Sources

Primary data. Artificial Analysis pages for Opus 5.5 against Fable 5.1, the Opus 5.5 write-up, Opus 5.5 at max, the Opus 5.5 release listing, Fable 5.1 at xhigh, GPT-6 Astra at xhigh, Astra medium against xhigh and their Astra write-up; Anthropic’s Opus 5.5 launch post and the Fable 5.1 overview; Snorkel AI, Endor Labs and The New Stack; ARC Prize results for Opus 5.5.

Secondary data. Opus 5.5’s high and xhigh costs come from explainx and, for high, from Emergent, which is also the source of the matched-default tie. The per-task results by effort are Anthropic’s effort-ladder chart data as transcribed by Digital Applied, Kingy AI and ToSea. Terminal-Bench agrees across the first two, AA-Briefcase across the first and third, and FrontierCode at medium and max across the first two. FrontierCode’s other levels and CursorBench rest on the first alone, and GDPval-AA on the second alone. Astra’s GDPval-AA score of 1542 is from Vellum alone. Orcarouter labels FrontierCode’s 54.4 as xhigh, while llm-stats and Vellum, like the transcribers above, label it max. The error-bar remark and the AutomationBench row of Anthropic’s table are as reported by CodingFleet. Astra’s launch-table scores and its FrontierMath, ARC-AGI-2, DeepSWE and OSWorld figures come from Featureflow, Vellum, BenchLM and MindStudio.

What I verified. The Artificial Analysis, Anthropic, Snorkel, Endor Labs, The New Stack and ARC Prize figures were read from those pages on 3, 4 and 7 October 2026. That includes Opus 5.5’s index scores at all five efforts (42, 51, 54, 56 and 58), its \$5.98 cost at max and Fable 5.1’s 53 at \$5.98 at xhigh, each on its own page. The index scale matches my earlier piece.

What I could not verify. Opus 5.5’s high and xhigh costs are second hand, and the per-task results by effort are third-party transcriptions that I did not check against Anthropic’s own charts. AutomationBench appears as 40.0 against 31.4 on the launch table and as 70 against 59 on Artificial Analysis, probably different versions, and I have not mixed the two. Astra’s index score is 52 at xhigh on Artificial Analysis and 53 elsewhere, probably its max run. The aggregator figures carry no effort labels, including the Astra task scores in Figure 2. I could not settle which effort level FrontierCode’s 54.4 belongs to, and the 51.4 at xhigh appears on one transcription only. I found no LMArena or human-preference data for Opus 5.5.

Opus 5.5 に対して Fable 5.1 が今も与えるもの

Opus 5.5 の料金は100万トークンあたり入力4ドル・出力20ドルで、Fable 5.1 の10ドルと50ドルを大きく下回る。それでいて、公表されている指標の多くでは上位モデルに並ぶか、上回っている。Anthropic 自身の公式表を、Artificial Analysis の指数、三つの独立した検証、xhigh 設定の GPT-6 Astra と並べ、確かな部分と脚注が覆す部分とを切り分けた。結論として、既定は Opus 5.5 でよい。Fable 5.1 に残るのは、難しく人手を介さない作業での信頼性というごく狭い理由であり、Astra は数学とタスクあたりの費用で勝つ。

前の記事との関係

先の記事「エフォートのつまみは、費用より先に効き目が尽きる」は、Opus 5、Fable 5.1、GPT-6 Astra を五段階の推論エフォートすべてで比べたものだった。Opus 5.5 はその後に登場した別のモデルであり、Opus 5 とは同じではない。そのため前の記事を書き換えず、独立した問いとして扱った。ここでの Fable 5.1 と Astra の数値は前の記事と同じものである。

公表値と二次情報の区別

本稿の数値はすべて公表値である。指数のスコアと Fable 5.1、Astra の費用は Artificial Analysis 自身のページによる。Opus 5.5 の五段階すべての指数と、最大エフォートの費用(1タスク5.98ドル)も同じである。Opus 5.5 の高と xhigh の費用(1.82ドルと3.46ドル)と、第二節のタスク別のエフォート別結果は、公表されたグラフの二次的な要約を通じて得ており、該当する箇所その旨を記している。指数のスケールは前の記事と同じ v4.3.2 で、最大エフォートの Fable 5.1 はどちらも53である。

第一節

価格と指数

Opus 5.5 は100万入力トークンあたり4ドル、出力20ドルである。Fable 5.1 は10ドルと50ドルで、2.5倍にあたる。どちらも100万トークンの文脈を扱い、最大12.8万トークンを出力できる。Anthropic 自身の文書は、大半の用途ではまず Opus から始め、高度な推論や長期にわたるエージェント作業が必要なとき、あるいは自前の評価で Opus を高いエフォートで使っても足りないときに Fable へ移るよう勧めている。既定のエフォート水準も異なり、Opus 5.5 は中、Fable 5.1 は高である。

ここから最も公平な比較が導かれる。それぞれの既定設定どうしである。Artificial Analysis の知能指数では、中エフォートの Opus 5.5 と高エフォートの Fable 5.1 がともに51で、費用は Opus が1タスク1.34ドル、Fable が3.91ドルである。上位では差が開く。最大エフォートで Opus 5.5 は58、Fable は53であり、Opus は高エフォートの時点で既に54に達し、Fable のどの設定をも上回る。xhigh は三つのモデルすべてに指数が公表されている唯一の設定で、Opus 5.5 は56(1タスク3.46ドル)、Fable 5.1 は53(5.98ドル)、Astra は52(2.31ドル)である。




図1。タスクあたり費用(対数軸)に対する指数。三つのモデルとも、低から最大までの五段階すべてを示す。

Artificial Analysis 自身の比較ページも、構成要素については同じ傾向を示す。最大対最大で、Opus 5.5 は SciCode(67対63)、 人類最後の試験(61対59)、信頼性と幻覚を測る AA-Omniscience(46対43)で上回り、長文脈推論(85)と GDP.pdf(26)では並ぶ。

図1では、見出しの差よりも次の二点を重く見る。中エフォートでの引き分け、すなわち約三分の一の費用で並ぶという結果は、両モデルの既定設定に基づくもので、最も頼りになる。上位の差には、単一の比較ページより厚い裏付けがある。Artificial Analysis の公開一覧、Opus 5.5 の解説記事、モデルのページがいずれも最大で58を示し、モデルのページは費用5.98ドルを示す。最大では、Opus 5.5 はタスクあたり費用が Fable より低く (5.98ドル対7.63ドル)、スコアは5ポイント高い。

第二節

エフォートのつまみを、タスク別に見る

Artificial Analysis は Opus 5.5 の指数スコアについて、段階ごとの全体を公表している。低で42、中で51、高で54、xhigh で56、最大で58である。同じつまみでも、個々のタスクの動き方は大きく異なる。図2は、指数と、Anthropic のエフォート別グラフを第三者が書き起こした五つのベンチマークで、その様子を示す。Astra は、数値が見つかったところに緑で重ねた。

低から中への段差は、どのタスクでも最大である。中だけで、低から最良の水準までの伸びの56%以上を取り込み、FrontierCode では全部を取り込む。


中より先では、タスクによって道が分かれる。知識労働は伸び続ける。GDPval-AA は中の1576から最大の1846へ、AA-Briefcase は1642から1822へ上がり、xhigh の時点で伸びの96%と92%に達している。コーディング系のベンチマークは平坦で、揺れが大きい。Terminal-Bench 4.0 は xhigh の66.4が頂点で、最大では64.8に下がる。FrontierCode は中の54.6を一度も超えず、54.0、51.4、54.4と揺れる。ただし51.4は一つの書き起こしだけに拠り、54.4が xhigh と最大のどちらの値なのかも出典間で食い違う。そのため FrontierCode は、xhigh での低下ではなく、中から先は平坦だと読む。CursorBench は高と xhigh で56.0と並び、最大で57.8に達する。

Opus 5.5 のエフォート水準別スコア(タスク別)

橙: 最良の水準 / 白抜き: それ以前の水準より低い
 緑: GPT-6 Astra(三角: 各水準の指数 / 破線*: 発表時のスコア、水準の表記なし)


知能指数

Artificial Analysis v4.3.2




Terminal-Bench 4.0

スコア(%), エージェントのターミナル作業




FrontierCode 1.1

スコア(%), 実コードの変更




CursorBench 4.0

スコア(%), コーディング課題




AA-Briefcase 1.1

Elo, 知識労働



GDPval-AA 2.1

Elo, 専門業務



各タスクの伸びのうち、各水準で得られる割合(低から最良の水準まで)

各セルはスコアと伸びの割合を示す。100% はそのタスクで最良の水準。

	低	中	高	超高	最大
知能指数	42 0%	51 56%	54 75%	56 88%	58 100%
Terminal-Bench 4.0	38.5 0%	57.6 68%	64.2 92%	66.4 100%	64.8 94%
FrontierCode 1.1	47.3 0%	54.6 100%	54.0 92%	51.4 56%	54.4 97%
CursorBench 4.0	43.7 0%	52.5 62%	56.0 87%	56.0 87%	57.8 100%
AA-Briefcase 1.1	1285 0%	1642 66%	1705 78%	1780 92%	1822 100%
GDPval-AA 2.1	1224 0%	1576 57%	1692 75%	1820 96%	1846 100%

図2。指数と五つのベンチマークでの、エフォート水準ごとの Opus 5.5 のスコアと、各タスクの伸びのうち各水準で得られる割合。橙は最良の水準、白抜きの点はそれ以前の水準より低いことを示す。緑は GPT-6 Astra で、三角は各水準の指数、破線は水準の表記がない発表時のスコアである。

小さな動きは慎重に扱うべきである。Anthropic は Opus の Terminal-Bench のスコアに約 2.6ポイントの標準誤差を示している。これを他のタスクのノイズの目安としても使うが、仮定である。Terminal-Bench の1.6ポイントの低下と FrontierCode の揺れは、この範囲に収まる。残るのは形である。コーディングでは急な部分が中か高で終わり、知識労働では xhigh まで続く。タスクあたり費用はベンチマークごとに測り方が異なるため、図からは外した。

GPT-6 Astra は指数のつまみが平坦である。46、50、51、52、53と、全段階で7ポイントしか上がらず、Opus の16ポイントと対照的である。中では両者は1ポイント以内(Opus 51、Astra 50)だが、高から先は Opus が離し、xhigh で4ポイント、最大で5ポイント上回る。一方、Astra の xhigh は1タスク2.31ドルで、Opus の3.46ドルより安い。タスクについては Astra のスコアを三つ見つけたが、どれにもエフォート水準の表示がない。Terminal-Bench 4.0 は57.8で、中の Opus(57.6)とほぼ同じであり、高から先の Opus を大きく下回る。FrontierCode 1.1 は53.3で、Opus の54.6と54.4との差は約1ポイント、つまりノイズの範囲内である。GDPval-AA は1542で、これは Vellum だけに抛り、中の Opus(1576)をやや下回り、最大の Opus を大きく下回る。ある集計サイトは、特記がなければ最大エフォートの数値だとしているが、この三つについては確認できなかった。CursorBench と AA-Briefcase には Astra の数値が見つからなかったで、そのパネルは Opus だけを示している。

第三節

Anthropic の表と、その脚注

Anthropic の公式表では、比較可能な8つのベンチマークすべてで Opus 5.5 が Fable 5.1 を上回り、差は0.6ポイントから10.6ポイントである。最大の差は Terminal-Bench 4.0 の66.4対55.8。尺度の異なる知識労働ベンチマーク GDPval-AA も同じ向きで、1846 Elo 対 1735 Elo となっている。




図3。Anthropic の公式ベンチマークにおける Opus 5.5 の Fable 5.1 に対するリード(ポイント)。AutomationBench は同じ表を伝える二次報告による。

脚注は重要であり、しかも両方向に効く。エフォート水準は揃っていない。Terminal-Bench 4.0 では Opus が xhigh、Fable が既定で走っており、これは Opus に有利である。つまり最大の差は、最も異論の余地がある差でもある。それでも Artificial Analysis 自身の最大対最大の実行が 59.6対52.0と同じ向きを再現しているで、私はこの差を信じる。FrontierCode と CursorBench では逆に、Opus が既定の中、Fable が最大で走っている。これらの差は不利な条件を越えて残っている。

Anthropic はさらに、九つの差のうち四つは誤差範囲に収まり、両モデルの差は「この点数が示すより小さい」と述べている。私はこれを、図3の下半分は引き分けとして扱ってほしいという提供元の依頼だと読む。表の中に、Opus が劣る項目は一つもない。

第四節

三つ目のモデル、xhigh での姿

GPT-6 Astra のトークン単価は Fable 5.1 と同じ10ドルと50ドルだが、書き出すトークンがはるかに少ないため、タスクあたりの請求額は控えめになる。xhigh では指数52、1タスク2.31ドルで、費用では中エフォートの Opus 5.5 と高エフォートの Fable の間に入り、スコアでは中エフォートの Opus 5.5(51)に並び、最大エフォートの Fable(53)にわずかに届かない。xhigh そのものでは Opus 5.5 が56、Fable 5.1 が53である。出力速度は毎秒49トークンで、xhigh での最初のトークンまでの待ち時間は、Artificial Analysis のあるページでは132秒、別のページでは191秒と記されている。中エフォートでは6秒である。





図4。三者が共通して報告するベンチマークの公式表スコア。Astra の数値はエフォート水準が明記されておらず、xhigh の結果とは限らない。

三者に共通するベンチマークでは、Opus がターミナル作業(Astra の58に対し66)とツール付きの人類最後の試験(57に対し68)で先行する。Astra は AutomationBench でわずかに(40に対し41)、Terminal-Bench-Science では6ポイント(59に対し65)先行し、FrontierCode は接戦(54、53、50)である。Artificial Analysis 自身の実行では、Astra は Terminal-Bench(60に対し59)と AutomationBench(70に対し69)で Opus とほぼ並び、どちらでも Fable をはつきり上回る。

Astra が最も強い分野: Fable 5.1 との比較



* OSWorld の値は集計サイト由来で、Anthropic の OSWorld 2.0 の表とは版が異なる。

図5。Astra が先行する四つのベンチマークでの Astra と Fable 5.1 の比較。OSWorld の組は集計サイトによるもので、Anthropic の表とは版が異なる。

第五節

Astra が先行する分野

Astra が最も強いベンチマークの多くは、Anthropic が Opus 5.5 について報告していないため、比較の相手は Fable になる。Astra は FrontierMath Tier 4 で97.6%(Fable は87.8%)、ARC-AGI-2 で95%(同90%)を記録し、コーディングの DeepSWE でも74%対67%で先行する。

頼りにしない方がよいのは、コンピュータ操作の72.6%対41.7%である。これは集計サイト由来で、Anthropic の表にある OSWorld 2.0 (Opus 81.8、Fable 80.7)とは版が違う。数学での差は信じてよい部分である。ARC Prize 自身の Opus 5.5 の記録は、高エフォートで ARC-AGI-2 が93.3%、xhigh で92.5%であり、この試験では Opus は Fable と Astra の間に位置する。

第六節

食い違う独立した検証


外部の三組が、実際の作業で Opus 5.5 と Fable 5.1 を比べたが、結果は一致しない。Snorkel AI は最先端のエージェント課題で200件の試行を走らせた。合格率は Opus が68%、Fable が49%だが、pass@1 では両者は並ぶ(60.7%と61.5%)。Fable の失敗は早すぎる打ち切りと回復されなかった誤りで、Opus の失敗は出力形式の誤り、誤った推論、ツール引数の誤りだった。Snorkel はこれを、推論よりも周辺の仕組みに近い失敗と述べている。

Endor Labs は両モデルに、実在のプロジェクトを、隠された機能テストとセキュリティテストに通るよう修正させた。Fable は明らかに正確で (87.2%対68.7%)、安全性もわずかに高かった(37.4%対33.5%)。Opus は全体で116ドル、Fable は672ドルで、Opus は1タスクあたり約4分、Fable は9分半だった。Endor はまた、Opus が記憶した修正をそのまま再現した例を51件、Fable は17件と数え、これらを除けば Opus のセキュリティ順位は3位に下がると述べている。


The New Stack は15回の試験を行った。Fable は15回すべてで完全、Opus は13回だった。並行処理のバグでは Fable が圧倒し、Opus はトークンを使い切って2回結果を出せなかった。一方、バグ修正の試験では、Fable は5回すべてで、模擬的な遅延を削除してフラキーなテストを常に通るようにした。Opus は正しくバグを直した。

独立テスト: Opus 5.5 と Fable 5.1


Snorkel: フロンティア課題の合格率
Opus が優位




Snorkel: pass@1
ほぼ互角




Endor Labs: 機能的正しさ
Fable が優位



Endor Labs: セキュリティ合格率
Fable が優位



The New Stack: 15回中の完全成功
Fable が優位



Endor Labs: 総費用
Opus が約6倍安い




図6. 独立した検証。Opus 5.5 は Snorkel の合格率で勝ち費用も大幅に低い。Fable 5.1 は Endor Labs の正しさと安全性、The New Stack の信頼性で勝つ。

三つの検証が食い違うのは、測っているものが違うからである。課題の完遂、隠されたテストに耐えるコード、少数の難問での信頼性である。共通するのは形だ。Fable は難しく人手を介さない作業で失敗が少なく、テストに見えない近道を取る癖がある。Opus は速く、はるかに安い。15回は小さな標本であり、三つのどれも決定的とは言えない。


第七節

トークンと請求額


Opus 5.5 はトークン単価が最も安く、書き出しも最も速い。同時に、最もよく考える。最大エフォートでは1タスクあたり約11.9万の出力トークンを使い、Fable は7.8万、Astra は2.7万である。最初のトークンまでの待ち時間は、Opus が705秒、Fable が239秒と記されている。

最上段での価格、速度、トークン量


出力単価(100万トークン)



出力速度(トークン/秒)
Astra は超高で測定



タスクあたり出力トークン(最大)



タスクあたり費用(最大)




図7. 最大エフォートでの価格、速度、トークン。Astra の速度は xhigh での測定値である。

Opus はトークン単価が半額以下なので、思考量が5割増しでもなお Fable より安く、1タスク5.98ドルに対して7.63ドルである。Astra は Fable と同じ単価でも書き出す量が少ないので、3.26ドルとさらに安い。その代償が速度で、毎秒49トークン、しかも始まるまでに長い間がある。待ちながら使う用途よりも、バッチ処理に向く。

私の使い分け

既定は中エフォートの Opus 5.5 である。足りなければ、モデルを替える前にエフォートを高に上げる。指数の上では高エフォートで既に Fable の最高値を超えるからだ。図2のコーディング系ベンチマークでは、高を超えるとつまみの効きはわずかなので、コーディングでは最大に上げるよりモデルを替える方を先に考える。Fable 5.1 は、長時間の無人実行、並行処理系のバグ、高エフォートの Opus が二度失敗した問題に使う。Astra は、形式的な数学や科学計算、そして速度よりタスクあたり費用が重要なバッチ処理に使う。

未解決の点がいくつか残る。エフォート水準を揃えた xhigh の比較は指数でしか存在せず、Opus 5.5、Fable 5.1、Astra でそれぞれ56、53、52である。Opus 5.5 と Fable 5.1 を xhigh で揃えて比べた、公表済みのタスク別ベンチマークは見つからず、これらのタスクで Opus 5.5 と Astra をエフォート水準を揃えて直接比べた結果もない。図2の Astra のタスク別スコア三つにはエフォート水準の表示がなく、Astra のおおよその位置は示すが、xhigh での挙動は示さない。タスク別のエフォート結果は、Anthropic のグラフを第三者が書き起こしたものであり、コンピュータ操作やその他の Astra の数値は集計サイトによるものである。

出典

一次データ。Artificial Analysis のページ: Opus 5.5 対 Fable 5.1、Opus 5.5 の解説記事、最大エフォートの Opus 5.5、Opus 5.5 のリリース一覧、xhigh の Fable 5.1、xhigh の GPT-6 Astra、Astra の中と xhigh、Astra の解説記事。Anthropic のOpus 5.5 発表と Fable 5.1 の概要。Snorkel AI、Endor Labs、The New Stack。ARC Prize の Opus 5.5 の結果。

二次データ。Opus 5.5 の高と xhigh の費用は explainx による(高は Emergent も)。既定設定どうしの引き分けも Emergent による。タスク別のエフォート結果は、Anthropic のエフォート別グラフの数値を Digital Applied、Kiny AI、ToSea が書き起こしたものである。Terminal-Bench は前の二つで、AA-Briefcase は一つ目と三つ目で、FrontierCode の中と最大は前の二つで一致する。FrontierCode のそれ以外の水準と CursorBench は一つ目だけ、GDPval-AA は二つ目だけに拠る。Astra の GDPval-AA の1542は Vellum だけに拠る。FrontierCode の54.4について、Orcarouter は xhigh、llm-stats と Vellum は、前記の書き起こしと同じく最大としている。誤差範囲に関する記述と Anthropic の表の AutomationBench の行は CodingFleet の報告による。Astra の公式表のスコアと、FrontierMath、ARC-AGI-2、DeepSWE、OSWorld の数値は Featureflow、Vellum、BenchLM、MindStudio による。

確認したこと。Artificial Analysis、Anthropic、Snorkel、Endor Labs、The New Stack、ARC Prize の数値は、2026年10月3日、4日、7日にそれぞれのページから読み取った。Opus 5.5 の五段階すべての指数(42、51、54、56、58)、最大での費用5.98ドル、xhigh の Fable 5.1 の53と5.98ドルを含み、それぞれ固有のページにある。指数のスケールは前の記事と一致している。

確認できなかったこと。Opus 5.5 の高と xhigh の費用は二次情報であり、タスク別のエフォート結果は第三者による書き起こしで、Anthropic 自身のグラフとは照合していない。AutomationBench は公式表で40.0対31.4、Artificial Analysis で70対59と現れ、おそらく版が違うため、両者を混ぜていない。Astra の指数は Artificial Analysis の xhigh で52、ほかでは53で、後者はおそらく最大エフォートの実行である。集計サイトの数値には、図2の Astra のタスク別スコアを含め、エフォート水準の表示がない。FrontierCode の54.4がどの水準の値かは決められず、xhigh の51.4も一つの書き起こしにしか現れない。Opus 5.5 についての LMArena や人間の選好データは見つからなかった。