BENCHMARK ATLAS / 12 NOVEMBER 2026

Fable 5.2, Opus 5.5 and GPT-6 Astra, benchmark by benchmark

I took the benchmarks from my two survey lists and collected every published result for Claude Fable 5.2, Claude Opus 5.5 and GPT-6 Astra. Where at least two of them have a number, Fable 5.2 has the top score on 28 of 33, Opus 5.5 on 3 and Astra on 2. The effort data is much thinner than the head-to-head, because most labs publish only the maximum setting.

HOW TO READ THE NUMBERS

Most values are maximum-effort scores from the lab that ran the evaluation. A score moves with the harness, with partial against strict credit and with the index version, so where I found two values I show both. A dash means I found no published result, not that none exists.

Section one

Who leads, and by how much

Across the 33 benchmarks where at least two of the three models have a published number, Fable 5.2 holds the top score on 28. The margin is large on long-horizon and agentic work: on Remote Labor Index it scores 41.3 against 21.3 for Opus 5.5 and 20.8 for Astra, and on RoboDojo it scores 64.9 against 39.4 and 29.8. It is small on saturated math, where FrontierMath Tier 4 reads 100, 95 and 97.6. Opus 5.5 leads on PhysicianBench (68.4) and ProgramBench (91.2). Astra leads on ARC-AGI-2 (95 against 93.3).

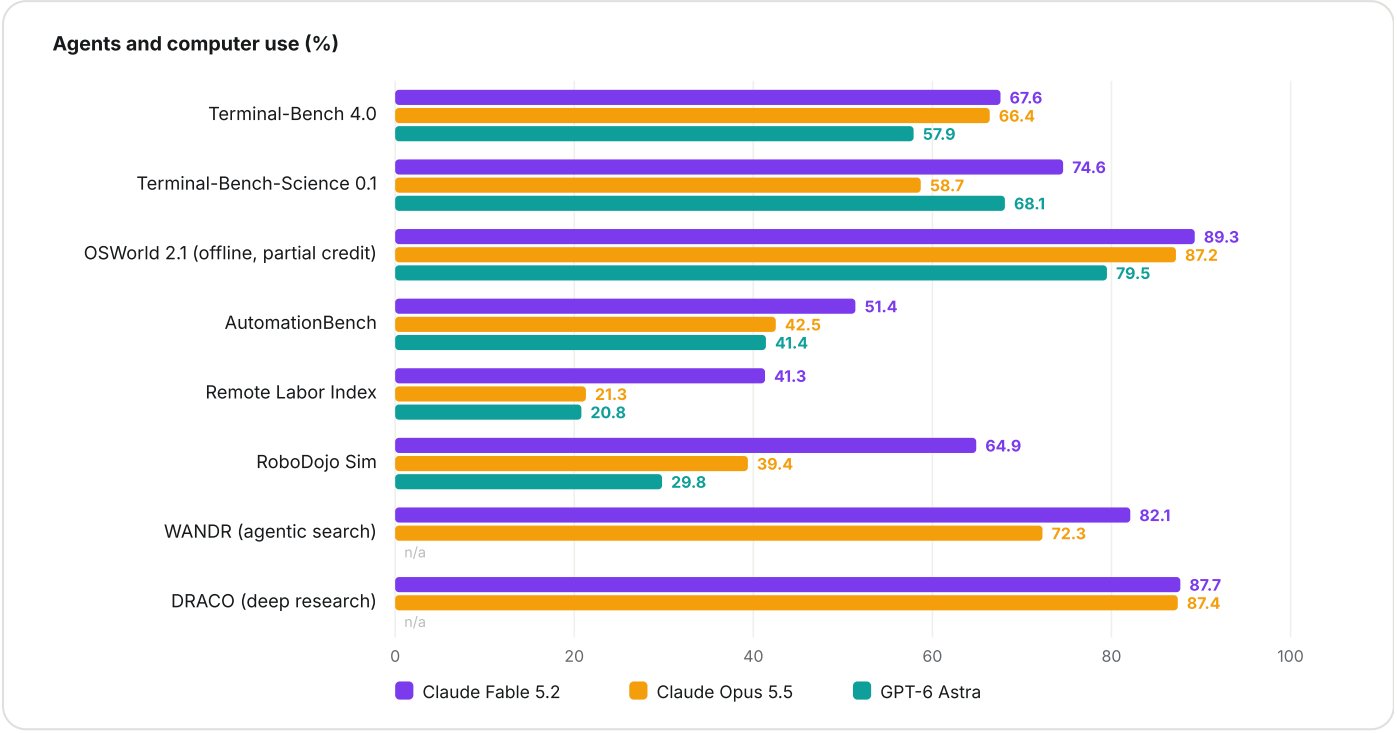


Figure 1. Agents and computer use. OSWorld 2.1 is the offline, partial-credit variant; the strict score is lower (see the conflicts table).

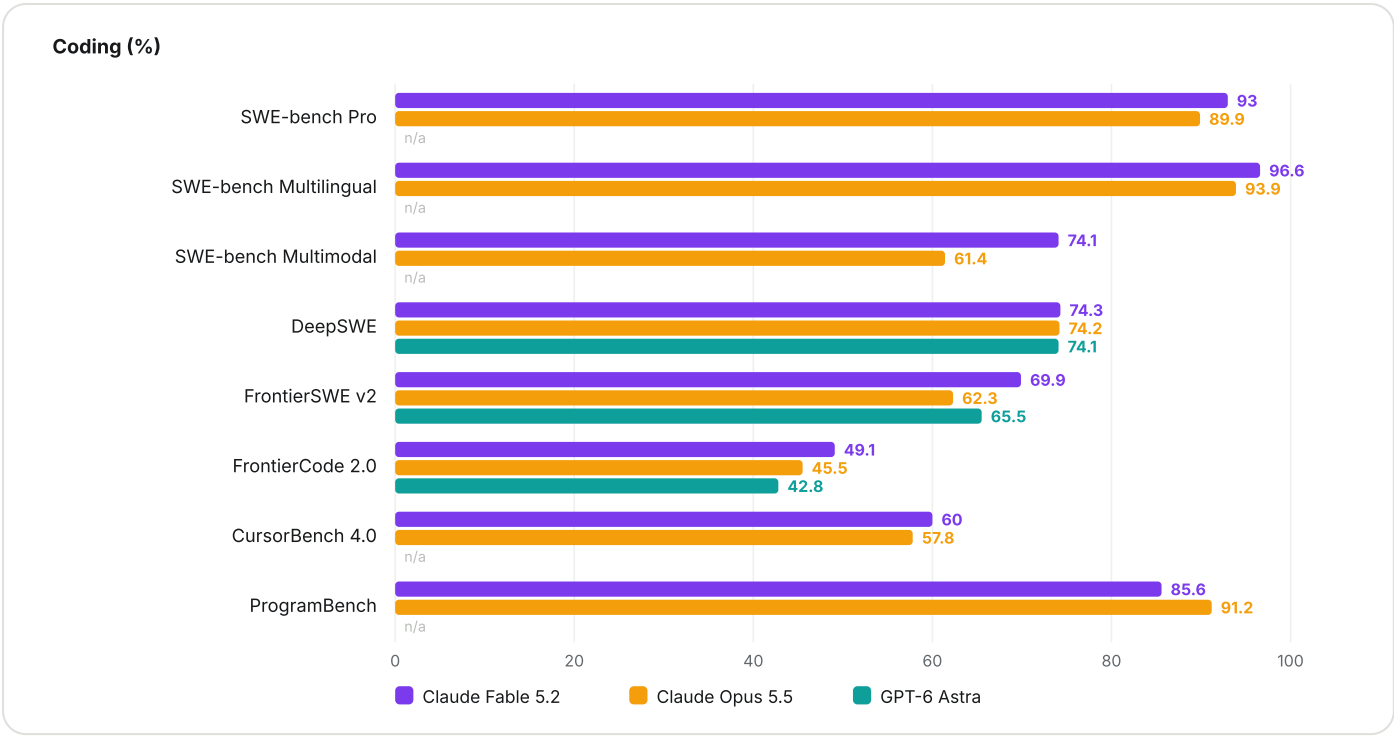


Figure 2. Coding. FrontierCode 2.0 shows each model's best published run; harnesses differ by lab.

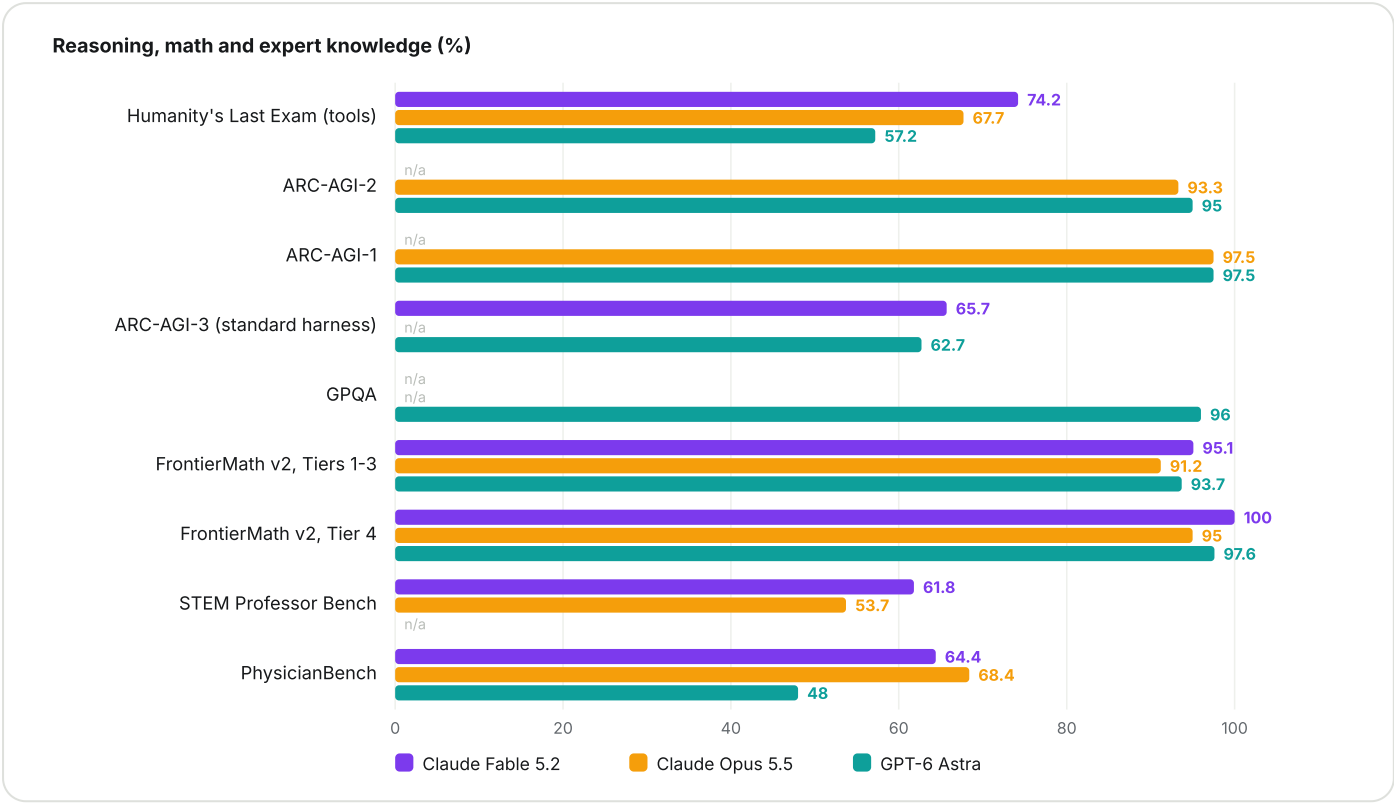


Figure 3. Reasoning, math and expert knowledge. ARC-AGI-3 is the standard harness; the provider-adapter harness reads far higher for both models.

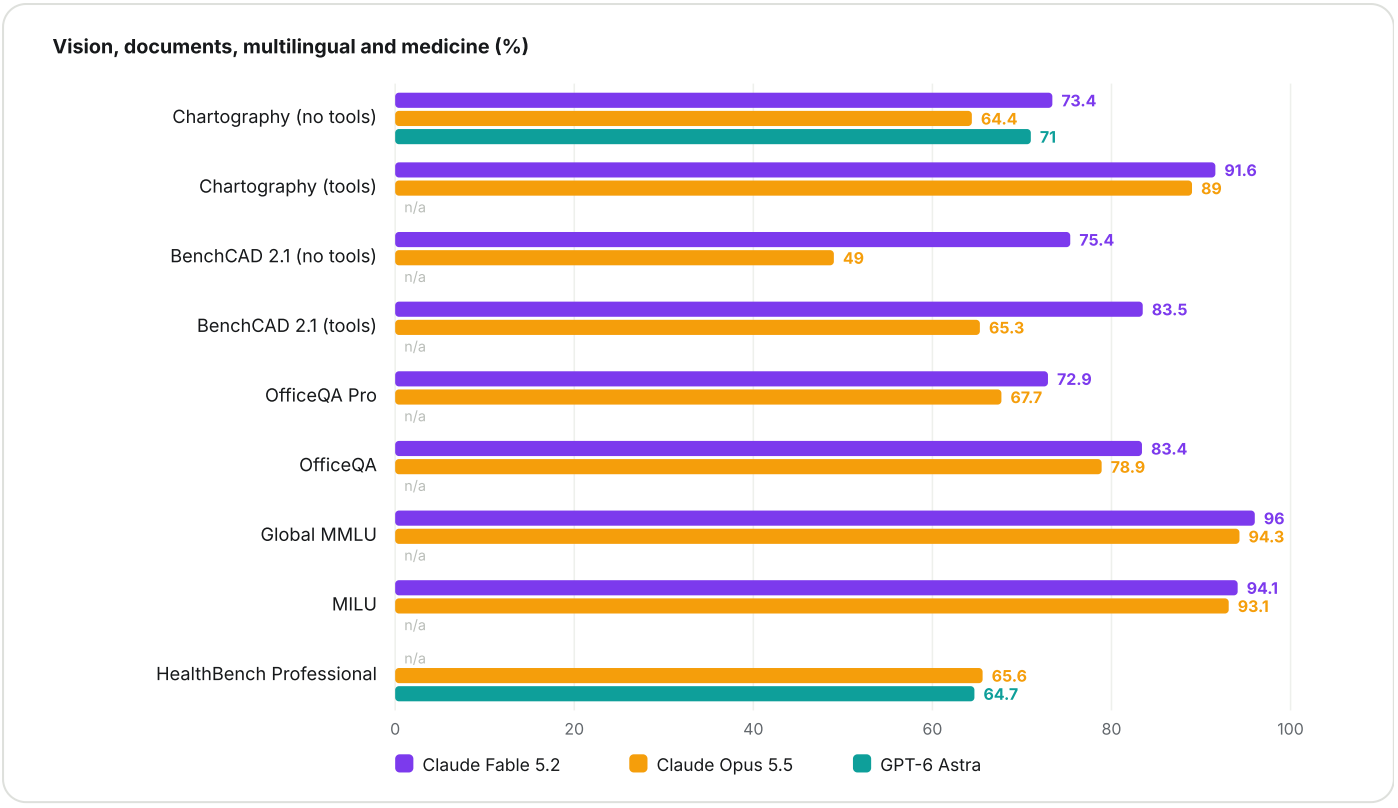


Figure 4. Vision, documents, multilingual and medicine.

Section two

What the effort setting buys

Fable 5.2 is the only one of the three with a published curve across all five settings, on the Artificial Analysis Intelligence Index. It climbs from 54 at low to 65 at max, but not evenly: low to high adds 8 points for about 11 more minutes per task, while high to max adds 3 points for about 28 more. High and xhigh tie at 62, so on this index xhigh buys time and not points. Opus 5.5 spans 35 at low to 58 at max; Artificial Analysis lists its medium, high and xhigh settings on the cost-quality frontier but does not give numbers for them. Astra is published at max only, at 57.

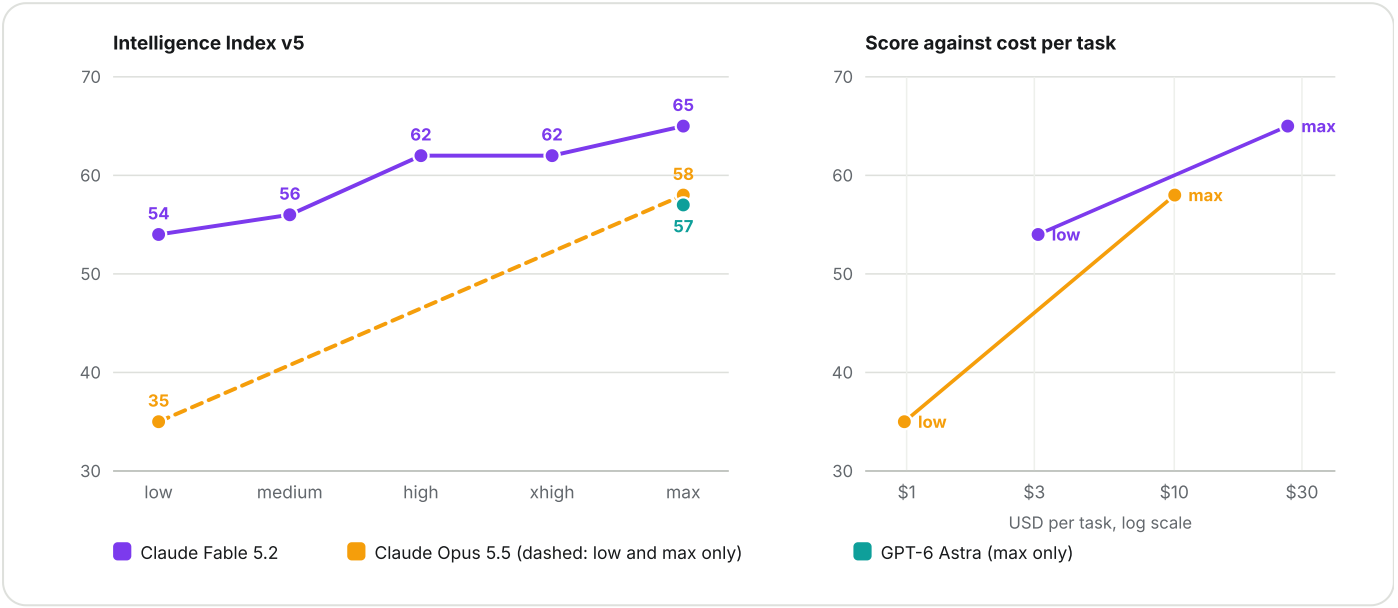


Figure 5. Artificial Analysis Intelligence Index v5 by effort setting (left) and score against cost per task (right). Opus 5.5 reads 58 in Artificial Analysis's launch article and 59 on its v5 leaderboard page; I plot 58.

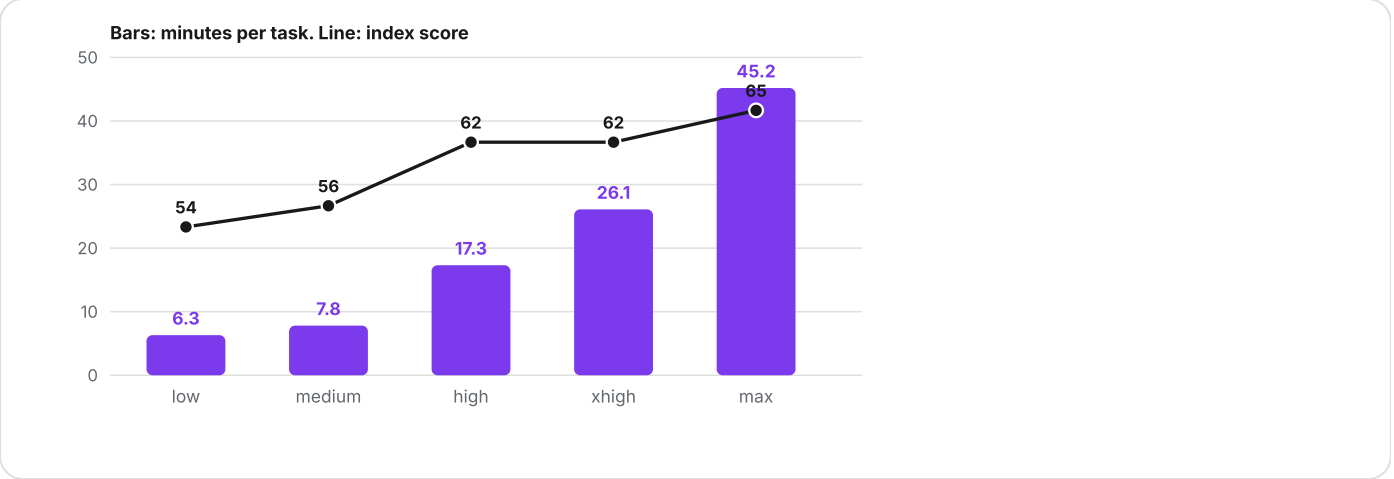


Figure 6. Fable 5.2 on the same index. Cost per task runs from about $3.10 at low to about $26.50 at max.

ARC-AGI-3

Astra has a full ladder here, and the harness matters more than the effort setting. Under the standard harness it improves steadily, from 17.5% at low to 62.7% at max, with the no-reasoning run at 35.2%. Under the provider-adapter harness every setting lands between 96.7% and 99.9%. In both, higher effort is cheaper per run, because fewer steps are wasted. For Fable 5.2 one source lists 65.7% (standard) and 94.9% (adapter), and another lists different stored rows, so I treat its ARC-AGI-3 figure as unsettled.

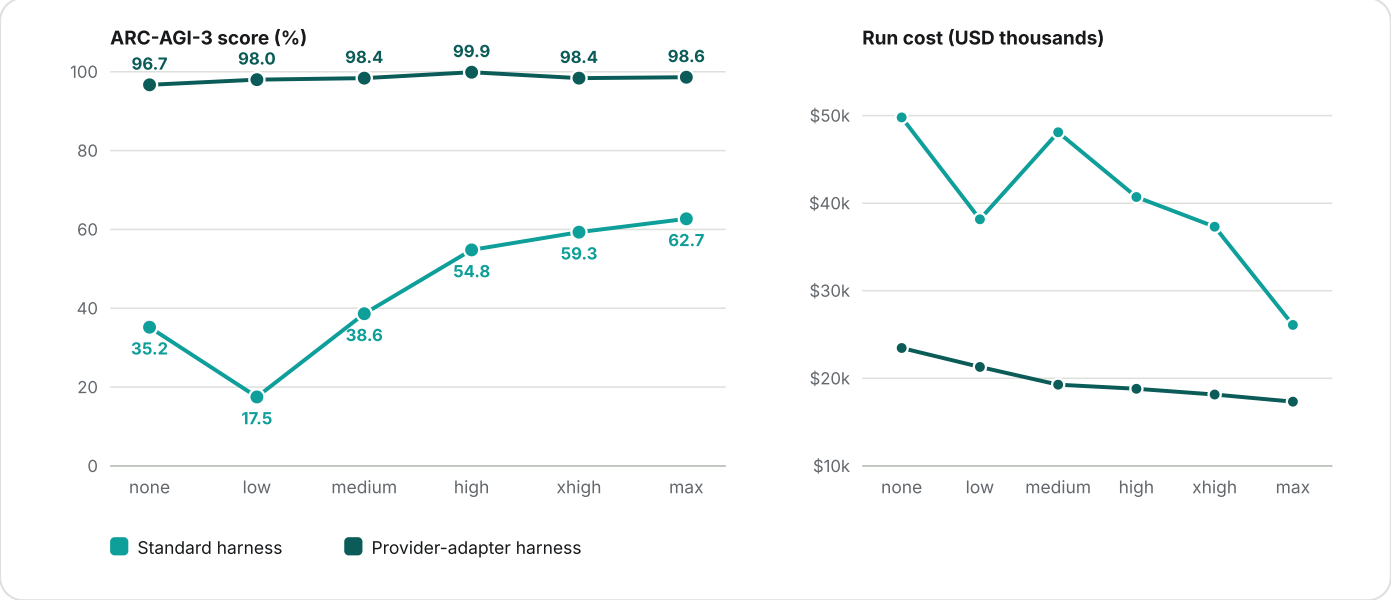


Figure 7. GPT-6 Astra on ARC-AGI-3 (semi-private set), score by effort for two harnesses (left) and the total cost of each run (right).

Coding, expert exams and data analysis

These ladders are short, and the harnesses differ: Opus 5.5 ran in Claude Code, Astra in Codex, and Fable 5.2's FrontierCode points come from Anthropic's own run. On FrontierCode 2.0, Opus 5.5 reaches 43.4 at xhigh and 45.5 at max; Astra 38.3, 41.4 and 42.8 from high to max; Fable 5.2 45.3 at high and 49.1 at xhigh, at $6.72 and $14.19 per task. On CursorBench 4.0, Opus 5.5 goes from 52.5 (medium) to 57.8 (max), flat at 56.0 across high and xhigh. On Humanity's Last Exam under Artificial Analysis's harness, Opus 5.5 jumps from 57.5 at xhigh to 61.4 at max while Fable 5.1 barely moves, 58.7 to 59.1.

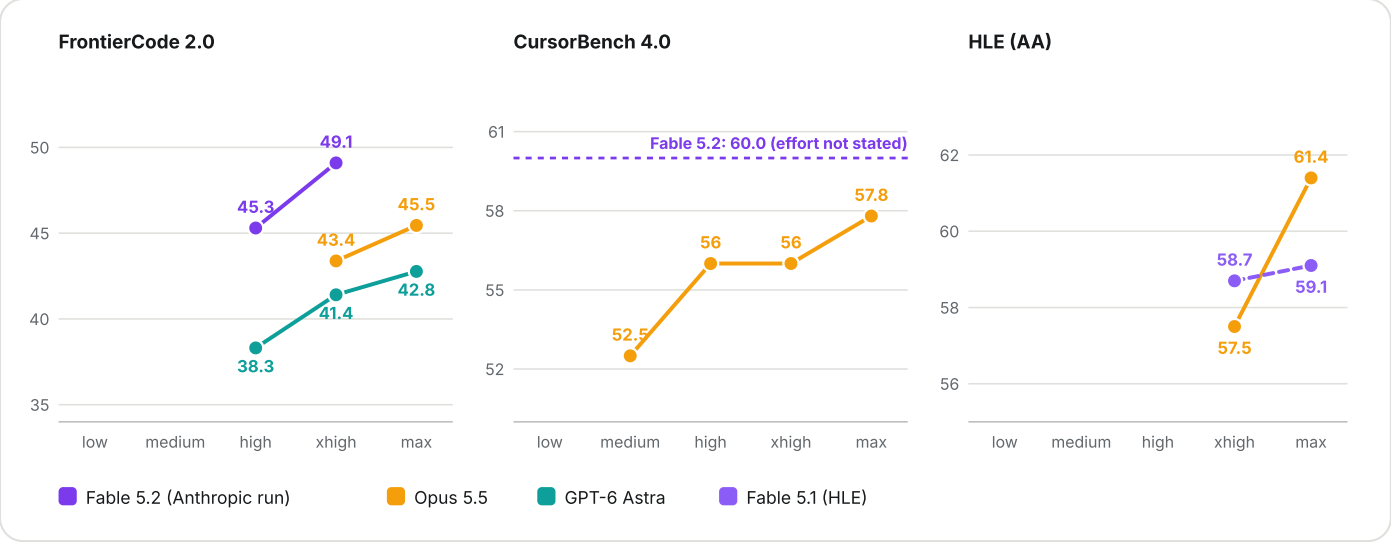


Figure 8. Effort ladders on FrontierCode 2.0, CursorBench 4.0 and Humanity's Last Exam.

Two more data points argue against assuming that more effort always helps. Astra on Hex DataBench v1.1 scores 55.0 at low and 55.0 at max, with a dip to 52.0 at high. On a 44-problem math study it scored 98.9% at medium and 97.7% at high, with overlapping 95% intervals. An arithmetic prompt was solved at every setting while output tokens grew from 546 to 1,422. Fable 5.2 on Chartography (no tools) gains from 66.4 at medium to 73.4 at max, against 64.4 for Opus 5.5 and 71.0 for Astra.

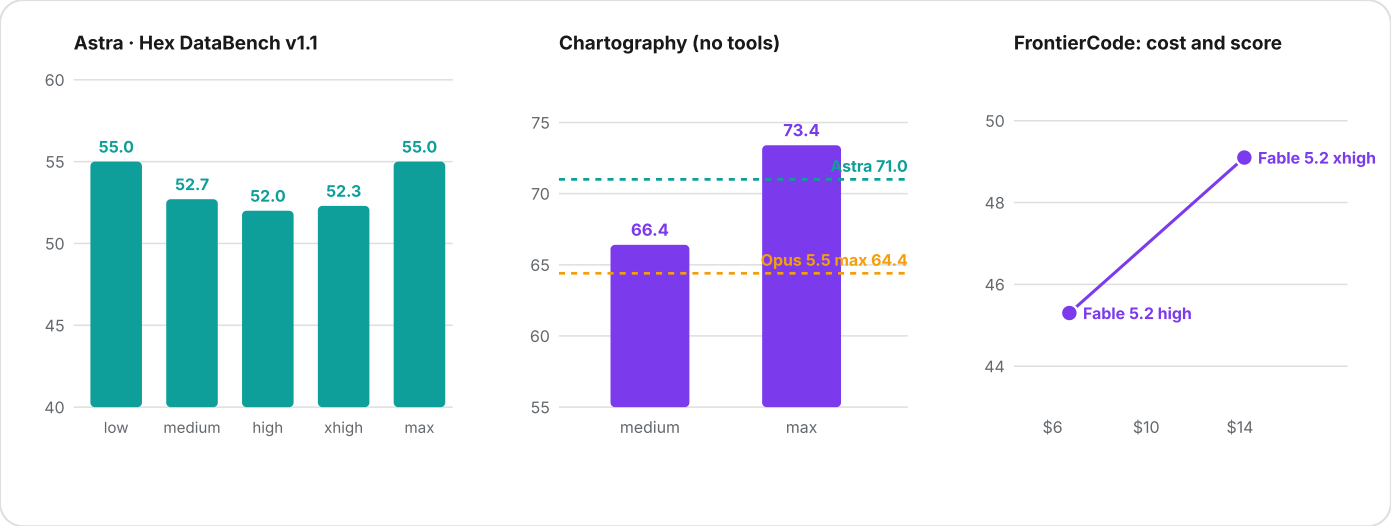


Figure 9. Astra on Hex DataBench v1.1 by effort (left), Chartography without tools (center), and Fable 5.2's FrontierCode cost against score (right).

Section three

Where sources disagree

The same benchmark often has two published numbers because of harness, partial against strict credit, index version, or an aggregator storing a different run. I keep both rather than choose. Several aggregator pages also cite documents that belong to other models, so I treat aggregator figures as claims until a primary page agrees. Opus 5.5's cyber figures were measured without safeguards; Fable 5.2 ships with them and falls back to a default model for certain requests, which affects tool-free comparisons.

BENCHMARK	VALUE A	VALUE B
ARC-AGI-3, Fable 5.2	65.7 (standard) / 94.9 (adapter)	79.26 / 97.72 (stored rows on one aggregator)
OSWorld 2.1, Fable 5.2	89.3 (offline, partial credit)	54.6 (strict)
GDPval-AA, Opus 5.5 (Elo)	1846	1866
Terminal-Bench 4.0, Opus 5.5	66.4 (Anthropic, xhigh)	59.6 (Artificial Analysis run)
AA-Briefcase Elo, Opus 5.5	1800	1822

BENCHMARK	VALUE A	VALUE B
Terminal-Bench-Science, Astra	68.1 (Anthropic table, benchmarklist)	64.6 (BenchLM) / 62.86 (Vals)
AA Intelligence Index, Opus 5.5	58 (launch article)	59 (v5 leaderboard page)

Section four

Coverage

Every benchmark from my lists where at least one of the three models has a published number. A dash means none found. Bold marks the best value in the row, lower being better where noted.

BENCHMARK	FABLE 5.2	OPUS 5.5	GPT-6 ASTRA
ARC-AGI-1	-	**97.5**	**97.5**
ARC-AGI-2	-	93.3	**95**
ARC-AGI-3 (standard)	**65.7**	-	62.7
ARC-AGI-3 (provider adapter)	94.9	-	**98.6**
Humanity's Last Exam (tools)	**74.2**	67.7	57.2
GPQA	-	-	96
FrontierMath v2 Tier 4	**100**	95	97.6
FrontierMath Erdős (open problems)	-	-	3
BrowseComp	-	-	91.5
OSWorld 2.0	-	48.7	**72.6**
OSWorld 2.1	**89.3**	87.2	79.5
Terminal-Bench 4.0	**67.6**	66.4	57.9
Terminal-Bench-Science	**74.6**	58.7	68.1
SWE-bench Pro	**93**	89.9	-
Remote Labor Index	**41.3**	21.3	20.8
GDPval-AA v2.1 (Elo)	-	**1846**	1542
Toolathlon-Verified	-	77.8	-
MRCR v2 256K-512K	-	-	100
MRCR v2 512K-1M	-	-	96.3
GraphWalks BFS 256K-1M	-	66.8	**71.8**
HealthBench Hard	-	-	36.6
Global-MMLU	**96**	94.3	-
NYT Connections	97.3	-	-
Chess puzzles (Epoch)	79	-	-
MathVis (Fable 5, not 5.2)	26.56	-	**31.25**
ExploitGym	-	33.3	**42.4**
CritPt v2 hard subset (AA)	**77**	-	72
SciCode (AA)	-	66.9	-
Gray Swan IPI, lower is better	-	**1**	8.5
Vending-Bench 2 (final $)	-	-	$15,515
SpireClimb	19.6	-	-

Section five

The catalog

270 benchmarks from the mainstream sweep and from the esoteric pass. 61 have a score on a page I could read; 209 are listed without one. The model shown is the latest or top-ranked model I found a number for, which is not necessarily the newest model in existence: a leaderboard shows its leader, and many pages were undated or unreachable. Benchmarks with no result are collected under each heading, and that means I found none, not that none exists.

Aggregators

7 / 19

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
Artificial Analysis Intelligence Index	Claude Fable 5.2 (max)	65	v5; Opus 5.5 59, Astra 57
Epoch Capabilities Index (ECI)	Claude Fable 5.2	174	
Epoch Benchmarking Hub	Claude Fable 5.2	ECI 174	see ECI
FrontierMath (Tiers 1-4, v2)	Claude Fable 5.2	T1-3 95.1% · T4 100.0%	BenchLM; Astra 93.7 / 97.6
LiveBench	gpt-5.5-xhigh	81.28	snapshot 2026-06-10; Fable 5 xhigh 78.57
Scale SEAL	Claude Fable 5.2	41.3% (Remote Labor Index)	
Vals AI (Vals Index)	Claude Fable 5.2 (High)	71.31%	1st of 36; Astra 65.02

No result found: LMArena; OpenCompass; BenchLM; BenchmarkList; Codesota; llm-stats; HELM; Open LLM Leaderboard v2; BFCL; OpenRouter rankings; AIMultiple 200+; Snorkel Open Benchmarks Grants

Knowledge & reasoning

7 / 11

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
MMLU-Pro	Sakana Namazu	90.33%	sampled 2026-08-11; Opus 4.5 89.5
GPQA Diamond	GPT-6 Astra	96.0%	BenchLM
Humanity's Last Exam	Claude Fable 5.2	74.2% (with tools)	Opus 5.5 67.7, Astra 57.2
CritPt	Claude Fable 5.2	77% (v2 hard subset)	AA; Astra 72%
ARC-AGI-1	Opus 5.5 / GPT-6 Astra	97.5%	tie
ARC-AGI-2	GPT-6 Astra (Max)	95%	Opus 5.5 (High) 93.33
ARC-AGI-3	GPT-6 Astra	99.9% adapter · 62.7% standard	harness-dependent

No result found: MMLU; HLE-Diamond (AA); FrontierScience; SimpleBench

Math

2 / 11

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
AIME 2025	GPT-5.2 (xhigh)	99%	snapshot 2026-06-10; saturated
ArXivMath (Aug 2026)	Claude Opus 5.5	96.9% tools · 91.2% no tools	Fable 5.1 92.1 / 82.9

No result found: HMMT; MATH-500; GSM8K; USAMO 2026; IMO-ProofBench / AnswerBench; Putnam-Bench; OlympiadBench; ProofBench; MathArena

Coding

9 / 17

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
SWE-bench Pro	Claude Fable 5.2 (max)	93.0%	Opus 5.5 89.9
SWE-bench Multilingual	Claude Fable 5.2	96.6%	
SWE-bench Multimodal	Claude Fable 5.2	74.1%	
Terminal-Bench 4.0	Claude Fable 5.2 (max)	67.6%	Opus 5.5 66.4, Astra 57.9
SciCode	Claude Opus 5.5 (max)	66.9%	AA v4.3
CursorBench 4.0	Claude Fable 5.2	60.0%	Opus 5.5 57.8 (max)
FrontierCode 2.0	Claude Fable 5.2 (xhigh)	49.1%	leaderboard best: Opus 5.5 max 45.45
FrontierSWE v2	Claude Fable 5.2	69.9%	
DeepSWE	Claude Fable 5.2	74.3%	Opus 74.2, Astra 74.1

No result found: SWE-bench Verified; Terminal-Bench 2.1 (Vals); LiveCodeBench; Aider Polyglot; HumanEval; SWE-Lancer; MLE-bench; CRUXEval

Agents & computer use

10 / 16

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
OSWorld (Verified)	Pointer Agent w/ Opus 4.7	83.64%	sampled 2026-05-27
OSWorld 2.0	GPT-6 Astra	72.6%	BenchLM
OSWorld 2.1	Claude Fable 5.2	89.3% (offline, partial)	Opus 5.5 87.2, Astra 79.5
Toolathlon	Claude Opus 5.5	77.8% (Verified)	
GDPval-AA	Claude Opus 5.5 (max)	1846 Elo	Astra 1542; Fable 5.2 1831 in one source
Remote Labor Index	Claude Fable 5.2 (high)	41.3%	Opus 21.3, Astra 20.8
Vending-Bench 2	GPT-6 Astra	$15,515 final	sampled 2026-10-03
BrowseComp	Nex-N2.5-Max	92.6%	Astra 91.5; latest entry Inkling 2 Small 90.2
DRACO	Claude Fable 5.2	87.7%	
AutomationBench	Claude Fable 5.2	51.4%	Opus 5.5 42.5, Astra 41.4

No result found: WebArena; tau-bench / tau2-bench; Agents' Last Exam; GAIA; MedBrowseComp; PaperBench

Long context

2 / 12

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
MRCR v2 (8-needle)	GPT-6 Astra	100% @256K-512K · 96.3% @512K-1M	BenchLM
Graphwalks	GPT-6 Astra	71.8% (BFS 256K-1M)	Opus 5.5 66.8

No result found: OpenAI-MRCR; RULER; NIAH / NIAH-2; LongBench v1/v2; NoLiMa; BABILong; AA-LCR; HELMET; NoCha; Michelangelo

Factuality

2 / 10

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
SimpleQA	Gemini 3.1 Pro (high)	77.3%	Fable 5 (max) 68.3; snapshot 2026-07-15
AA-Omniscience	Claude Opus 5.5 (max)	48 (v1.1 index)	AA v5

No result found: SimpleQA Verified; FACTS; Vectara HHEM; HalluHard; PersonQA; TruthfulQA; FActScore; LongFact

Instruction & chat

1 / 10

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
IFEval	Kimi-K2.6	94.5	self-reported, 2026-06-08

No result found: IFBench; Multi-IF; MT-Bench; Arena-Hard; AlpacaEval; WildBench; EQ-Bench; WritingBench; RewardBench

Medicine

3 / 11

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
HealthBench	Claude Opus 5.5	68.1% raw	Astra 56.9
HealthBench Hard	GPT-6 Astra	36.6%	
HealthBench Professional	Claude Opus 5.5	65.6%	Astra 64.7

No result found: MedQA; MedMCQA; PubMedQA; MedXpertQA; MedHELM; MEDEC; MedVH; CREOLA

Law, finance, science

1 / 17

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
Terminal-Bench-Science	Claude Fable 5.2	74.6%	Opus 5.5 58.7, Astra 68.1

No result found: LegalBench; LawBench; LexEval; CaseLaw v2; Legal Research Bench; HLAB; FinanceBench; Finance Agent v2; EMB; CorpFin; TaxEval; Tax Agent Bench; LAB-Bench; ScienceAgentBench; HLE-Physics; CMT-Benchmark

Multilingual

1 / 10

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
Global-MMLU	Claude Fable 5.2	96.0%	Lite/full not distinguished

No result found: MMLU-ProX; INCLUDE; MGSM; Belebele; AfriMMLU / AfriXNLI; MuBench; MultiLoKo; BenchMax; FLORES-200

Multimodal

0 / 13

No result found: MMMU / MMMU-Pro; MathVista; ChartQA; DocVQA; RealWorldQA; OCRBench; ScreenSpot-Pro; Video-MME / v2; MLVU; LVBench; MMVU; EgoSchema; VideoMMMU

Generative media

0 / 11

No result found: Image arenas (LMArena); GenEval; GenAI-Bench / GenAI-Arena; HEIM; T2I-CompBench; Imagine-Bench; EditScore; Gen-Arena; VBench; EvalCrafter; VideoGen-Reward

Speech & embeddings

0 / 7

No result found: Open ASR Leaderboard; FFASR / ESB / LibriSpeech / FLEURS; Seed-TTS; Real World VoiceEQ; MMAU / MMAR; MTEB / MMTEB / MIEB; MAEB / MAEB+

Robotics

1 / 6

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
RoboDojo Sim	Claude Fable 5.2	64.9%	Opus 5.5 39.4; Astra 29.8

No result found: LIBERO (+Plus/-X/-PRO/-PeRM); CALVIN; SimplerEnv; vla-eval harness; NativeEmbodied

Autonomy & cyber

3 / 15

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
ExploitGym	GPT-6 Astra	42.4%	Opus 5.5 33.3
ExploitBench (V8)	GPT-6 Astra	100%	secondary report
CVE Rediscovery	Claude Mythos 5.2	89.6%	Opus 5.5 81.3

No result found: METR time horizons (HCAST, RE-Bench, SWAA); MirrorCode / expenditure horizon; RE-Bench; Cybench; NYU CTF; CVE-Bench; BountyBench; CyberGym; AISI cyber ranges; CAIBench; SEC-bench; BaxBench

Safety & alignment

1 / 15

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
Gray Swan IPI	GPT-6 Astra	8.5% (15 attempts)	Opus 5.5 1.0%; lower is better

No result found: HarmBench; JailbreakBench; StrongREJECT; AILuminate; AIR-Bench; AgentHarm; WMDP / BioLP-Bench / VCT; XSTest; AgentDojo; MASK; Apollo scheming suite / Bloom / Petri; SycEval; MACHIAVELLI; BIG-Bench HHH

Ancient scripts

1 / 7

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
TokenAI Hieroglyphic AI Benchmark	TokenAI model	~90% overall	vendor-reported

No result found: Hemauer Egyptian/Luwian evaluation; Reasoning Over the Glyphs; Ancient logographic benchmark (EGY/AKK/ZHO/Linear A); HieroLM; Dongba pictogram study; Falsifiability Sheet pilot

Linguistics puzzles

0 / 5

No result found: LingOly; Linguini; IOLBench / LOBSTER / LingBench++; PuzzLing Machines / modeLing; Rosetta-to-Match-Up corpus

Esoteric code

1 / 1

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
EsoLang-Bench	GPT-5.2	3.8% best	vs 100% Python; 0-11% overall

Games

3 / 5

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
BALROG	Gemini 3	29.5% progress	sampled 2026-05-29; NetHack 1.6%
Kaggle Game Arena (chess)	Gemini 3 Pro Preview	Elo 1325	Gemini 3 Flash 1297
InfiniteBM Chess	Claude Opus 4.7	Elo 1997.5	only 16 games

No result found: Kaggle Game Arena (poker / Werewolf); Pokemon Agent Challenge

Social & theory of mind

0 / 5

No result found: Werewolf Arena / WOLF / Triadic Werewolf; MafiaScope / MIVA; Decrypto / Avalon-ToM-Bench; SOTOPIA / Hi-ToM / FANToM / ToMi; MACHIAVELLI

Open math & proofs

1 / 8

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
FrontierMath Erdős	GPT-6 Astra	3%	68 open problems, fixed budget

No result found: FrontierMath: Open Problems / HorizonMath; Formal Conjectures; miniF2F; PutnamBench; ProverBench; ProofNet / CombiBench / FormalMATH; FormalProofBench / SorryDB

Puzzles

3 / 5

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
NYT Connections	Claude Fable 5.2	97.3%	
Sudoku-Bench		<15% best	no-tool runs, older models
InsanityBench		~10% best	at time of posting

No result found: Cryptic crosswords / puzzlehunts / PuzzlePlex; Riddles / lateral thinking sets

Spatial & physical

0 / 5

No result found: BuildArena; GRASP / FloorplanQA / SPhyR; 3DSRBench / OpenBench / SpatialEval; GeoBench (GeoGuessr); PHYRE / Physion / IntPhys / CLEVRER / PIQA

Niche science

0 / 3

No result found: PG-LLM (protein variants); ChemBench; SciKnowEval / SFE / SDE

Tokenization quirks

0 / 2

No result found: CharBench; TASE / Strawberry Problem set

Humor, creativity, music

0 / 4

No result found: Oogiri-Master; LoTbench; MusiXQA / ABC-Eval; Pelican on a bicycle

Behavior & wellbeing

2 / 5

BENCHMARK	LATEST OR TOP MODEL FOUND	SCORE	NOTE
Spiral-Bench	GPT-5	87	DeepSeek-R1-0528 22.4
SAD (situational awareness)	Claude 3.5 Sonnet	54%	2024 result

No result found: DelusionEval; ELEPHANT / SnitchBench; Model-welfare self-report work

Ethics & values

0 / 2

No result found: TrolleyBench / MoralBench / MOSAIC; MultiTP / GlobalOpinionQA / PRISM / ETHICS

Forecasting

0 / 2

No result found: Prophet Arena; Prediction Arena / ForecastBench / ForecastQA

Sources

Primary data. Anthropic announcement pages and the Claude Opus 5.5 system card; OpenAI's GPT-6 Astra materials; Artificial Analysis (Intelligence Index v5 and its effort breakdowns); ARC Prize results; Epoch AI (ECI, FrontierMath); Vals AI; Hex's DataBench write-up; BenchLM comparison pages and benchmarklist.com leaderboards for per-benchmark scores.

What I verified. Every figure was read from a page I could open, and nothing is estimated or interpolated. Where two sources disagree both values appear.

What I could not verify. Per-effort data exists for very few model and benchmark pairs, so most effort ladders here have two to four points. Several aggregator figures have no primary page behind them. Many official leaderboards render client-side and

returned nothing, so those benchmarks show no result in the catalog.

ベンチマーク・アトラス / 2026年11月12日

Fable 5.2、Opus 5.5、GPT-6 Astra をベンチマークごとに比べる

自分の調査リスト二本にあるベンチマークから、Claude Fable 5.2、Claude Opus 5.5、GPT-6 Astra の公表済みの結果をすべて集めた。少なくとも二つのモデルに数値がある 33 件のうち、最高点は Fable 5.2 が 28 件、Opus 5.5 が 3 件、Astra が 2 件である。エフォートの設定別データはそれよりずっと薄い。多くの研究所は最大設定の値しか公表しないからだ。

数値の読み方

数値の大半は、評価を実施した研究所が出した最大エフォートのスコアである。スコアはハーネス、部分点か厳密採点か、指数のバージョンによって動くため、二つの値が見つかった場合は両方を示した。ダッシュは公表済みの結果を見つけられなかったという意味であり、存在しないという意味ではない。

第一節

誰が、どれだけ先行しているか

少なくとも二つのモデルに公表値がある 33 件のベンチマークのうち、Fable 5.2 が最高点を取ったのは 28 件である。差が大きいのは長期的でエージェント的な課題で、Remote Labor Index では Fable 5.2 が 41.3、Opus 5.5 が 21.3、Astra が 20.8、RoboDojo では 64.9 に対し 39.4 と 29.8 である。飽和した数学では差が小さく、FrontierMath ティア 4 は 100、95、97.6 となる。Opus 5.5 が先行するのは PhysicianBench（68.4）と ProgramBench（91.2）、Astra が先行するのは ARC-AGI-2（95 対 93.3）である。



図 1. エージェントとコンピュータ操作。OSWorld 2.1 はオフライン・部分点の変種で、厳密採点の値はこれより低い（食い違いの表を参照）。

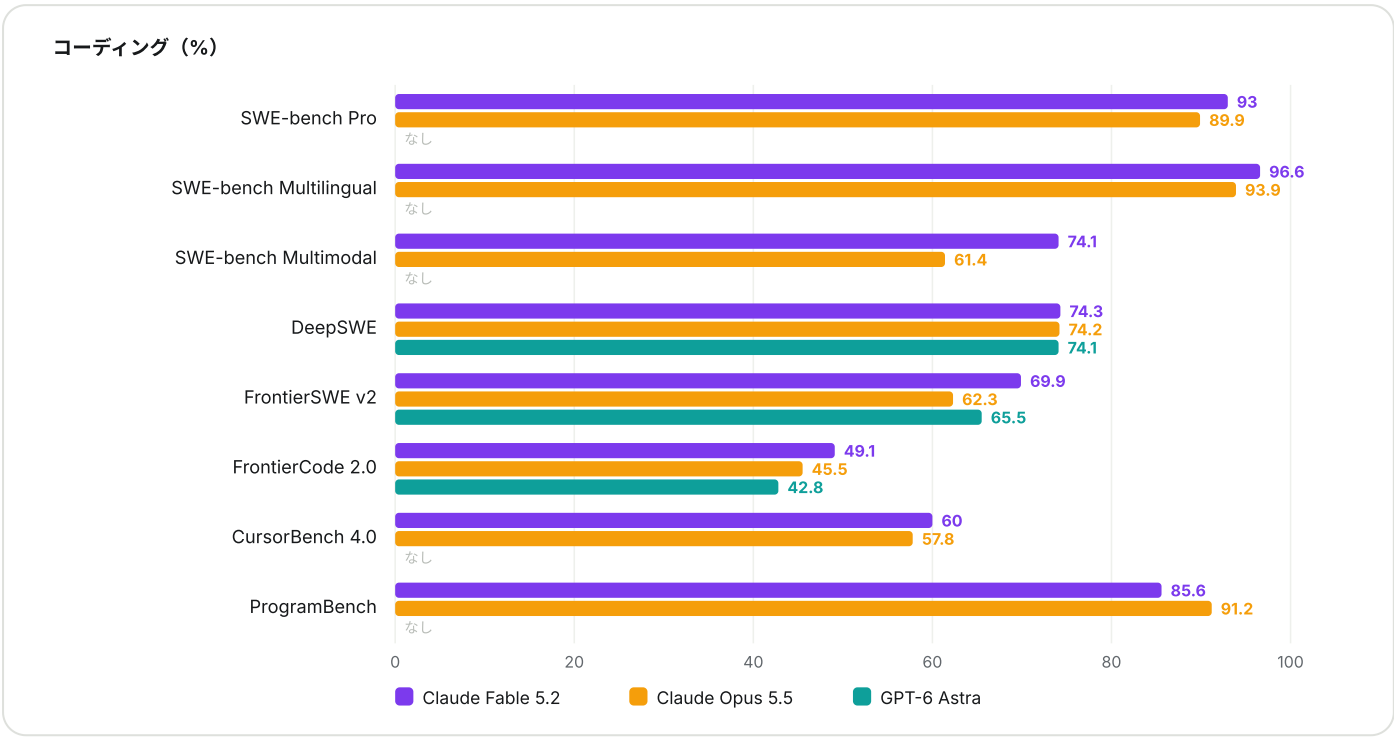


図 2. コーディング。FrontierCode 2.0 は各モデルの公表済みの最良の実行で、ハーネスは研究所ごとに異なる。

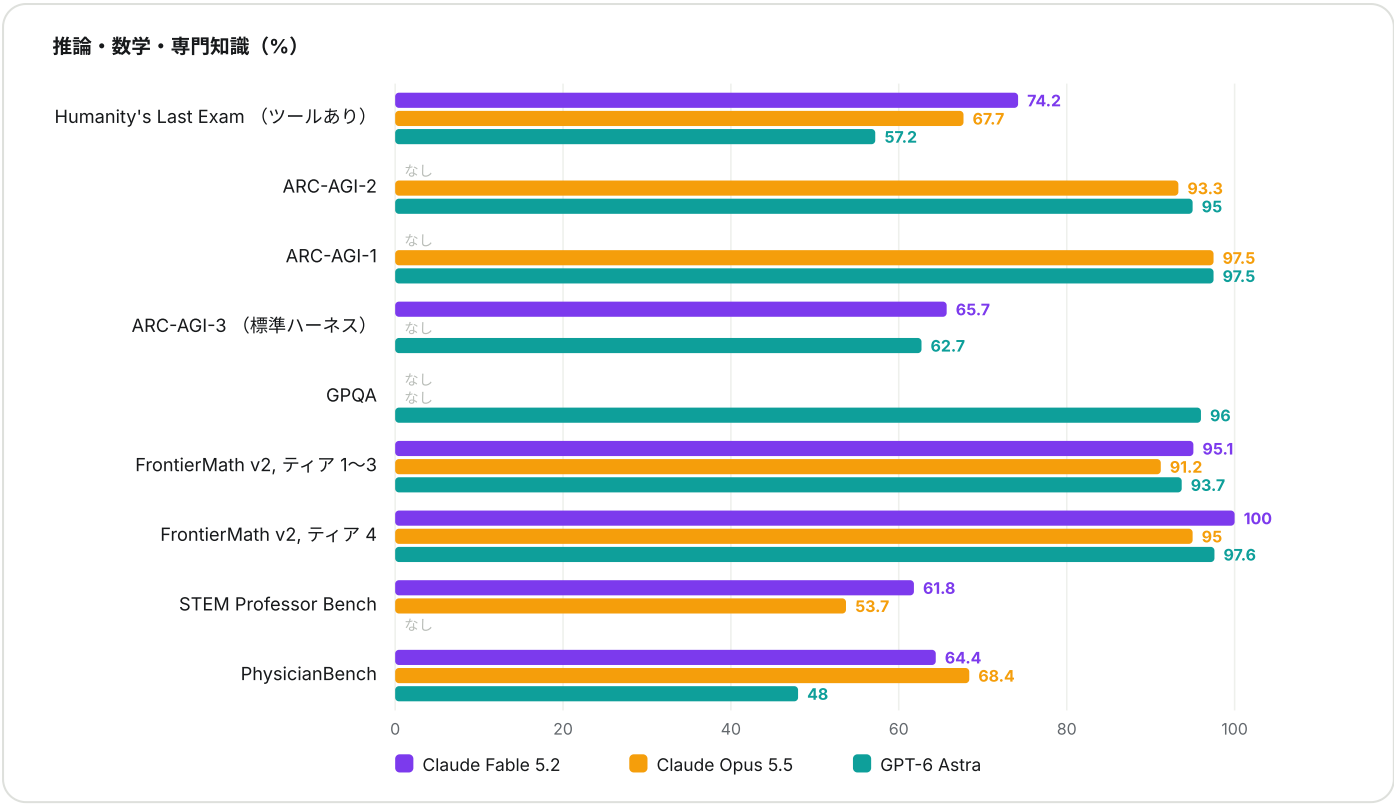


図 3. 推論・数学・専門知識。ARC-AGI-3 は標準ハーネスの値で、プロバイダ・アダプタ・ハーネスでは両モデルとも大きく上がる。

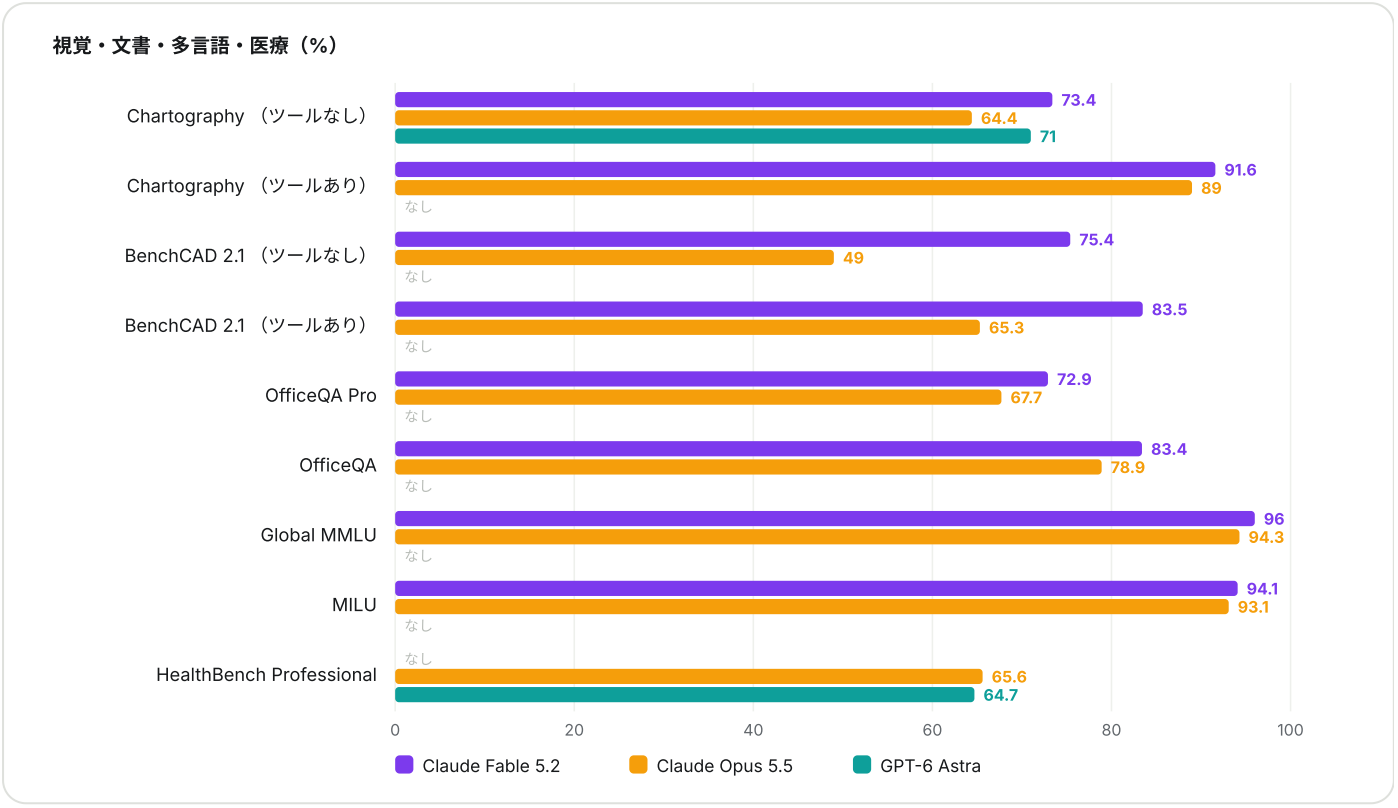


図 4. 視覚・文書・多言語・医療。

第二節

エフォート設定で何が買えるか

三つのうち五つの設定すべてで曲線が公表されているのは Fable 5.2 だけで、Artificial Analysis の Intelligence Index で low の 54 から max の 65 まで上がる。ただし一様ではない。low から high までは 1 タスクあたり約 11 分の追加で 8 ポイント上がるが、high から max までは約 28 分の追加で 3 ポイントしか上がらない。high と xhigh は 62 で並ぶので、この指数では xhigh が買うのは点数ではなく時間である。Opus 5.5 は low の 35 から max の 58 までで、Artificial Analysis は medium、high、xhigh をコスト対品質のフロンティア上に載せているが、数値は示していない。Astra は max の 57 だけが公表されている。

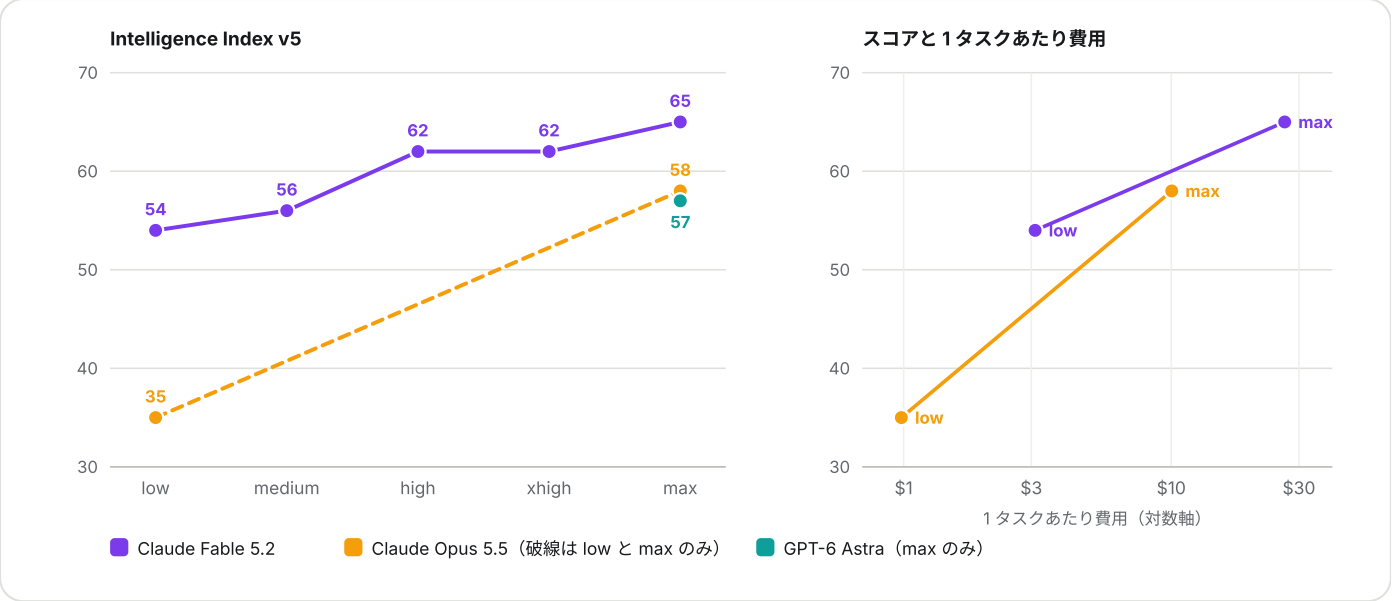


図 5. エフォート設定別の Artificial Analysis Intelligence Index v5（左）と、1 タスクあたり費用に対するスコア（右）。Opus 5.5 は Artificial Analysis の発表記事では 58、v5 のリーダーボードでは 59 だが、ここでは 58 を描いた。

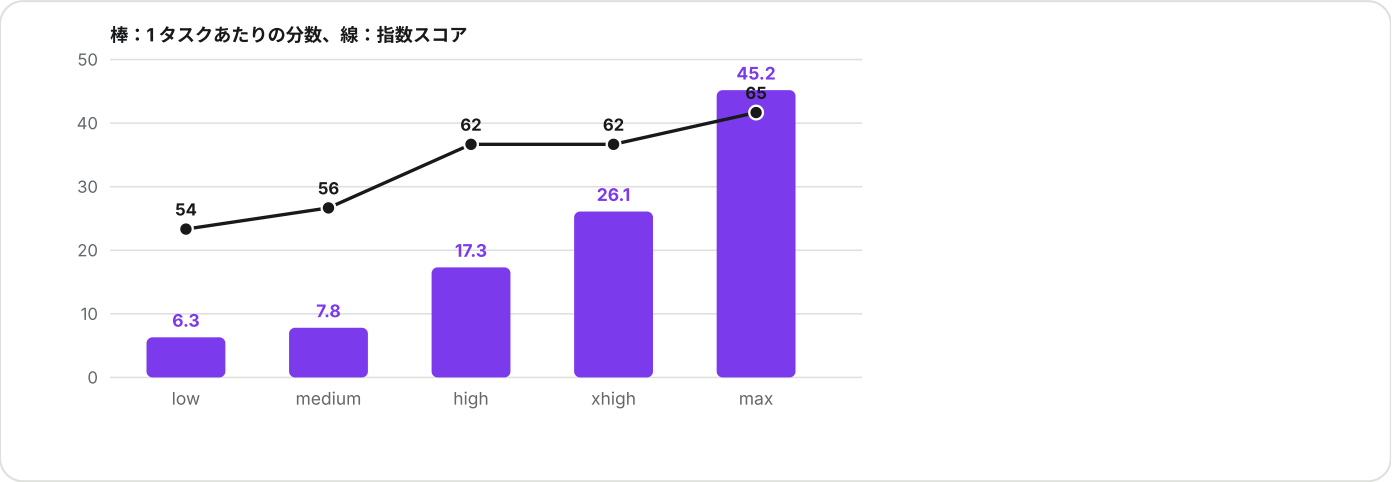


図 6. 同じ指数での Fable 5.2。1 タスクあたり費用は low の約 3.10 ドルから max の約 26.50 ドルまで増える。

ARC-AGI-3

Astra はここで全段階の値が揃っており、エフォート設定よりもハーネスの影響のほうが大きい。標準ハーネスでは low の 17.5% から max の 62.7% まで着実に上がり、推論なしの実行は 35.2% である。プロバイダ・アダプタ・ハーネスでは、どの設定でも 96.7% から 99.9% に収まる。どちらでも、エフォートが高いほうが一回の実行費用は安い。無駄な手数が減るためである。Fable 5.2 については、ある情報源が 65.7%（標準）と 94.9%（アダプタ）を載せ、別の情報源が異なる保存値を載せているので、この値は確定していないものとして扱う。

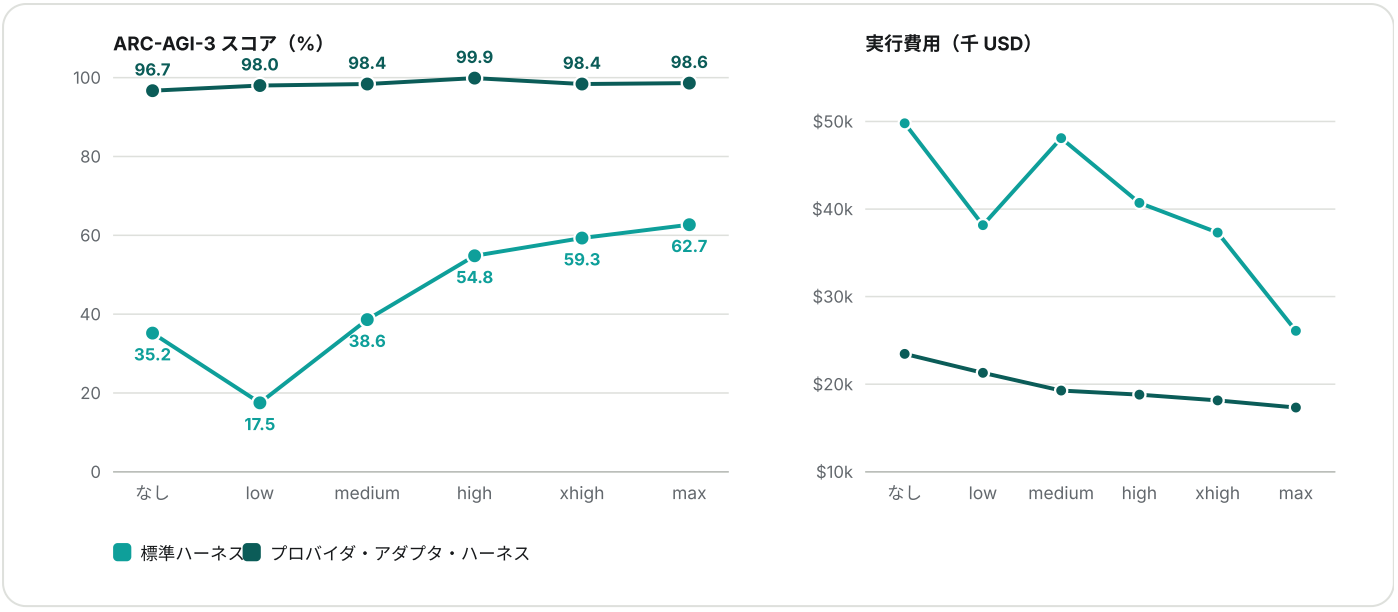


図 7. ARC-AGI-3（セミプライベート）での GPT-6 Astra。二つのハーネスでのエフォート別スコア（左）と、各実行の総費用（右）。

コーディング、専門試験、データ分析

これらの階梯は短く、ハーネスも異なる。Opus 5.5 は Claude Code、Astra は Codex で動かされ、Fable 5.2 の FrontierCode の点は Anthropic 自身の実行によるものだ。FrontierCode 2.0 では、Opus 5.5 が xhigh で 43.4、max で 45.5、Astra が high から max まで 38.3、41.4、42.8、Fable 5.2 が high で 45.3、xhigh で 49.1（1 タスク 6.72 ドルと 14.19 ドル）である。CursorBench 4.0 では Opus 5.5 が medium の 52.5 から max の 57.8 まで上がり、high と xhigh は 56.0 で横ばいになる。Artificial Analysis の実行での Humanity's Last Exam では、Opus 5.5 が xhigh の 57.5 から max の 61.4 へ跳ね上がる一方、Fable 5.1 は 58.7 から 59.1 とほとんど動かない。

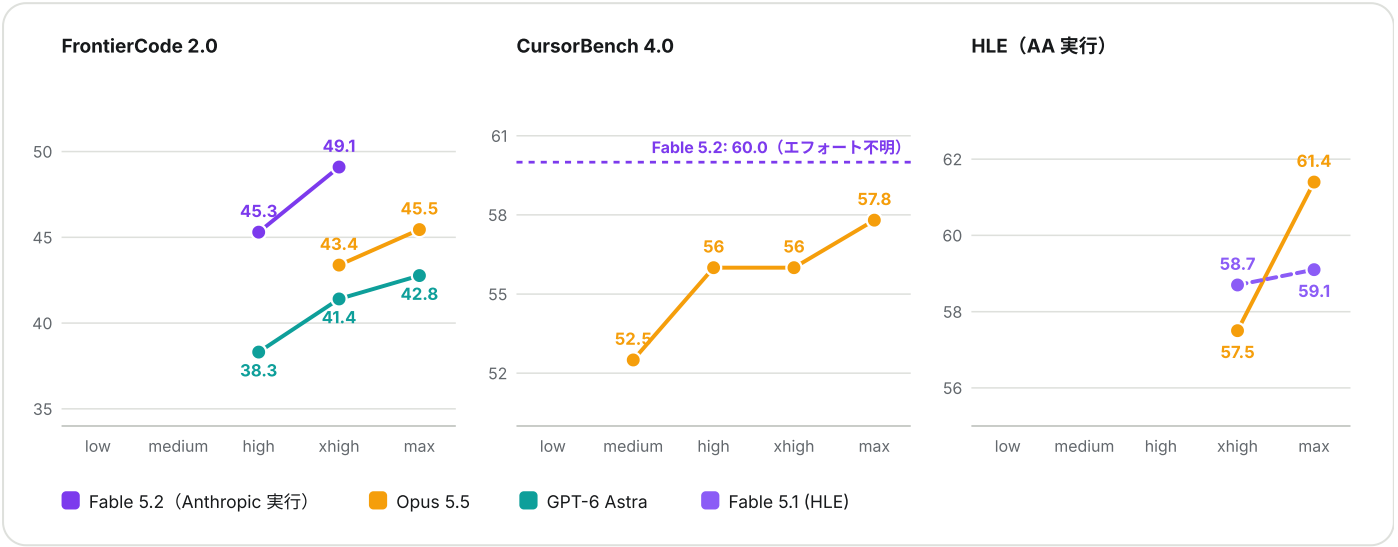


図 8. FrontierCode 2.0、CursorBench 4.0、Humanity's Last Exam のエフォート階梯。

さらに二つのデータは、エフォートを上げれば常に有利だという想定に反する。Hex DataBench v1.1 の Astra は low で 55.0、max で 55.0 と同じで、high では 52.0 に下がる。44 問の数学の検証では、medium が 98.9%、high が 97.7% で、95% 区間は重なる。算術の問いはどの設定でも正解で、出力トークンは 546 から 1,422 に増えた。Chartography（ツールなし）の Fable 5.2 は medium の 66.4 から max の 73.4 に伸び、Opus 5.5 は 64.4、Astra は 71.0 である。

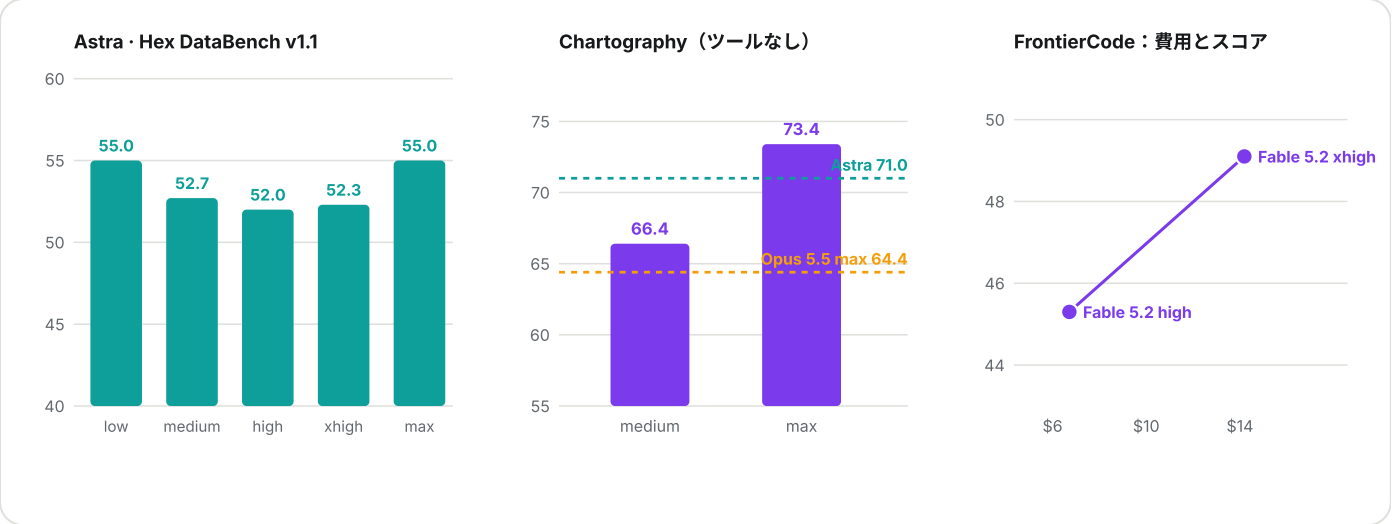


図 9. エフォート別の Astra の Hex DataBench v1.1（左）、ツールなしの Chartography（中央）、Fable 5.2 の FrontierCode の費用とスコア（右）。

第三節

情報源が食い違う箇所

同じベンチマークに二つの公表値があることは多い。ハーネス、部分点か厳密採点か、指数のバージョン、あるいは集計サイトが別の実行を保存していることが理由である。どちらかを選ばず、両方を残した。集計サイトのページには他のモデルの文書を出典にしているものもあるため、一次ページと一致するまでは集計サイトの値を主張として扱う。Opus 5.5 のサイバー関連の値は安全策なしで測定されたもので、Fable 5.2 は安全策を備え、特定の要求では既定のモデルに切り替わる。これはツールなしの比較に影響する。

ベンチマーク	値 A	値 B
ARC-AGI-3、Fable 5.2	65.7（標準）/ 94.9（アダプタ）	79.26 / 97.72（ある集計サイトの保存値）
OSWorld 2.1、Fable 5.2	89.3（オフライン・部分点）	54.6（厳密採点）
GDPval-AA、Opus 5.5（Elo）	1846	1866
Terminal-Bench 4.0、Opus 5.5	66.4（Anthropic、xhigh）	59.6（Artificial Analysis の実行）
AA-Briefcase Elo、Opus 5.5	1800	1822
Terminal-Bench-Science、Astra	68.1（Anthropic の表、benchmarklist）	64.6（BenchLM）/ 62.86（Vals）
AA Intelligence Index、Opus 5.5	58（発表記事）	59（v5 のリーダーボード）

第四節

カバー範囲

調査リストのうち、三つのモデルの少なくとも一つに公表値があるベンチマークをすべて並べた。ダッシュは未確認の意味。太字はその行の最良値で、低いほうが良い項目はその旨を記した。

ベンチマーク	FABLE 5.2	OPUS 5.5	GPT-6 ASTRA
ARC-AGI-1	-	**97.5**	**97.5**
ARC-AGI-2	-	93.3	**95**
ARC-AGI-3 （標準）	**65.7**	-	62.7
ARC-AGI-3 (プロバイダ・アダプタ)	94.9	-	**98.6**
Humanity's Last Exam （ツールあり）	**74.2**	67.7	57.2
GPQA	-	-	96

ベンチマーク	FABLE 5.2	OPUS 5.5	GPT-6 ASTRA
FrontierMath v2 ティア 4	**100**	95	97.6
FrontierMath Erdős (未解決問題)	-	-	3
BrowseComp	-	-	91.5
OSWorld 2.0	-	48.7	**72.6**
OSWorld 2.1	**89.3**	87.2	79.5
Terminal-Bench 4.0	**67.6**	66.4	57.9
Terminal-Bench-Science	**74.6**	58.7	68.1
SWE-bench Pro	**93**	89.9	-
Remote Labor Index	**41.3**	21.3	20.8
GDPval-AA v2.1 (Elo)	-	**1846**	1542
Toolathlon-Verified	-	77.8	-
MRCR v2 256K-512K	-	-	100
MRCR v2 512K-1M	-	-	96.3
GraphWalks BFS 256K-1M	-	66.8	**71.8**
HealthBench Hard	-	-	36.6
Global-MMLU	**96**	94.3	-
NYT Connections	97.3	-	-
Chess puzzles (Epoch)	79	-	-
MathVis (Fable 5, 5.2 ではない)	26.56	-	**31.25**
ExploitGym	-	33.3	**42.4**
CritPt v2 ハード部分集合 (AA)	**77**	-	72
SciCode (AA)	-	66.9	-
Gray Swan IPI, 低いほど良い	-	**1**	8.5
Vending-Bench 2 (最終ドル)	-	-	$15,515
SpireClimb	19.6	-	-

第五節

全ベンチマークの一覧

主流の網羅調査と、奇抜なものを集めた調査から、合計 270 件のベンチマークを挙げた。読めたページにスコアがあるのは 61 件で、残る 209 件はスコアなしで掲げた。表示したモデルは、数値を見つけられた最新または最上位のモデルであり、必ずしも現存する最新のモデルではない。リーダーボードが示すのはその首位であり、日付のないページや到達できないページも多かった。結果のないベンチマークは各見出しの下にまとめた。見つけられなかったという意味で、存在しないという意味ではない。

集計サイト・リーダーボード

7 / 19

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Artificial Analysis Intelligence Index	Claude Fable 5.2 (max)	65	v5。Opus 5.5 は 59、Astra は 57

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Epoch Capabilities Index (ECI)	Claude Fable 5.2	174	
Epoch Benchmarking Hub	Claude Fable 5.2	ECI 174	ECI を参照
FrontierMath (Tiers 1-4, v2)	Claude Fable 5.2	T1-3 95.1%・T4 100.0%	BenchLM。Astra は 93.7 / 97.6
LiveBench	gpt-5.5-xhigh	81.28	2026-06-10 時点。Fable 5 xhigh は 78.57
Scale SEAL	Claude Fable 5.2	41.3%（Remote Labor Index）	
Vals AI (Vals Index)	Claude Fable 5.2 (High)	71.31%	36 モデル中 1 位。Astra は 65.02

結果なし： LMArena、OpenCompass、BenchLM、BenchmarkList、Codesota、llm-stats、HELM、Open LLM Leaderboard v2、BFCL、OpenRouter rankings、AIMultiple 200+、Snorkel Open Benchmarks Grants

知識と推論

7 / 11

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
MMLU-Pro	Sakana Namazu	90.33%	2026-08-11 時点
GPQA Diamond	GPT-6 Astra	96.0%	BenchLM
Humanity's Last Exam	Claude Fable 5.2	74.2%（ツールあり）	Opus 5.5 は 67.7、Astra は 57.2
CritPt	Claude Fable 5.2	77%（v2 ハード部分集合）	AA。Astra は 72%
ARC-AGI-1	Opus 5.5 / GPT-6 Astra	97.5%	同点
ARC-AGI-2	GPT-6 Astra (Max)	95%	Opus 5.5（High）は 93.33
ARC-AGI-3	GPT-6 Astra	99.9% アダプタ・62.7% 標準	ハーネスに依存

結果なし： MMLU、HLE-Diamond (AA)、FrontierScience、SimpleBench

数学

2 / 11

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
AIME 2025	GPT-5.2 (xhigh)	99%	2026-06-10 時点。飽和
ArXivMath (Aug 2026)	Claude Opus 5.5	96.9% ツールあり・91.2% ツールなし	Fable 5.1 は 92.1 / 82.9

結果なし： HMMT、MATH-500、GSM8K、USAMO 2026、IMO-ProofBench / AnswerBench、Putnam-Bench、OlympiadBench、ProofBench、MathArena

コーディング

9 / 17

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
SWE-bench Pro	Claude Fable 5.2 (max)	93.0%	Opus 5.5 は 89.9
SWE-bench Multilingual	Claude Fable 5.2	96.6%	
SWE-bench Multimodal	Claude Fable 5.2	74.1%	
Terminal-Bench 4.0	Claude Fable 5.2 (max)	67.6%	Opus 5.5 は 66.4、Astra は 57.9
SciCode	Claude Opus 5.5 (max)	66.9%	AA v4.3
CursorBench 4.0	Claude Fable 5.2	60.0%	Opus 5.5 は 57.8（max）
FrontierCode 2.0	Claude Fable 5.2 (xhigh)	49.1%	リーダーボード最高は Opus 5.5 max の 45.45
FrontierSWE v2	Claude Fable 5.2	69.9%	
DeepSWE	Claude Fable 5.2	74.3%	Opus は 74.2、Astra は 74.1

結果なし： SWE-bench Verified、Terminal-Bench 2.1 (Vals)、LiveCodeBench、Aider Polyglot、HumanEval、SWE-Lancer、MLE-bench、CRUXEval

エージェントとコンピュータ操作

10 / 16

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
OSWorld (Verified)	Pointer Agent w/ Opus 4.7	83.64%	2026-05-27 時点
OSWorld 2.0	GPT-6 Astra	72.6%	BenchLM
OSWorld 2.1	Claude Fable 5.2	89.3%（オフライン・部分点）	Opus 5.5 は 87.2、Astra は 79.5
Toolathlon	Claude Opus 5.5	77.8%（Verified）	
GDPval-AA	Claude Opus 5.5 (max)	1846 Elo	Astra は 1542。ある情報源では Fable 5.2 が 1831
Remote Labor Index	Claude Fable 5.2 (high)	41.3%	Opus は 21.3、Astra は 20.8
Vending-Bench 2	GPT-6 Astra	$15,515 最終	2026-10-03 時点
BrowseComp	Nex-N2.5-Max	92.6%	Astra は 91.5。最新の掲載は Inkling 2 Small の 90.2
DRACO	Claude Fable 5.2	87.7%	
AutomationBench	Claude Fable 5.2	51.4%	Opus 5.5 は 42.5、Astra は 41.4

結果なし： WebArena、tau-bench / tau2-bench、Agents' Last Exam、GAIA、MedBrowseComp、PaperBench

長い文脈

2 / 12

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
MRCR v2 (8-needle)	GPT-6 Astra	100% @256K-512K・96.3% @512K-1M	BenchLM
Graphwalks	GPT-6 Astra	71.8%（BFS 256K〜1M）	Opus 5.5 は 66.8

結果なし： OpenAI-MRCR、RULER、NIAH / NIAH-2、LongBench v1/v2、NoLiMa、BABILong、AA-LCR、HELMET、NoCha、Michelangelo

事実性

2 / 10

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
SimpleQA	Gemini 3.1 Pro (high)	77.3%	Fable 5（max）は 68.3。2026-07-15 時点
AA-Omniscience	Claude Opus 5.5 (max)	48（v1.1 指数）	AA v5

結果なし： SimpleQA Verified、FACTS、Vectara HHEM、HalluHard、PersonQA、TruthfulQA、FActScore、LongFact

指示追従と対話

1 / 10

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
IFEval	Kimi-K2.6	94.5	自己申告、2026-06-08

結果なし： IFBench、Multi-IF、MT-Bench、Arena-Hard、AlpacaEval、WildBench、EQ-Bench、WritingBench、RewardBench

医学

3 / 11

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
HealthBench	Claude Opus 5.5	68.1% 素点	Astra は 56.9
HealthBench Hard	GPT-6 Astra	36.6%	
HealthBench Professional	Claude Opus 5.5	65.6%	Astra は 64.7

結果なし： MedQA、MedMCQA、PubMedQA、MedXpertQA、MedHELM、MEDEC、MedVH、CREOLA

法律・金融・科学

1 / 17

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Terminal-Bench-Science	Claude Fable 5.2	74.6%	Opus 5.5 は 58.7、Astra は 68.1

結果なし： LegalBench、LawBench、LexEval、CaseLaw v2、Legal Research Bench、HLAB、FinanceBench、Finance Agent v2、EMB、CorpFin、TaxEval、Tax Agent Bench、LAB-Bench、ScienceAgentBench、HLE-Physics、CMT-Benchmark

多言語

1 / 10

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Global-MMLU	Claude Fable 5.2	96.0%	Lite と full は区別されていない

結果なし： MMLU-ProX、INCLUDE、MGSM、Belebele、AfriMMLU / AfriXNLI、MuBench、MultiLoKo、BenchMax、FLORES-200

マルチモーダル

0 / 13

結果なし： MMMU / MMMU-Pro、MathVista、ChartQA、DocVQA、RealWorldQA、OCRBench、ScreenSpot-Pro、Video-MME / v2、MLVU、LVBench、MMVU、EgoSchema、VideoMMMU

生成メディア

0 / 11

結果なし： Image arenas (LMArena)、GenEval、GenAI-Bench / GenAI-Arena、HEIM、T2I-CompBench、Imagine-Bench、EditScore、Gen-Arena、VBench、EvalCrafter、VideoGen-Reward

音声と埋め込み

0 / 7

結果なし： Open ASR Leaderboard、FFASR / ESB / LibriSpeech / FLEURS、Seed-TTS、Real World VoiceEQ、MMAU / MMAR、MTEB / MMTEB / MIEB、MAEB / MAEB+

ロボティクス

1 / 6

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
RoboDojo Sim	Claude Fable 5.2	64.9%	Opus 5.5 は 39.4、Astra は 29.8

結果なし： LIBERO (+Plus/-X/-PRO/-PeRM)、CALVIN、SimplerEnv、vla-eval harness、NativeEmbodied

自律性とサイバー

3 / 15

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
ExploitGym	GPT-6 Astra	42.4%	Opus 5.5 は 33.3
ExploitBench (V8)	GPT-6 Astra	100%	二次情報
CVE Rediscovery	Claude Mythos 5.2	89.6%	Opus 5.5 は 81.3

結果なし： METR time horizons (HCAST, RE-Bench, SWAA)、MirrorCode / expenditure horizon、RE-Bench、Cybench、NYU CTF、CVE-Bench、BountyBench、CyberGym、AISI cyber ranges、CAIBench、SEC-bench、BaxBench

安全性とアライメント

1 / 15

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Gray Swan IPI	GPT-6 Astra	8.5%（15 回試行）	Opus 5.5 は 1.0%。低いほど良い

結果なし： HarmBench、JailbreakBench、StrongREJECT、AILuminate、AIR-Bench、AgentHarm、WMDP / BioLP-Bench / VCT、XSTest、AgentDojo、MASK、Apollo scheming suite / Bloom / Petri、SycEval、MACHIAVELLI、BIG-Bench HHH

古代文字

1 / 7

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
TokenAI Hieroglyphic AI Benchmark	TokenAI model	~90% 全体	ベンダー申告

結果なし： Hemauer Egyptian/Luwian evaluation、Reasoning Over the Glyphs、Ancient logographic benchmark (EGY/AKK/ZHO/Linear A)、HieroLM、Dongba pictogram study、Falsifiability Sheet pilot

言語学パズル

0 / 5

結果なし： LingOly、Linguini、IOLBench / LOBSTER / LingBench++、PuzzLing Machines / modeLing、Rosetta-to-Match-Up corpus

難解言語

1 / 1

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
EsoLang-Bench	GPT-5.2	3.8% 最高	Python は 100%。全体では 0〜11%

ゲーム

3 / 5

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
BALROG	Gemini 3	29.5% 進捗	2026-05-29 時点。NetHack は 1.6%
Kaggle Game Arena (chess)	Gemini 3 Pro Preview	Elo 1325	Gemini 3 Flash は 1297
InfiniteBM Chess	Claude Opus 4.7	Elo 1997.5	16 局のみ

結果なし： Kaggle Game Arena (poker / Werewolf)、Pokemon Agent Challenge

社会性と心の理論

0 / 5

結果なし： Werewolf Arena / WOLF / Triadic Werewolf、MafiaScope / MIVA、Decrypto / Avalon-ToM-Bench、SOTOPIA / Hi-ToM / FANToM / ToMi、MACHIAVELLI

未解決数学と形式証明

1 / 8

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
FrontierMath Erdős	GPT-6 Astra	3%	未解決問題 68 件、固定予算

結果なし： FrontierMath: Open Problems / HorizonMath、Formal Conjectures、miniF2F、PutnamBench、ProverBench、ProofNet / CombiBench / FormalMATH、FormalProofBench / SorryDB

パズル

3 / 5

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
NYT Connections	Claude Fable 5.2	97.3%	
Sudoku-Bench		<15% 最高	ツールなしの実行、古いモデル
InsanityBench		~10% 最高	投稿時点

結果なし： Cryptic crosswords / puzzlehunts / PuzzlePlex、Riddles / lateral thinking sets

空間と物理

0 / 5

結果なし： BuildArena、GRASP / FloorplanQA / SPhyR、3DSRBench / OpenBench / SpatialEval、GeoBench (GeoGuessr)、PHYRE / Physion / IntPhys / CLEVRER / PIQA

ニッチな科学

0 / 3

結果なし： PG-LLM (protein variants)、ChemBench、SciKnowEval / SFE / SDE

トークン化の癖

0 / 2

結果なし： CharBench、TASE / Strawberry Problem set

ユーモア・創造性・音楽

0 / 4

結果なし： Oogiri-Master、LoTbench、MusiXQA / ABC-Eval、Pelican on a bicycle

振る舞いと健全性

2 / 5

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Spiral-Bench	GPT-5	87	DeepSeek-R1-0528 は 22.4
SAD (situational awareness)	Claude 3.5 Sonnet	54%	2024 年の結果

結果なし： DelusionEval、ELEPHANT / SnitchBench、Model-welfare self-report work

倫理と価値観

0 / 2

結果なし： TrolleyBench / MoralBench / MOSAIC、MultiTP / GlobalOpinionQA / PRISM / ETHICS

予測

0 / 2

結果なし： Prophet Arena、Prediction Arena / ForecastBench / ForecastQA

出典

一次データ。 Anthropic の発表ページと Claude Opus 5.5 のシステムカード、OpenAI の GPT-6 Astra の資料、Artificial Analysis（Intelligence Index v5 とエフォート別の内訳）、ARC Prize の結果、Epoch AI（ECI、FrontierMath）、Vals AI、Hex の DataBench の解説、ベンチマーク別のスコアについては BenchLM の比較ページと benchmarklist.com のリーダーボード。

確認したこと。 すべての数値は開けたページから読み取り、推定や補間はしていない。二つの情報源が食い違う場合は両方の値を載せた。

確認できなかったこと。 エフォート別のデータがあるモデルとベンチマークの組はごくわずかで、ここでの階梯の大半は二点から四点しかない。集計サイトの数値には一次ページの裏付けがないものもある。公式リーダーボードの多くはクライアント側で描画されて何も返さなかったため、一覧ではそれらのベンチマークは結果なしとなっている。