ベンチマーク・アトラス / 2026年11月12日

Fable 5.2、Opus 5.5、GPT-6 Astra をベンチマークごとに比べる

自分の調査リスト二本にあるベンチマークから、Claude Fable 5.2、Claude Opus 5.5、GPT-6 Astra の公表済みの結果をすべて集めた。少なくとも二つのモデルに数値がある 33 件のうち、最高点は Fable 5.2 が 28 件、Opus 5.5 が 3 件、Astra が 2 件である。エフォートの設定別データはそれよりずっと薄い。多くの研究所は最大設定の値しか公表しないからだ。

数値の読み方

数値の大半は、評価を実施した研究所が出した最大エフォートのスコアである。スコアはハーネス、部分点か厳密採点か、指数のバージョンによって動くため、二つの値が見つかった場合は両方を示した。ダッシュは公表済みの結果を見つけられなかったという意味であり、存在しないという意味ではない。

第一節

誰が、どれだけ先行しているか

少なくとも二つのモデルに公表値がある 33 件のベンチマークのうち、Fable 5.2 が最高点を取ったのは 28 件である。差が大きいのは長期的でエージェント的な課題で、Remote Labor Index では Fable 5.2 が 41.3、Opus 5.5 が 21.3、Astra が 20.8、RoboDojo では 64.9 に対し 39.4 と 29.8 である。飽和した数学では差が小さく、FrontierMath ティア 4 は 100、95、97.6 となる。Opus 5.5 が先行するのは PhysicianBench（68.4）と ProgramBench（91.2）、Astra が先行するのは ARC-AGI-2（95 対 93.3）である。



図 1. エージェントとコンピュータ操作。OSWorld 2.1 はオフライン・部分点の変種で、厳密採点の値はこれより低い（食い違いの表を参照）。

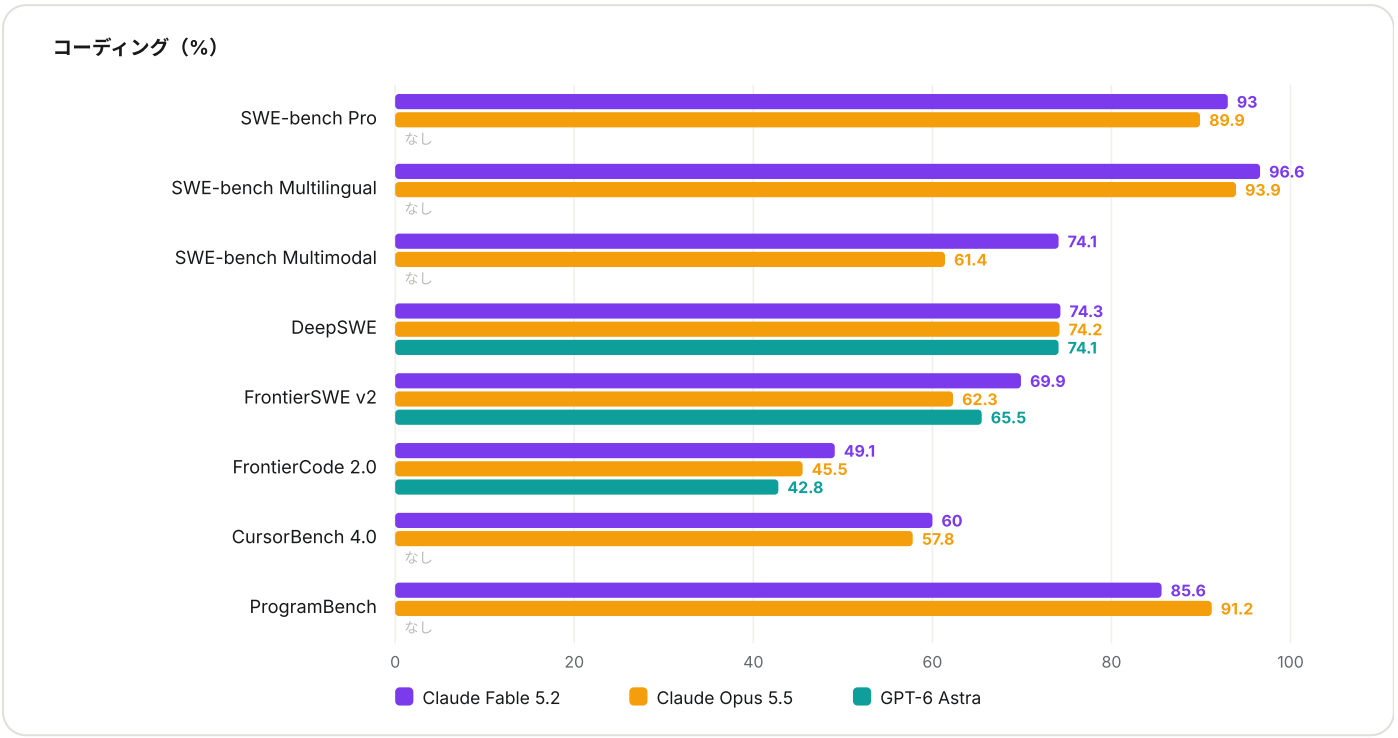


図 2. コーディング。FrontierCode 2.0 は各モデルの公表済みの最良の実行で、ハーネスは研究所ごとに異なる。

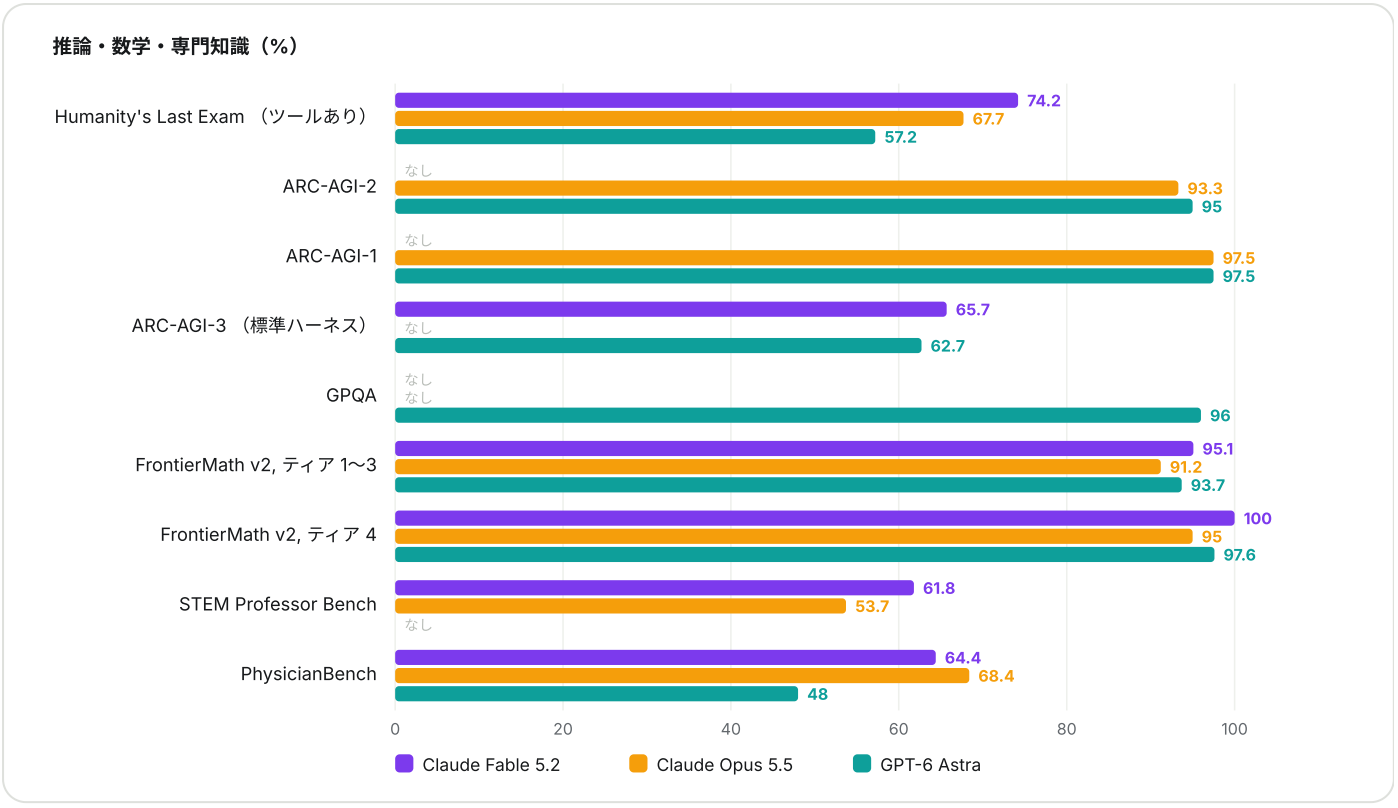


図 3. 推論・数学・専門知識。ARC-AGI-3 は標準ハーネスの値で、プロバイダ・アダプタ・ハーネスでは両モデルとも大きく上がる。

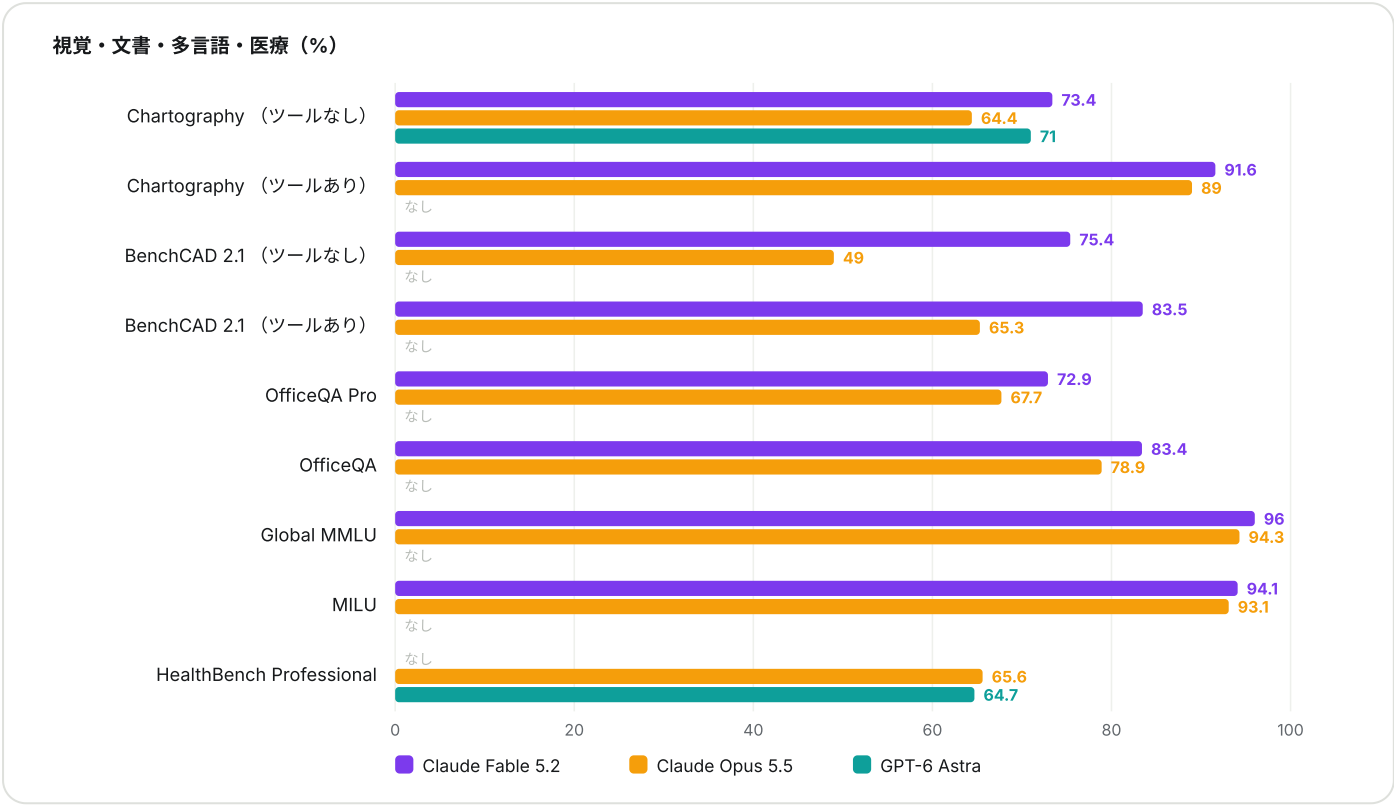


図 4. 視覚・文書・多言語・医療。

第二節

エフォート設定で何が買えるか

三つのうち五つの設定すべてで曲線が公表されているのは Fable 5.2 だけで、Artificial Analysis の Intelligence Index で low の 54 から max の 65 まで上がる。ただし一様ではない。low から high までは 1 タスクあたり約 11 分の追加で 8 ポイント上がるが、high から max までは約 28 分の追加で 3 ポイントしか上がらない。high と xhigh は 62 で並ぶので、この指数では xhigh が買うのは点数ではなく時間である。Opus 5.5 は low の 35 から max の 58 までで、Artificial Analysis は medium、high、xhigh をコスト対品質のフロンティア上に載せているが、数値は示していない。Astra は max の 57 だけが公表されている。

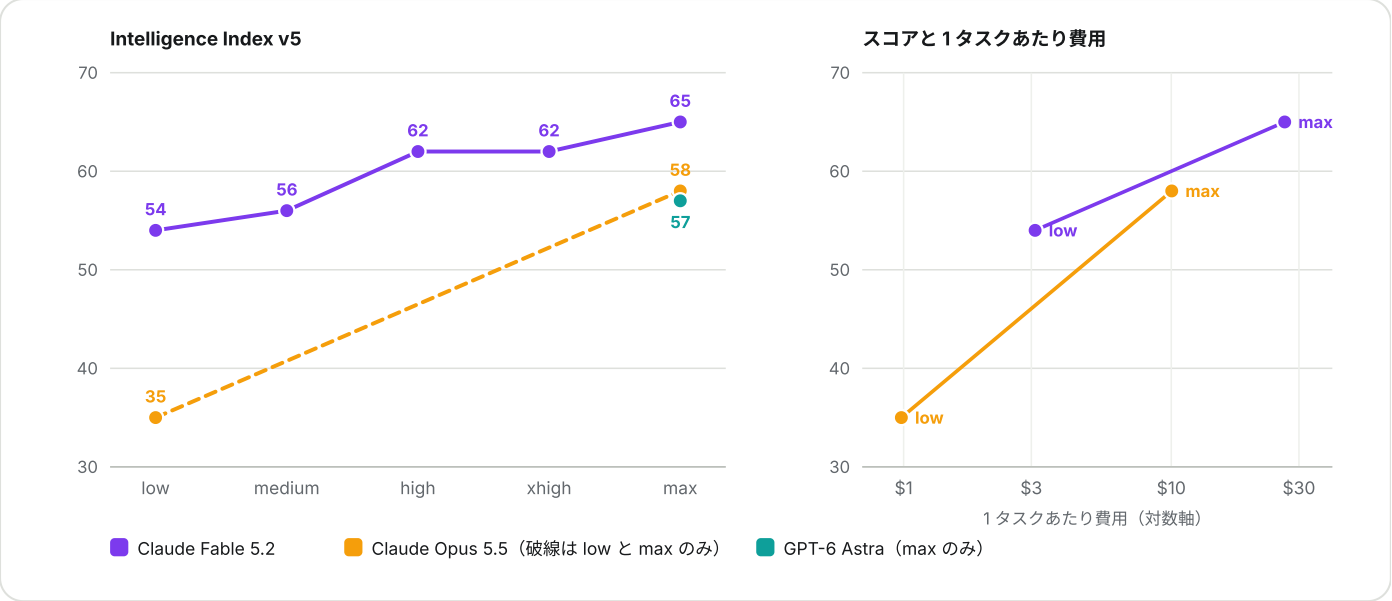


図 5. エフォート設定別の Artificial Analysis Intelligence Index v5（左）と、1 タスクあたり費用に対するスコア（右）。Opus 5.5 は Artificial Analysis の発表記事では 58、v5 のリーダーボードでは 59 だが、ここでは 58 を描いた。

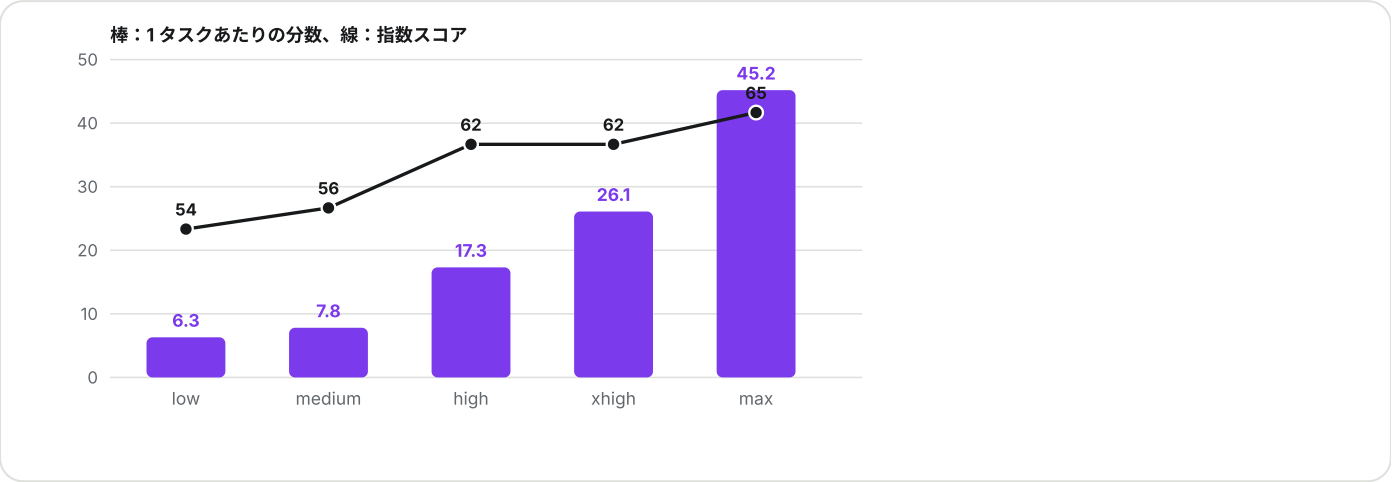


図 6. 同じ指数での Fable 5.2。1 タスクあたり費用は low の約 3.10 ドルから max の約 26.50 ドルまで増える。

ARC-AGI-3

Astra はここで全段階の値が揃っており、エフォート設定よりもハーネスの影響のほうが大きい。標準ハーネスでは low の 17.5% から max の 62.7% まで着実に上がり、推論なしの実行は 35.2% である。プロバイダ・アダプタ・ハーネスでは、どの設定でも 96.7% から 99.9% に収まる。どちらでも、エフォートが高いほうが一回の実行費用は安い。無駄な手数が減るためである。Fable 5.2 については、ある情報源が 65.7%（標準）と 94.9%（アダプタ）を載せ、別の情報源が異なる保存値を載せているので、この値は確定していないものとして扱う。

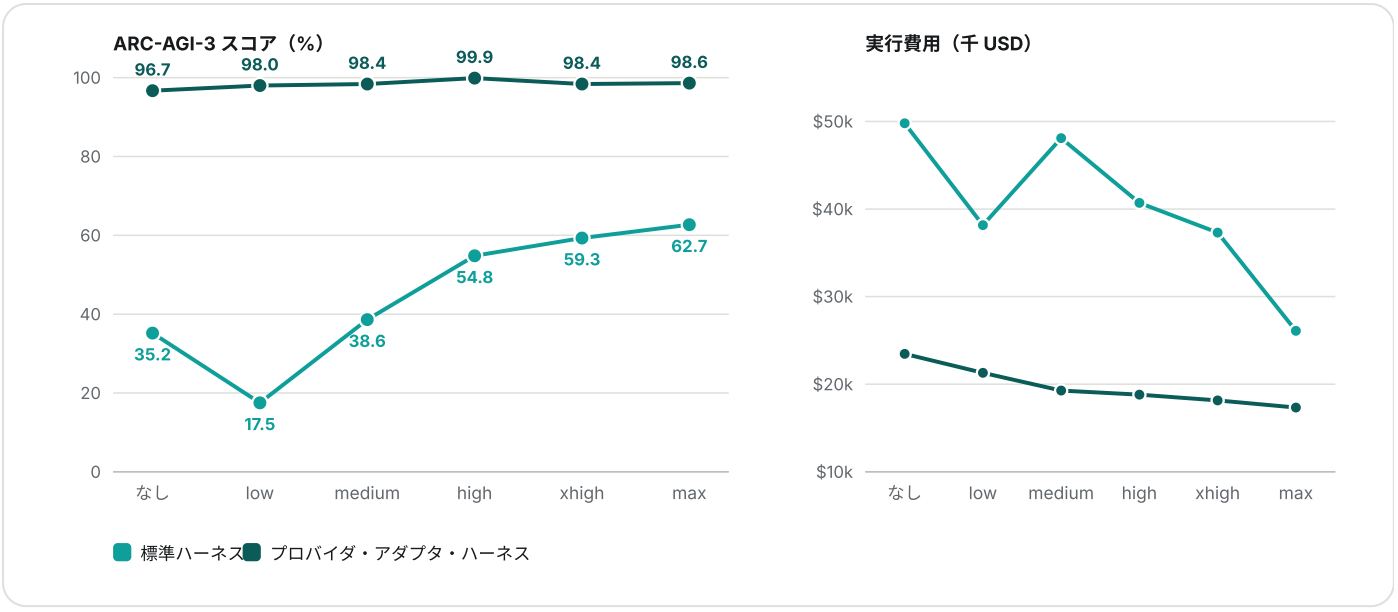


図 7. ARC-AGI-3（セミプライベート）での GPT-6 Astra。二つのハーネスでのエフォート別スコア（左）と、各実行の総費用（右）。

コーディング、専門試験、データ分析

これらの階梯は短く、ハーネスも異なる。Opus 5.5 は Claude Code、Astra は Codex で動かされ、Fable 5.2 の FrontierCode の点は Anthropic 自身の実行によるものだ。FrontierCode 2.0 では、Opus 5.5 が xhigh で 43.4、max で 45.5、Astra が high から max まで 38.3、41.4、42.8、Fable 5.2 が high で 45.3、xhigh で 49.1（1 タスク 6.72 ドルと 14.19 ドル）である。CursorBench 4.0 では Opus 5.5 が medium の 52.5 から max の 57.8 まで上がり、high と xhigh は 56.0 で横ばいになる。Artificial Analysis の実行での Humanity's Last Exam では、Opus 5.5 が xhigh の 57.5 から max の 61.4 へ跳ね上がる一方、Fable 5.1 は 58.7 から 59.1 とほとんど動かない。

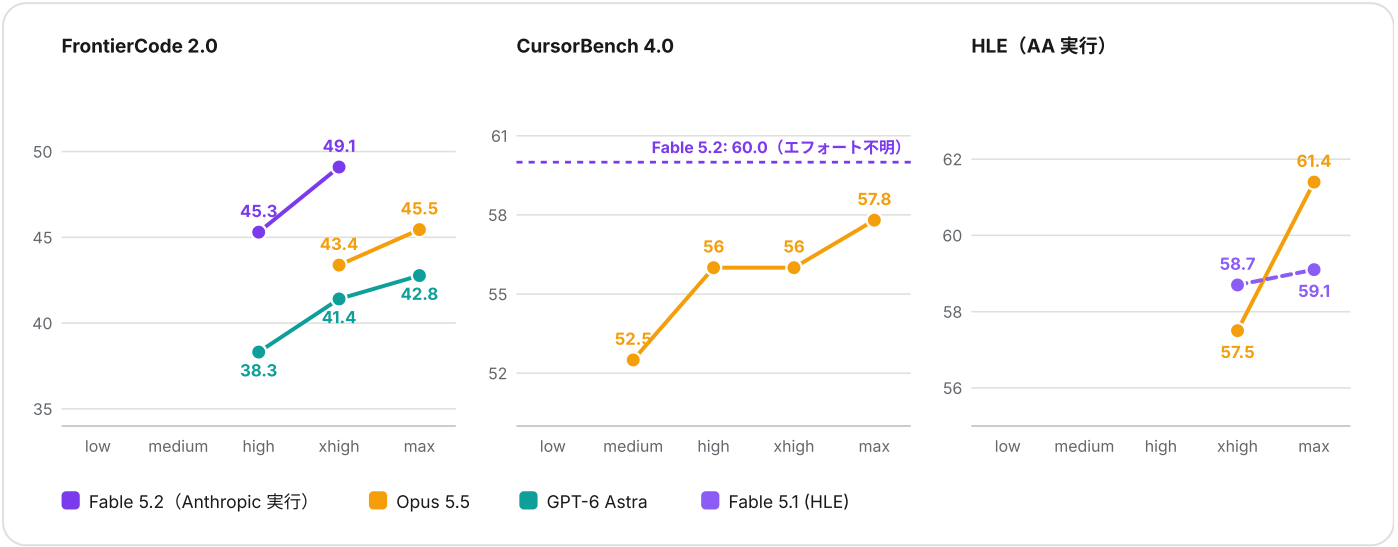


図 8. FrontierCode 2.0、CursorBench 4.0、Humanity's Last Exam のエフォート階梯。

さらに二つのデータは、エフォートを上げれば常に有利だという想定に反する。Hex DataBench v1.1 の Astra は low で 55.0、max で 55.0 と同じで、high では 52.0 に下がる。44 問の数学の検証では、medium が 98.9%、high が 97.7% で、95% 区間は重なる。算術の問いはどの設定でも正解で、出力トークンは 546 から 1,422 に増えた。Chartography（ツールなし）の Fable 5.2 は medium の 66.4 から max の 73.4 に伸び、Opus 5.5 は 64.4、Astra は 71.0 である。

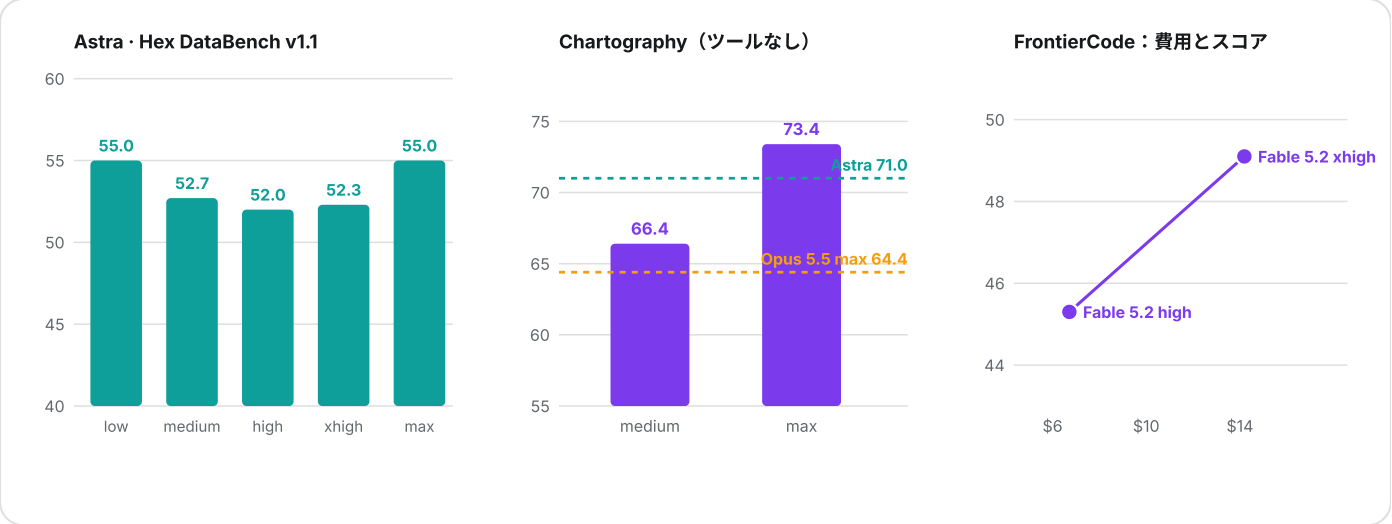


図 9. エフォート別の Astra の Hex DataBench v1.1（左）、ツールなしの Chartography（中央）、Fable 5.2 の FrontierCode の費用とスコア（右）。

第三節

情報源が食い違う箇所

同じベンチマークに二つの公表値があることは多い。ハーネス、部分点か厳密採点か、指数のバージョン、あるいは集計サイトが別の実行を保存していることが理由である。どちらかを選ばず、両方を残した。集計サイトのページには他のモデルの文書を出典にしているものもあるため、一次ページと一致するまでは集計サイトの値を主張として扱う。Opus 5.5 のサイバー関連の値は安全策なしで測定されたもので、Fable 5.2 は安全策を備え、特定の要求では既定のモデルに切り替わる。これはツールなしの比較に影響する。

ベンチマーク	値 A	値 B
ARC-AGI-3、Fable 5.2	65.7（標準）/ 94.9（アダプタ）	79.26 / 97.72（ある集計サイトの保存値）
OSWorld 2.1、Fable 5.2	89.3（オフライン・部分点）	54.6（厳密採点）
GDPval-AA、Opus 5.5（Elo）	1846	1866
Terminal-Bench 4.0、Opus 5.5	66.4（Anthropic、xhigh）	59.6（Artificial Analysis の実行）
AA-Briefcase Elo、Opus 5.5	1800	1822
Terminal-Bench-Science、Astra	68.1（Anthropic の表、benchmarklist）	64.6（BenchLM）/ 62.86（Vals）
AA Intelligence Index、Opus 5.5	58（発表記事）	59（v5 のリーダーボード）

第四節

カバー範囲

調査リストのうち、三つのモデルの少なくとも一つに公表値があるベンチマークをすべて並べた。ダッシュは未確認の意味。太字はその行の最良値で、低いほうが良い項目はその旨を記した。

ベンチマーク	FABLE 5.2	OPUS 5.5	GPT-6 ASTRA
ARC-AGI-1	-	**97.5**	**97.5**
ARC-AGI-2	-	93.3	**95**
ARC-AGI-3 （標準）	**65.7**	-	62.7
ARC-AGI-3 (プロバイダ・アダプタ)	94.9	-	**98.6**
Humanity's Last Exam （ツールあり）	**74.2**	67.7	57.2
GPQA	-	-	96

ベンチマーク	FABLE 5.2	OPUS 5.5	GPT-6 ASTRA
FrontierMath v2 ティア 4	**100**	95	97.6
FrontierMath Erdős (未解決問題)	-	-	3
BrowseComp	-	-	91.5
OSWorld 2.0	-	48.7	**72.6**
OSWorld 2.1	**89.3**	87.2	79.5
Terminal-Bench 4.0	**67.6**	66.4	57.9
Terminal-Bench-Science	**74.6**	58.7	68.1
SWE-bench Pro	**93**	89.9	-
Remote Labor Index	**41.3**	21.3	20.8
GDPval-AA v2.1 (Elo)	-	**1846**	1542
Toolathlon-Verified	-	77.8	-
MRCR v2 256K-512K	-	-	100
MRCR v2 512K-1M	-	-	96.3
GraphWalks BFS 256K-1M	-	66.8	**71.8**
HealthBench Hard	-	-	36.6
Global-MMLU	**96**	94.3	-
NYT Connections	97.3	-	-
Chess puzzles (Epoch)	79	-	-
MathVis (Fable 5, 5.2 ではない)	26.56	-	**31.25**
ExploitGym	-	33.3	**42.4**
CritPt v2 ハード部分集合 (AA)	**77**	-	72
SciCode (AA)	-	66.9	-
Gray Swan IPI, 低いほど良い	-	**1**	8.5
Vending-Bench 2 (最終ドル)	-	-	$15,515
SpireClimb	19.6	-	-

第五節

全ベンチマークの一覧

主流の網羅調査と、奇抜なものを集めた調査から、合計 270 件のベンチマークを挙げた。読めたページにスコアがあるのは 61 件で、残る 209 件はスコアなしで掲げた。表示したモデルは、数値を見つけられた最新または最上位のモデルであり、必ずしも現存する最新のモデルではない。リーダーボードが示すのはその首位であり、日付のないページや到達できないページも多かった。結果のないベンチマークは各見出しの下にまとめた。見つけられなかったという意味で、存在しないという意味ではない。

集計サイト・リーダーボード

7 / 19

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Artificial Analysis Intelligence Index	Claude Fable 5.2 (max)	65	v5。Opus 5.5 は 59、Astra は 57

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Epoch Capabilities Index (ECI)	Claude Fable 5.2	174	
Epoch Benchmarking Hub	Claude Fable 5.2	ECI 174	ECI を参照
FrontierMath (Tiers 1-4, v2)	Claude Fable 5.2	T1-3 95.1%・T4 100.0%	BenchLM。Astra は 93.7 / 97.6
LiveBench	gpt-5.5-xhigh	81.28	2026-06-10 時点。Fable 5 xhigh は 78.57
Scale SEAL	Claude Fable 5.2	41.3%（Remote Labor Index）	
Vals AI (Vals Index)	Claude Fable 5.2 (High)	71.31%	36 モデル中 1 位。Astra は 65.02

結果なし： LMArena、OpenCompass、BenchLM、BenchmarkList、Codesota、llm-stats、HELM、Open LLM Leaderboard v2、BFCL、OpenRouter rankings、AIMultiple 200+、Snorkel Open Benchmarks Grants

知識と推論

7 / 11

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
MMLU-Pro	Sakana Namazu	90.33%	2026-08-11 時点
GPQA Diamond	GPT-6 Astra	96.0%	BenchLM
Humanity's Last Exam	Claude Fable 5.2	74.2%（ツールあり）	Opus 5.5 は 67.7、Astra は 57.2
CritPt	Claude Fable 5.2	77%（v2 ハード部分集合）	AA。Astra は 72%
ARC-AGI-1	Opus 5.5 / GPT-6 Astra	97.5%	同点
ARC-AGI-2	GPT-6 Astra (Max)	95%	Opus 5.5（High）は 93.33
ARC-AGI-3	GPT-6 Astra	99.9% アダプタ・62.7% 標準	ハーネスに依存

結果なし： MMLU、HLE-Diamond (AA)、FrontierScience、SimpleBench

数学

2 / 11

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
AIME 2025	GPT-5.2 (xhigh)	99%	2026-06-10 時点。飽和
ArXivMath (Aug 2026)	Claude Opus 5.5	96.9% ツールあり・91.2% ツールなし	Fable 5.1 は 92.1 / 82.9

結果なし： HMMT、MATH-500、GSM8K、USAMO 2026、IMO-ProofBench / AnswerBench、Putnam-Bench、OlympiadBench、ProofBench、MathArena

コーディング

9 / 17

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
SWE-bench Pro	Claude Fable 5.2 (max)	93.0%	Opus 5.5 は 89.9
SWE-bench Multilingual	Claude Fable 5.2	96.6%	
SWE-bench Multimodal	Claude Fable 5.2	74.1%	
Terminal-Bench 4.0	Claude Fable 5.2 (max)	67.6%	Opus 5.5 は 66.4、Astra は 57.9
SciCode	Claude Opus 5.5 (max)	66.9%	AA v4.3
CursorBench 4.0	Claude Fable 5.2	60.0%	Opus 5.5 は 57.8（max）
FrontierCode 2.0	Claude Fable 5.2 (xhigh)	49.1%	リーダーボード最高は Opus 5.5 max の 45.45
FrontierSWE v2	Claude Fable 5.2	69.9%	
DeepSWE	Claude Fable 5.2	74.3%	Opus は 74.2、Astra は 74.1

結果なし： SWE-bench Verified、Terminal-Bench 2.1 (Vals)、LiveCodeBench、Aider Polyglot、HumanEval、SWE-Lancer、MLE-bench、CRUXEval

エージェントとコンピュータ操作

10 / 16

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
OSWorld (Verified)	Pointer Agent w/ Opus 4.7	83.64%	2026-05-27 時点
OSWorld 2.0	GPT-6 Astra	72.6%	BenchLM
OSWorld 2.1	Claude Fable 5.2	89.3%（オフライン・部分点）	Opus 5.5 は 87.2、Astra は 79.5
Toolathlon	Claude Opus 5.5	77.8%（Verified）	
GDPval-AA	Claude Opus 5.5 (max)	1846 Elo	Astra は 1542。ある情報源では Fable 5.2 が 1831
Remote Labor Index	Claude Fable 5.2 (high)	41.3%	Opus は 21.3、Astra は 20.8
Vending-Bench 2	GPT-6 Astra	$15,515 最終	2026-10-03 時点
BrowseComp	Nex-N2.5-Max	92.6%	Astra は 91.5。最新の掲載は Inkling 2 Small の 90.2
DRACO	Claude Fable 5.2	87.7%	
AutomationBench	Claude Fable 5.2	51.4%	Opus 5.5 は 42.5、Astra は 41.4

結果なし： WebArena、tau-bench / tau2-bench、Agents' Last Exam、GAIA、MedBrowseComp、PaperBench

長い文脈

2 / 12

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
MRCR v2 (8-needle)	GPT-6 Astra	100% @256K-512K・96.3% @512K-1M	BenchLM
Graphwalks	GPT-6 Astra	71.8%（BFS 256K〜1M）	Opus 5.5 は 66.8

結果なし： OpenAI-MRCR、RULER、NIAH / NIAH-2、LongBench v1/v2、NoLiMa、BABILong、AA-LCR、HELMET、NoCha、Michelangelo

事実性

2 / 10

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
SimpleQA	Gemini 3.1 Pro (high)	77.3%	Fable 5（max）は 68.3。2026-07-15 時点
AA-Omniscience	Claude Opus 5.5 (max)	48（v1.1 指数）	AA v5

結果なし： SimpleQA Verified、FACTS、Vectara HHEM、HalluHard、PersonQA、TruthfulQA、FActScore、LongFact

指示追従と対話

1 / 10

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
IFEval	Kimi-K2.6	94.5	自己申告、2026-06-08

結果なし： IFBench、Multi-IF、MT-Bench、Arena-Hard、AlpacaEval、WildBench、EQ-Bench、WritingBench、RewardBench

医学

3 / 11

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
HealthBench	Claude Opus 5.5	68.1% 素点	Astra は 56.9
HealthBench Hard	GPT-6 Astra	36.6%	
HealthBench Professional	Claude Opus 5.5	65.6%	Astra は 64.7

結果なし： MedQA、MedMCQA、PubMedQA、MedXpertQA、MedHELM、MEDEC、MedVH、CREOLA

法律・金融・科学

1 / 17

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Terminal-Bench-Science	Claude Fable 5.2	74.6%	Opus 5.5 は 58.7、Astra は 68.1

結果なし： LegalBench、LawBench、LexEval、CaseLaw v2、Legal Research Bench、HLAB、FinanceBench、Finance Agent v2、EMB、CorpFin、TaxEval、Tax Agent Bench、LAB-Bench、ScienceAgentBench、HLE-Physics、CMT-Benchmark

多言語

1 / 10

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Global-MMLU	Claude Fable 5.2	96.0%	Lite と full は区別されていない

結果なし： MMLU-ProX、INCLUDE、MGSM、Belebele、AfriMMLU / AfriXNLI、MuBench、MultiLoKo、BenchMax、FLORES-200

マルチモーダル

0 / 13

結果なし： MMMU / MMMU-Pro、MathVista、ChartQA、DocVQA、RealWorldQA、OCRBench、ScreenSpot-Pro、Video-MME / v2、MLVU、LVBench、MMVU、EgoSchema、VideoMMMU

生成メディア

0 / 11

結果なし： Image arenas (LMArena)、GenEval、GenAI-Bench / GenAI-Arena、HEIM、T2I-CompBench、Imagine-Bench、EditScore、Gen-Arena、VBench、EvalCrafter、VideoGen-Reward

音声と埋め込み

0 / 7

結果なし： Open ASR Leaderboard、FFASR / ESB / LibriSpeech / FLEURS、Seed-TTS、Real World VoiceEQ、MMAU / MMAR、MTEB / MMTEB / MIEB、MAEB / MAEB+

ロボティクス

1 / 6

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
RoboDojo Sim	Claude Fable 5.2	64.9%	Opus 5.5 は 39.4、Astra は 29.8

結果なし： LIBERO (+Plus/-X/-PRO/-PeRM)、CALVIN、SimplerEnv、vla-eval harness、NativeEmbodied

自律性とサイバー

3 / 15

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
ExploitGym	GPT-6 Astra	42.4%	Opus 5.5 は 33.3
ExploitBench (V8)	GPT-6 Astra	100%	二次情報
CVE Rediscovery	Claude Mythos 5.2	89.6%	Opus 5.5 は 81.3

結果なし： METR time horizons (HCAST, RE-Bench, SWAA)、MirrorCode / expenditure horizon、RE-Bench、Cybench、NYU CTF、CVE-Bench、BountyBench、CyberGym、AISI cyber ranges、CAIBench、SEC-bench、BaxBench

安全性とアライメント

1 / 15

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Gray Swan IPI	GPT-6 Astra	8.5%（15 回試行）	Opus 5.5 は 1.0%。低いほど良い

結果なし： HarmBench、JailbreakBench、StrongREJECT、AILuminate、AIR-Bench、AgentHarm、WMDP / BioLP-Bench / VCT、XSTest、AgentDojo、MASK、Apollo scheming suite / Bloom / Petri、SycEval、MACHIAVELLI、BIG-Bench HHH

古代文字

1 / 7

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
TokenAI Hieroglyphic AI Benchmark	TokenAI model	~90% 全体	ベンダー申告

結果なし： Hemauer Egyptian/Luwian evaluation、Reasoning Over the Glyphs、Ancient logographic benchmark (EGY/AKK/ZHO/Linear A)、HieroLM、Dongba pictogram study、Falsifiability Sheet pilot

言語学パズル

0 / 5

結果なし： LingOly、Linguini、IOLBench / LOBSTER / LingBench++、PuzzLing Machines / modeLing、Rosetta-to-Match-Up corpus

難解言語

1 / 1

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
EsoLang-Bench	GPT-5.2	3.8% 最高	Python は 100%。全体では 0〜11%

ゲーム

3 / 5

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
BALROG	Gemini 3	29.5% 進捗	2026-05-29 時点。NetHack は 1.6%
Kaggle Game Arena (chess)	Gemini 3 Pro Preview	Elo 1325	Gemini 3 Flash は 1297
InfiniteBM Chess	Claude Opus 4.7	Elo 1997.5	16 局のみ

結果なし： Kaggle Game Arena (poker / Werewolf)、Pokemon Agent Challenge

社会性と心の理論

0 / 5

結果なし： Werewolf Arena / WOLF / Triadic Werewolf、MafiaScope / MIVA、Decrypto / Avalon-ToM-Bench、SOTOPIA / Hi-ToM / FANToM / ToMi、MACHIAVELLI

未解決数学と形式証明

1 / 8

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
FrontierMath Erdős	GPT-6 Astra	3%	未解決問題 68 件、固定予算

結果なし： FrontierMath: Open Problems / HorizonMath、Formal Conjectures、miniF2F、PutnamBench、ProverBench、ProofNet / CombiBench / FormalMATH、FormalProofBench / SorryDB

パズル

3 / 5

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
NYT Connections	Claude Fable 5.2	97.3%	
Sudoku-Bench		<15% 最高	ツールなしの実行、古いモデル
InsanityBench		~10% 最高	投稿時点

結果なし： Cryptic crosswords / puzzlehunts / PuzzlePlex、Riddles / lateral thinking sets

空間と物理

0 / 5

結果なし： BuildArena、GRASP / FloorplanQA / SPhyR、3DSRBench / OpenBench / SpatialEval、GeoBench (GeoGuessr)、PHYRE / Physion / IntPhys / CLEVRER / PIQA

ニッチな科学

0 / 3

結果なし： PG-LLM (protein variants)、ChemBench、SciKnowEval / SFE / SDE

トークン化の癖

0 / 2

結果なし： CharBench、TASE / Strawberry Problem set

ユーモア・創造性・音楽

0 / 4

結果なし： Oogiri-Master、LoTbench、MusiXQA / ABC-Eval、Pelican on a bicycle

振る舞いと健全性

2 / 5

ベンチマーク	確認できた最新または最上位のモデル	スコア	備考
Spiral-Bench	GPT-5	87	DeepSeek-R1-0528 は 22.4
SAD (situational awareness)	Claude 3.5 Sonnet	54%	2024 年の結果

結果なし： DelusionEval、ELEPHANT / SnitchBench、Model-welfare self-report work

倫理と価値観

0 / 2

結果なし： TrolleyBench / MoralBench / MOSAIC、MultiTP / GlobalOpinionQA / PRISM / ETHICS

予測

0 / 2

結果なし： Prophet Arena、Prediction Arena / ForecastBench / ForecastQA

出典

一次データ。 Anthropic の発表ページと Claude Opus 5.5 のシステムカード、OpenAI の GPT-6 Astra の資料、Artificial Analysis（Intelligence Index v5 とエフォート別の内訳）、ARC Prize の結果、Epoch AI（ECI、FrontierMath）、Vals AI、Hex の DataBench の解説、ベンチマーク別のスコアについては BenchLM の比較ページと benchmarklist.com のリーダーボード。

確認したこと。 すべての数値は開けたページから読み取り、推定や補間はしていない。二つの情報源が食い違う場合は両方の値を載せた。

確認できなかったこと。 エフォート別のデータがあるモデルとベンチマークの組はごくわずかで、ここでの階梯の大半は二点から四点しかない。集計サイトの数値には一次ページの裏付けがないものもある。公式リーダーボードの多くはクライアント側で描画されて何も返さなかったため、一覧ではそれらのベンチマークは結果なしとなっている。